ΙΟΝΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ

Τμημα Πληροφορικης

Εξόρυξη και Ανάλυση Συναισθημάτων με Χρήση BERT και RoBERTa σε Κείμενα από Διαδικτυακές Πλατφόρμες

Στέργιος Μουτζίκος

Επιβλέπων Καθηγητής: κ. Ανδρέας Καναβός

Φεβρουάριος 2026

Abstract

This thesis addresses the extraction and analysis of sentiment from online platform texts using modern Natural Language Processing (NLP) techniques. Specifically, two pre-trained models based on the Transformer architecture are utilized: BERT (Bidirectional Encoder Representations from Transformers) and RoBERTa (Robustly Optimized BERT Pretraining Approach), which have been fine-tuned on the GoEmotions dataset for the classification of 28 distinct emotions, and were applied to data from the Stack Overflow platform.

The methodology includes data collection and preprocessing, application of both models for emotion recognition, and their comparative evaluation through statistical methods. The evaluation methods include agreement rates, Cohen's Kappa, McNemar's test, Pearson correlation analysis, and independent samples t-test.

The results demonstrate that both models exhibit high agreement at the broader sentiment category level, while they differ in the fine-grained classification of individual emotions. BERT displays higher confidence scores, suggesting potential overconfidence, whereas RoBERTa demonstrates better calibration. Furthermore, a correlation was identified between the recognized emotions and user engagement metrics.

This work contributes to the field by providing a systematic comparison of two leading sentiment analysis models and proposes directions for future research, including the use of newer models, multilingual expansion, and improvement of interpretability.

Keywords: Sentiment Analysis, BERT, RoBERTa, Natural Language Processing, Transformer, GoEmotions, Machine Learning, Text Mining

Περίληψη

Η παρούσα πτυχιακή εργασία πραγματεύεται την εξόρυξη και ανάλυση συναισθήματος από κείμενα διαδικτυακών πλατφορμών με χρήση σύγχρονων τεχνικών Επεξεργασίας Φυσικής Γλώσσας (NLP). Συγκεκριμένα, αξιοποιούνται δύο προ-εκπαιδευμένα μοντέλα βασισμένα στην αρχιτεκτονική Transformer: το BERT (Bidirectional Encoder Representations from Transformers) και το RoBERTa (Robustly Optimized BERT Pretraining Approach), τα οποία έχουν λεπτο-ρυθμιστεί στο σύνολο δεδομένων GoEmotions για την ταξινόμηση 28 διακριτών συναισθημάτων, και εφαρμόστηκαν σε δεδομένα από την πλατφόρμα Stack Overflow.
Η μεθοδολογία περιλαμβάνει τη συλλογή και προ-επεξεργασία δεδομένων, την εφαρμογή των δύο μοντέλων για την αναγνώριση συναισθημάτων, και τη συγκριτική αξιολόγησή τους μέσω στατιστικών μεθόδων. Οι μέθοδοι αξιολόγησης περιλαμβάνουν ποσοστά συμφωνίας, Cohen's Kappa, έλεγχο McNemar, ανάλυση συσχέτισης Pearson και independent samples t-test.
Τα αποτελέσματα καταδεικνύουν ότι τα δύο μοντέλα παρουσιάζουν υψηλή συμφωνία σε επίπεδο ευρύτερης συναισθηματικής κατηγορίας (sentiment), ενώ διαφέρουν στη λεπτομερή ταξινόμηση μεμονωμένων συναισθημάτων. Το BERT εμφανίζει υψηλότερα confidence scores, υποδηλώνοντας πιθανή υπερβολική εμπιστοσύνη, ενώ το RoBERTa παρουσιάζει καλύτερη βαθμονόμηση. Επιπλέον, διαπιστώθηκε συσχέτιση μεταξύ των αναγνωρισμένων συναισθημάτων και των μετρικών αλληλεπίδρασης των χρηστών (engagement metrics).
Η εργασία συνεισφέρει στον τομέα παρέχοντας μια συστηματική σύγκριση δύο κορυφαίων μοντέλων ανάλυσης συναισθήματος και προτείνει κατευθύνσεις για μελλοντική έρευνα, συμπεριλαμβανομένης της χρήσης νεότερων μοντέλων, της πολυγλωσσικής επέκτασης, και της βελτίωσης της ερμηνευσιμότητας.

Λέξεις-κλειδιά: Ανάλυση Συναισθήματος, BERT, RoBERTa, Επεξεργασία Φυσικής Γλώσσας, Transformer, GoEmotions, Μηχανική Μάθηση, Εξόρυξη Κειμένου

Ευχαριστίες

Με την ολοκλήρωση της πτυχιακής μου εργασίας, θα ήθελα να εκφράσω τις θερμές μου ευχαριστίες σε όλους όσους συνέβαλαν με οποιονδήποτε τρόπο στην ολοκλήρωσή της.

Αρχικά, θα ήθελα να ευχαριστήσω τον επιβλέποντα καθηγητή μου, κ. Ανδρέα Καναβό, για την καθοδήγηση και την εμπιστοσύνη που μου έδειξε καθ' όλη τη διάρκεια της ερευνητικής μου προσπάθειας.

Ευχαριστώ τους φίλους μου και συμφοιτητές μου για τις αμέτρητες στιγμές ανταλλαγής ιδεών καθ' όλη τη διάρκεια των σπουδών. Η παρουσία τους έκανε αυτή τη διαδρομή πιο όμορφη και ουσιαστική.

Επίσης, ένα μεγάλο ευχαριστώ οφείλω στην οικογένειά μου, και ειδικά στους γονείς μου και στην αδελφή μου, για την αμέριστη υποστήριξη και ακούραστη υπομονή τους καθ' όλη τη διάρκεια των σπουδών μου.

Τέλος, θα ήθελα να ευχαριστήσω και να συγχαρώ όλους τους φοιτητές και ανθρώπους που αγωνίζονται καθημερινά για ένα καλύτερο αύριο.

Στέργιος Μουτζίκος
Κέρκυρα, Φεβρουάριος 2026

Contents

1 Εισαγωγη 8
1.1 Εισαγωγή στον Ερευνητικό Χώρο της Εργασίας 8
1.2 Βασικές Προσεγγίσεις Επίλυσης 8
1.3 Ερευνητικά Ερωτήματα 9
1.4 Συνεισφορά της Εργασίας 10
2 Ερευνητικος Χωρος (με Βιβλιογραφικη Επισκοπηση) 10
2.1 Βιβλιογραφική Επισκόπηση 11
2.1.1 Αρχικές Προσεγγίσεις 11
2.1.2 Προσεγγίσεις Μηχανικής Μάθησης 11
2.1.3 Deep Learning και Transformers 12
2.1.4 Ανάλυση Συναισθημάτων στον Κοινωνικό Ιστό 12
2.1.5 Συσχέτιση Συναισθημάτων με Χαρακτηριστικά Χρήστη 13
3 Τα Μοντελα που χρησιμοποιηθηκαν 16
3.1 BERT: Bidirectional Encoder Representations from Transformers 16
3.1.1 Θεωρητικό Υπόβαθρο 16
3.1.2 Αρχιτεκτονική 16
3.1.3 Προ-εκπαίδευση 17
3.1.4 Χρησιμοποιούμενο Μοντέλο: BERT GoEmotions 17
3.2 RoBERTa: Robustly Optimized BERT Pretraining Approach . . . 17
3.2.1 Θεωρητικό Υπόβαθρο 17
3.2.2 Βασικές Διαφορές από το BERT 18
3.2.3 Προ-εκπαίδευση 19
3.2.4 Χρησιμοποιούμενο Μοντέλο: RoBERTa GoEmotions . . 19
3.3 Αντιστοίχιση Συναισθημάτων σε Κατηγορίες Sentiment 19
3.4 Σύγκριση Αρχιτεκτονικών 19

3.5 Πλεονεκτήματα και Μειονεκτήματα 21
3.5.1 BERT 21
3.5.2 RoBERTa 21
3.6 Hugging Face: Η Πλατφόρμα Φόρτωσης Μοντέλων 21
4 Μεθοδολογικη Διαδικασια 22
4.1 Πηγή Δεδομένων 22
4.1.1 Δομή και Πίνακες Δεδομένων 23
4.1.2 Στρατηγική Δειγματοληψίας 24
4.1.3 Κώδικας Εξαγωγής Δεδομένων 25
4.1.4 Στατιστικά Στοιχεία Εξαχθέντων Δεδομένων 26
4.2 Βιβλιοθήκες και Περιγραφή Δεδομένων 27
4.2.1 Εγκατάσταση Απαιτούμενων Βιβλιοθηκών 27
4.2.2 Εισαγωγή Βιβλιοθηκών και Αρχικοποίηση 28
4.2.3 Αρχική Διερεύνηση Δεδομένων 30
4.3 Περιγραφή Προεπεξεργασίας 34
4.3.1 Καθαρισμός Κειμένου (Text Cleaning) 34
4.3.2 Επαλήθευση Ποιότητας Καθαρισμού 36
4.3.3 Ανάλυση Μήκους Κειμένων 36
4.3.4 Προετοιμασία Δεδομένων για Ανάλυση NLP 38
4.4 Πειράματα Μάθησης 41
4.4.1 Ανάλυση Συναισθημάτων με GoEmotions Model 41
4.5 Μέθοδοι Στατιστικής Αξιολόγησης 44
4.6 Σύνοψη Μεθοδολογικής Διαδικασίας 45
5 Αναλυση και Αξιολογηση 46
5.1 Αρχική Σύγκριση Μοντέλων 46
5.2 Συγχώνευση Δεδομένων 47
5.3 Αντιστοίχιση Συναισθημάτων σε Κατηγορίες (Sentiment Mapping) 49
5.4 Ανάλυση Συμφωνίας Μοντέλων 50
5.5 Κατανομή Συναισθημάτων 52
5.5.1 Σύγκριση Κατανομής Συναισθημάτων 52
5.5.2 Οπτική Σύγκριση Κορυφαίων Συναισθημάτων 54
5.6 Κατανομή Sentiment 55
5.7 Confusion Matrix Μεταξύ Μοντέλων 57
5.8 Συσχέτιση Συναισθήματος με Βαθμολογία Σχολίου 58

5.9 Συνοπτικά Στατιστικά Ανάλυσης 59
5.10 Cross tabulation Ταξινόμηση Συναισθημάτων 60
5.11 Οπτικοποίηση Συμφωνίας Μοντέλων 62
5.12 Συνοπτικός Πίνακας Αποτελεσμάτων 63
5.13 Στατιστικοί Έλεγχοι 65
5.13.1 Έλεγχος McNemar 65
5.13.2 Ανάλυση Συσχετίσεων (Pearson Correlation) 67
5.13.3 Σύγκριση Confidence Scores 69
5.13.4 Cohen's Kappa: Συμφωνία Μεταξύ Μοντέλων 71
5.14 Πρόσθετες Οπτικοποιήσεις 72
5.14.1 Scatter Plot: Σύγκριση Confidence Scores 73
5.14.2 Ανάλυση Διαφωνιών: Ποια Συναισθήματα Προκαλούν Σύγχυση 74
5.15 Γεωγραφική Ανάλυση Συναισθημάτων 75
5.15.1 Κατανομή Τοποθεσιών Χρηστών 75
5.15.2 Heatmap: Συναισθήματα ανά Τοποθεσία 77
5.16 Ανάλυση Ψήφων ανά Συναίσθημα 78
5.16.1 Upvotes ανά Συναίσθημα 78
5.16.2 Downvotes ανά Συναίσθημα 78
5.17 Ανάλυση Συναισθημάτων ανά Ομάδα Βαθμολογίας 79
5.17.1 Δημιουργία Ομάδων Βαθμολογίας 79
5.17.2 Συναισθήματα ανά Βαθμολογία Σχολίου 80
5.17.3 Συναισθήματα ανά Βαθμολογία Δημοσίευσης 81
5.18 Συγκεντρωτικά Αποτελέσματα Σύγκρισης Μοντέλων 83
5.18.1 Τελικός Πίνακας Σύγκρισης Μοντέλων 83
5.18.2 Insights Ανάλυσης Συναισθημάτων 84
6 ΣΥΜΠΕΡΑΣΜΑΤΑ 86
6.1 Κύρια Συμπεράσματα 86
6.2 Απάντηση στα Ερευνητικά Ερωτήματα 87
6.3 Συνεισφορά της Εργασίας 87
6.3.1 Θεωρητική Συνεισφορά 87
6.3.2 Πρακτική Συνεισφορά 88
6.3.3 Στατιστική Συνεισφορά 88
6.4 Προτάσεις για Πρακτική Εφαρμογή 88

6.5 Περιορισμοί της Έρευνας 89
6.6 Τελική Σύνοψη 90
7 Προτασεις για Μελλοντικες Βελτιωσεις 90
7.1 Εμπλουτισμός Δεδομένων 90
7.1.1 Δημιουργία Ground Truth Dataset 90
7.1.2 Επέκταση σε Πολλαπλές Πλατφόρμες 90
7.1.3 Πολυγλωσσική Ανάλυση 91
7.2 Ποιοτική Ανάλυση και Επαλήθευση 91
7.2.1 Σύγκριση με Baseline Μοντέλα 91
7.2.2 Ποιοτική Έρευνα 91
7.2.3 Cross-Validation και Robustness 92
7.3 Προηγμένες Τεχνικές Ανάλυσης 92
7.3.1 Νεότερα Μοντέλα Transformer 92
7.3.2 Fine-tuning σε Domain-Specific Δεδομένα 92
7.3.3 Ensemble και Hybrid Μέθοδοι 92
7.3.4 Aspect-Based Sentiment Analysis 93
7.4 Τεχνολογικές Επεκτάσεις 93
7.4.1 Χρονική Ανάλυση (Temporal Analysis) 93
7.4.2 Ερμηνευσιμότητα (Explainability) 93
7.4.3 Ανίχνευση Ειρωνείας και Σαρκασμού 93
7.4.4 Real-Time Ανάλυση 94
7.5 Εφαρμογές και Αξιοποίηση 94
7.6 Σύνοψη Μελλοντικών Κατευθύνσεων 94
7.7 Επίλογος 95
8 Βιβλιογραφια 97

1 Εισαγωγή

1.1 Εισαγωγή στον Ερευνητικό Χώρο της Εργασίας

Η ραγδαία ανάπτυξη του διαδικτύου και η εκρηκτική αύξηση των διαδικτυακών πλατφορμών κοινωνικής δικτύωσης και ανταλλαγής γνώσεων έχουν δημιουργήσει έναν τεράστιο όγκο δεδομένων κειμένου που παράγεται καθημερινά από εκατομμύρια χρήστες παγκοσμίως. Οι πλατφόρμες αυτές, όπως το Stack Overflow, το Twitter, το Reddit και άλλες, αποτελούν πλέον αναπόσπαστο κομμάτι της ψηφιακής επικοινωνίας, παρέχοντας στους χρήστες τη δυνατότητα να εκφράζουν απόψεις, συναισθήματα και να ανταλλάσσουν πληροφορίες σε πραγματικό χρόνο. Η ανάλυση συναισθήματος (Sentiment Analysis) αποτελεί έναν από τους πιο δυναμικά αναπτυσσόμενους κλάδους της Επεξεργασίας Φυσικής Γλώσσας (Natural Language Processing - NLP) και της Τεχνητής Νοημοσύνης. Στόχος της είναι η αυτόματη αναγνώριση, εξαγωγή και ταξινόμηση των συναισθημάτων και των απόψεων που εκφράζονται μέσα σε κείμενα. Η σημασία της ανάλυσης συναισθήματος εκτείνεται σε πολλαπλές τομείς, συμπεριλαμβανομένης της παρακολούθησης της φήμης επιχειρήσεων, της ανάλυσης της κοινής γνώμης, της πρόβλεψης τάσεων της αγοράς, καθώς και της κατανόησης της συμπεριφοράς των χρηστών σε διαδικτυακές κοινότητες.
Η παρούσα πτυχιακή εργασία επικεντρώνεται στην εξόρυξη και ανάλυση συναισθήματος σε κείμενα που προέρχονται από διαδικτυακές πλατφόρμες, με τη χρήση σύγχρονων μοντέλων βαθιάς μάθησης βασισμένων στην αρχιτεκτονική Transformer. Συγκεκριμένα, πραγματοποιείται συγκριτική αξιολόγηση δύο κορυφαίων προεκπαιδευμένων μοντέλων: του BERT (Bidirectional Encoder Representations from Transformers) και του RoBERTa (Robustly Optimized BERT Pretraining Approach), τα οποία έχουν επιδείξει εξαιρετικές επιδόσεις σε ποικίλες εργασίες επεξεργασίας φυσικής γλώσσας.

1.2 Βασικές Προσεγγίσεις Επίλυσης

Οι παραδοσιακές προσεγγίσεις στην ανάλυση συναισθήματος περιλαμβάνουν:

- **Μέθοδοι βασισμένες σε λεξικά (Lexicon-based methods):** Χρησιμοποιούν προκαθορισμένα λεξικά συναισθημάτων όπου κάθε λέξη συσχετίζεται με μια συναισθηματική τιμή. Παραδείγματα αποτελούν τα VADER, SentiWordNet και AFINN.

- **Μέθοδοι μηχανικής μάθησης (Machine Learning methods):** Περιλαμβάνουν αλγορίθμους όπως Naive Bayes, Support Vector Machines (SVM) και Random

Forests, οι οποίοι εκπαιδεύονται σε επισημασμένα δεδομένα με χειροκίνητα εξαγόμενα χαρακτηριστικά.

- **Αναπαραστάσεις λέξεων (Word Embeddings):** Τεχνικές όπως Word2Vec και GloVe που αναπαριστούν λέξεις ως πυκνά διανύσματα σε έναν συνεχή διανυσματικό χώρο, αποτυπώνοντας σημασιολογικές σχέσεις.
- **Μοντέλα Transformer:** Η πλέον σύγχρονη προσέγγιση που βασίζεται στον μηχανισμό attention, με κορυφαίους εκπροσώπους τα μοντέλα BERT, RoBERTa, GPT και τις παραλλαγές τους.

Στην παρούσα εργασία υιοθετείται η προσέγγιση της μεταφοράς μάθησης (transfer learning) με χρήση προεκπαιδευμένων μοντέλων Transformer. Συγκεκριμένα:

1. Χρησιμοποιούνται τα μοντέλα BERT και RoBERTa που έχουν λεπτορυθμιστεί (fine-tuned) στο dataset GoEmotions για ταξινόμηση 28 συναισθημάτων, και εφαρμόζονται σε δεδομένα από το Stack Overflow.
2. Τα συναισθήματα αντιστοιχίζονται σε τρεις ευρύτερες κατηγορίες (θετικό, αρνητικό, ουδέτερο) για συγκριτική ανάλυση.
3. Εφαρμόζονται στατιστικοί έλεγχοι για την αξιολόγηση της συμφωνίας μεταξύ των μοντέλων και τη σύγκριση των επιδόσεων τους.

1.3 Ερευνητικά Ερωτήματα

Η παρούσα εργασία επιδιώκει να απαντήσει στα ακόλουθα ερευνητικά ερωτήματα:

1. **ΕΕ1:** Σε ποιο βαθμό συμφωνούν τα μοντέλα BERT και RoBERTa στην ανάλυση συναισθήματος;
2. **ΕΕ2:** Ποιες είναι οι διαφορές στη βαθμονόμηση (calibration) μεταξύ των δύο μοντέλων;
3. **ΕΕ3:** Ποια είναι τα κυρίαρχα συναισθήματα στην τεχνική κοινότητα του Stack Overflow;
4. **ΕΕ4:** Υπάρχει συσχέτιση μεταξύ συναισθήματος και δημοτικότητας σχολίων;
5. **ΕΕ5:** Σε ποια συναισθήματα παρατηρούνται οι περισσότερες διαφωνίες μεταξύ των μοντέλων;

1.4 Συνεισφορά της Εργασίας

Η παρούσα πτυχιακή εργασία συνεισφέρει στον ερευνητικό χώρο της ανάλυσης συναισθήματος μέσω των ακόλουθων:

1. **Συγκριτική Ανάλυση Μοντέλων:** Παρέχεται μια εκτενής συγκριτική αξιολόγηση των μοντέλων BERT και RoBERTa στην ανίχνευση συναισθημάτων, εξετάζοντας διαστάσεις όπως η ακρίβεια ταξινόμησης, η βαθμονόμηση των βαθμών εμπιστοσύνης και η συμφωνία μεταξύ των μοντέλων.

2. **Στατιστική Επικύρωση:** Εφαρμόζονται αυστηροί στατιστικοί έλεγχοι (Cohen's Kappa, McNemar's Test, Pearson Correlation, T-test) για την τεκμηρίωση των ευρημάτων και τη διασφάλιση της εγκυρότητας των συμπερασμάτων.

3. **Ανάλυση Πραγματικών Δεδομένων:** Η εργασία βασίζεται σε πραγματικά δεδομένα από την πλατφόρμα Stack Overflow, προσφέροντας γνώσεις για τη συναισθηματική δυναμική τεχνικών κοινοτήτων.

4. **Πολυδιάστατη Ανάλυση:** Διερευνάται η σχέση μεταξύ των ανιχνευόμενων συναισθημάτων και μετρικών αλληλεπίδρασης χρηστών (βαθμολογίες, upvotes, downvotes), καθώς και γεωγραφικών παραγόντων.

5. **Αναπαραγώγιμη Μεθοδολογία:** Παρέχεται πλήρης τεκμηρίωση της μεθοδολογίας και του κώδικα, επιτρέποντας την αναπαραγωγή των αποτελεσμάτων και την επέκταση της έρευνας.

2 Ερευνητικός Χώρος (με Βιβλιογραφική Επισκόπηση)

Το παρόν κεφάλαιο παρουσιάζει μια εκτενή βιβλιογραφική επισκόπηση του ερευνητικού χώρου της ανάλυσης συναισθήματος και της επεξεργασίας φυσικής γλώσσας. Η επισκόπηση καλύπτει την ιστορική εξέλιξη του πεδίου, τις παραδοσιακές και σύγχρονες μεθοδολογίες, καθώς και τις πρόσφατες εξελίξεις στα μοντέλα βαθιάς μάθησης με έμφαση στην αρχιτεκτονική Transformer και τα μοντέλα BERT και RoBERTa.

2.1 Βιβλιογραφική Επισκόπηση

2.1.1 Αρχικές Προσεγγίσεις

Η ανάλυση συναισθήματος ως ερευνητικό πεδίο άρχισε να αναπτύσσεται συστηματικά στις αρχές της δεκαετίας του 2000. Οι [24] πραγματοποίησαν μία από τις πρώτες συστηματικές μελέτες, εφαρμόζοντας τεχνικές μηχανικής μάθησης για την ταξινόμηση κριτικών ταινιών ως θετικές ή αρνητικές. Η εργασία τους έδειξε ότι απλοί αλγόριθμοι όπως ο Naive Bayes και τα Support Vector Machines μπορούσαν να επιτύχουν ακρίβεια περίπου 82% στην ταξινόμηση συναισθήματος.

Οι [31] πρότειναν μια μη επιβλεπόμενη μέθοδο βασισμένη στον σημασιολογικό προσανατολισμό φράσεων, χρησιμοποιώντας το Pointwise Mutual Information (PMI) για τον υπολογισμό της συναισθηματικής πολικότητας. Η προσέγγισή τους επέτρεψε την ανάλυση συναισθήματος χωρίς την ανάγκη επισημασμένων δεδομένων εκπαίδευσης.

Ο [17] παρουσίασε μια ολοκληρωμένη επισκόπηση του πεδίου, ορίζοντας τα θεμελιώδη προβλήματα και τις προκλήσεις της ανάλυσης συναισθήματος. Η εργασία του αποτέλεσε σημείο αναφοράς για τους ερευνητές, καθιερώνοντας την ορολογία και τα πλαίσια αξιολόγησης που χρησιμοποιούνται μέχρι σήμερα.

Η ανάπτυξη λεξικών συναισθημάτων αποτέλεσε θεμελιώδη συνεισφορά στον τομέα. Οι [12] δημιούργησαν ένα από τα πρώτα εκτενή λεξικά γνώμης, εντοπίζοντας λέξεις που εκφράζουν θετική ή αρνητική στάση. Το SentiWordNet, που αναπτύχθηκε από τους [1], επέκτεινε το WordNet με βαθμολογίες συναισθήματος για κάθε synset, παρέχοντας ένα πλούσιο λεξικογραφικό πόρο.

Το VADER (Valence Aware Dictionary and sEntiment Reasoner), που παρουσιάστηκε από τους [13], σχεδιάστηκε ειδικά για την ανάλυση κειμένων κοινωνικών μέσων. Το VADER λαμβάνει υπόψη τόσο τη λεξιλογική σημασία όσο και κανόνες γραμματικής και σύνταξης, επιτυγχάνοντας εξαιρετικές επιδόσεις σε ανεπίσημα κείμενα.

2.1.2 Προσεγγίσεις Μηχανικής Μάθησης

Οι παραδοσιακές μέθοδοι μηχανικής μάθησης κυριάρχησαν στον τομέα της ανάλυσης συναισθήματος για περισσότερο από μια δεκαετία. Οι [23] παρουσίασαν μια εκτενή επισκόπηση των μεθόδων εξόρυξης γνώμης, συγκρίνοντας διάφορους αλγορίθμους ταξινόμησης συμπεριλαμβανομένων των Naive Bayes, Maximum Entropy και Support Vector Machines.

Οι [10] εφάρμοσαν τεχνικές μηχανικής μάθησης για την ανάλυση συναισθήματος σε tweets, χρησιμοποιώντας emoticons ως θορυβώδεις ετικέτες για τη δημιουργία συνόλου εκπαίδευσης.

Η μεθοδολογία τους, γνωστή ως "distant supervision", έδειξε ότι μπορούν να επιτευχθούν ικανοποιητικές επιδόσεις χωρίς χειροκίνητη επισήμανση δεδομένων.
Η εισαγωγή των word embeddings σηματοδότησε μια σημαντική μετάβαση στην αναπαράσταση κειμένου. Οι [20] παρουσίασαν το Word2Vec, μια μέθοδο που μαθαίνει πυκνές διανυσματικές αναπαραστάσεις λέξεων από μεγάλα σώματα κειμένου. Οι [25] ανέπτυξαν το GloVe (Global Vectors for Word Representation), μια μέθοδο που συνδυάζει τα πλεονεκτήματα των μεθόδων παγκόσμιας στατιστικής πίνακα και τοπικών μεθόδων context window.

2.1.3 Deep Learning και Transformers

Τα Επαναληπτικά Νευρωνικά Δίκτυα (RNNs) αποτέλεσαν τις πρώτες αρχιτεκτονικές βαθιάς μάθησης που εφαρμόστηκαν επιτυχώς σε προβλήματα επεξεργασίας ακολουθιών. Οι [28] πρότειναν τα Recursive Neural Tensor Networks για την ανάλυση συναισθήματος σε επίπεδο πρότασης. Τα δίκτυα Long Short-Term Memory (LSTM), που παρουσιάστηκαν αρχικά από τους [11], αντιμετώπισαν το πρόβλημα του vanishing gradient.
Οι [14] εφάρμοσαν Συνελικτικά Νευρωνικά Δίκτυα στην ταξινόμηση κειμένου, χρησιμοποιώντας πολλαπλά φίλτρα διαφορετικών μεγεθών για την εξαγωγή n-gram χαρακτηριστικών.
Η αρχιτεκτονική Transformer, που παρουσιάστηκε από τους [32], επέφερε επανάσταση στην επεξεργασία φυσικής γλώσσας. Η βασική καινοτομία είναι ο μηχανισμός self-attention, ο οποίος επιτρέπει σε κάθε θέση της εισόδου να "προσέχει" όλες τις άλλες θέσεις.
Το BERT (Bidirectional Encoder Representations from Transformers), που παρουσιάστηκε από τους [8], αποτελεί ορόσημο στην ιστορία της NLP. Η βασική καινοτομία του BERT είναι η αμφίδρομη προεκπαίδευση, η οποία επιτρέπει στο μοντέλο να λαμβάνει υπόψη τόσο το αριστερό όσο και το δεξιό context κάθε token ταυτόχρονα.

2.1.4 Ανάλυση Συναισθημάτων στον Κοινωνικό Ιστό

Οι [26] οργάνωσαν τον διαγωνισμό SemEval-2017 Task 4 για ανάλυση συναισθήματος σε Twitter, ο οποίος αποτέλεσε σημείο αναφοράς για την αξιολόγηση συστημάτων ανάλυσης συναισθήματος σε κοινωνικά μέσα.
Οι [2] δημιούργησαν το TweetEval, ένα ενοποιημένο benchmark για αξιολόγηση μοντέλων NLP σε tweets, συμπεριλαμβάνοντας εργασίες ανάλυσης συναισθήματος, αναγνώρισης συναισθημάτων και ανίχνευσης hate speech.
Οι [21] ανέπτυξαν το BERTweet, ένα μοντέλο BERT προεκπαιδευμένο αποκλειστικά σε tweets, το οποίο επιτυγχάνει καλύτερες επιδόσεις σε εργασίες σχετικές με Twitter.

Η ανάλυση συναισθήματος σε τεχνικές κοινότητες όπως το Stack Overflow παρουσιάζει ιδιαίτερες προκλήσεις. Οι [22] δημιούργησαν ένα benchmark dataset για ανάλυση συναισθήματος σε τεχνικά κείμενα, επισημαίνοντας τις διαφορές με τα γενικού σκοπού datasets. Οι [4] μελέτησαν την ακρίβεια εργαλείων ανάλυσης συναισθήματος σε περιβάλλοντα ανάπτυξης λογισμικού.

Οι [33] παρουσίασαν μια εκτενή επισκόπηση των μεθόδων βαθιάς μάθησης για ανάλυση συναισθήματος, εντοπίζοντας τις κύριες προκλήσεις: ανεπίσημο ύφος γραφής και χρήση αργκό, ορθογραφικά λάθη και συντομογραφίες, ειρωνεία και σαρκασμός, έλλειψη context, και πολυγλωσσικό περιεχόμενο.

2.1.5 Συσχέτιση Συναισθημάτων με Χαρακτηριστικά Χρήστη

Οι [16] διερεύνησαν τη σχέση μεταξύ συναισθημάτων και ποιότητας απαντήσεων στο Stack Overflow, δείχνοντας ότι οι απαντήσεις με θετικό συναισθηματικό τόνο τείνουν να λαμβάνουν υψηλότερες βαθμολογίες.

Οι [29] παρουσίασαν μια συστηματική ανάλυση των μετρικών αξιολόγησης για ταξινόμηση, συμπεριλαμβανομένων precision, recall, F1-score και accuracy, αναλύοντας τις ιδιότητες και την καταλληλότητά τους για διαφορετικά σενάρια.

Ο [5] εισήγαγε το Cohen's Kappa, μια μετρική που μετρά τη συμφωνία μεταξύ δύο ταξινομητών λαμβάνοντας υπόψη τη συμφωνία που θα προέκυπτε τυχαία:

$$\kappa = \frac{p_o - p_e}{1 - p_e} \tag{1}$$

όπου p_o είναι η παρατηρούμενη συμφωνία και p_e είναι η αναμενόμενη τυχαία συμφωνία.

Ο [19] πρότεινε το McNemar's test για τη σύγκριση της απόδοσης δύο ταξινομητών στα ίδια δεδομένα:

$$\chi^2 = \frac{(b - c)^2}{b + c} \tag{2}$$

όπου b και c είναι οι αριθμοί των δειγμάτων στα οποία τα δύο μοντέλα διαφωνούν.

Το GoEmotions, που δημιουργήθηκε από τους [6], αποτελεί το μεγαλύτερο χειροκίνητα επισημασμένο dataset συναισθημάτων στην αγγλική γλώσσα. Περιλαμβάνει 58.000 σχόλια από το Reddit, επισημασμένα με 27 κατηγορίες συναισθημάτων συν μια ουδέτερη κατηγορία. Οι κατηγορίες οργανώνονται σε τρεις ομάδες: Θετικά (12), Αρνητικά (11), και Ουδέτερα/Αμφίσημα (5).

Στρατηγικές Fine-tuning και Παραλλαγές BERT: Οι [30] διερεύνησαν διάφορες στρατηγικές fine-tuning του BERT για ταξινόμηση κειμένου, προτείνοντας τεχνικές όπως το further pre-training σε domain-specific δεδομένα και τη σταδιακή αποδέσμευση (gradual unfreezing) των επιπέδων.
Οι [9] εφάρμοσαν το BERT για aspect-based sentiment analysis, προσθέτοντας ένα auxiliary sentence που περιέχει τον στόχο (aspect) για να κατευθύνει την προσοχή του μοντέλου.
Πολλές παραλλαγές του BERT έχουν προταθεί για τη βελτίωση διαφόρων πτυχών. Οι [27] ανέπτυξαν το DistilBERT, μια συμπαγή έκδοση του BERT χρησιμοποιώντας knowledge distillation, διατηρώντας το 97% των επιδόσεων με 40% λιγότερες παραμέτρους. Οι [15] πρότειναν το ALBERT με τεχνικές μείωσης παραμέτρων όπως factorized embedding parameterization και cross-layer parameter sharing.

RoBERTa και Βαθμονόμηση Μοντέλων: Το RoBERTa (Robustly Optimized BERT Pretraining Approach), που παρουσιάστηκε από τους [18], βελτιστοποίησε τη διαδικασία προεκπαίδευσης του BERT μέσω συστηματικών πειραμάτων. Οι κύριες αλλαγές περιλαμβάνουν:

- **Κατάργηση NSP:** Η εργασία Next Sentence Prediction αφαιρέθηκε, καθώς αποδείχθηκε ότι δεν συνεισφέρει σημαντικά στην απόδοση.
- **Dynamic Masking:** Αντί για στατικό masking, το pattern μασκαρίσματος αλλάζει σε κάθε epoch.
- **Μεγαλύτερα Batches:** Χρήση μεγαλύτερων batch sizes για βελτιωμένη σύγκλιση.
- **Περισσότερα Δεδομένα:** Προεκπαίδευση σε μεγαλύτερο corpus (160GB αντί για 16GB).

Οι [18] έδειξαν ότι το RoBERTa υπερτερεί του BERT σε διάφορα benchmarks, συμπεριλαμβανομένων των GLUE, RACE και SQuAD. Οι [7] διερεύνησαν τη βαθμονόμηση (calibration) των προβλέψεων μοντέλων βασισμένων σε Transformers, δείχνοντας ότι τα μεγάλα προεκπαιδευμένα μοντέλα τείνουν να είναι υπερβολικά σίγουρα (overconfident) για τις προβλέψεις τους.

Μεγάλα Γλωσσικά Μοντέλα (LLMs): Η ανάπτυξη μεγάλων γλωσσικών μοντέλων όπως το GPT-3 [3] έχει ανοίξει νέες δυνατότητες για την ανάλυση συναισθήματος μέσω

in-context learning και prompting. Οι [34] διερεύνησαν τις δυνατότητες του ChatGPT για ανάλυση συναισθήματος, διαπιστώνοντας ότι ενώ επιτυγχάνει εντυπωσιακές επιδόσεις σε γενικές εργασίες, τα εξειδικευμένα fine-tuned μοντέλα παραμένουν ανταγωνιστικά σε domain-specific εφαρμογές.

Σύνοψη Βιβλιογραφικής Επισκόπησης: Η βιβλιογραφική επισκόπηση αποκάλυψε τη σημαντική εξέλιξη του πεδίου της ανάλυσης συναισθήματος, από τις πρώιμες μεθόδους βασισμένες σε λεξικά έως τα σύγχρονα μοντέλα Transformer. Τα μοντέλα BERT και RoBERTa αντιπροσωπεύουν την τρέχουσα κατάσταση της τεχνολογίας, επιτυγχάνοντας εξαιρετικές επιδόσεις σε ποικίλες εργασίες ανάλυσης συναισθήματος.

Table 1: Σύνοψη Κύριων Ερευνητικών Εργασιών

Κατηγορία	**Εργασία**	**Συνεισφορά**
Παραδοσιακές Μέθοδοι	Pang et al. (2002)	ML για ανάλυση κριτικών
	Hutto & Gilbert (2014)	VADER για social media
Word Embeddings	Mikolov et al. (2013)	Word2Vec
	Pennington et al. (2014)	GloVe
Deep Learning	Kim (2014)	CNN για κείμενο
	Hochreiter & Schmidhuber (1997)	LSTM
Transformer	Vaswani et al. (2017)	Αρχιτεκτονική Transformer
	Devlin et al. (2018)	BERT
	Liu et al. (2019)	RoBERTa
	Sanh et al. (2019)	DistilBERT
Datasets	Demszky et al. (2020)	GoEmotions
Μετρικές Αξιολόγησης	Cohen (1960)	Cohen's Kappa
	McNemar (1947)	McNemar's Test
LLMs	Brown et al. (2020)	GPT-3

3 Τα Μοντέλα που χρησιμοποιήθηκαν

Στην παρούσα ενότητα παρουσιάζονται τα δύο προ-εκπαιδευμένα μοντέλα γλωσσικής κατανόησης που χρησιμοποιήθηκαν για την ανάλυση συναισθήματος: το BERT (Bidirectional Encoder Representations from Transformers) και το RoBERTa (Robustly Optimized BERT Pre-training Approach). Αμφότερα τα μοντέλα βασίζονται στην αρχιτεκτονική Transformer και αποτελούν σημεία αναφοράς στον τομέα της Επεξεργασίας Φυσικής Γλώσσας (NLP).

3.1 BERT: Bidirectional Encoder Representations from Transformers

3.1.1 Θεωρητικό Υπόβαθρο

Το BERT αναπτύχθηκε από την Google AI Language και παρουσιάστηκε το 2018. Αποτελεί ένα από τα πλέον επιδραστικά μοντέλα στον τομέα της Επεξεργασίας Φυσικής Γλώσσας, καθώς εισήγαγε την έννοια της *αμφίδρομης* (bidirectional) προ-εκπαίδευσης σε γλωσσικά μοντέλα.
Η θεμελιώδης καινοτομία του BERT έγκειται στην ικανότητά του να μαθαίνει συμφραζόμενες αναπαραστάσεις λέξεων (contextual word representations) λαμβάνοντας υπόψη τόσο το αριστερό όσο και το δεξί περιβάλλον μιας λέξης ταυτόχρονα. Αυτό επιτυγχάνεται μέσω του μηχανισμού *Masked Language Modeling* (MLM), κατά τον οποίο τυχαία tokens της εισόδου καλύπτονται (masked) και το μοντέλο εκπαιδεύεται να τα προβλέψει.

3.1.2 Αρχιτεκτονική

Η αρχιτεκτονική του BERT βασίζεται αποκλειστικά στον κωδικοποιητή (encoder) του Transformer. Τα κύρια χαρακτηριστικά περιλαμβάνουν:

- **Επίπεδα Transformer:** Το BERT-base αποτελείται από 12 επίπεδα (layers), ενώ το BERT-large από 24 επίπεδα.
- **Κεφαλές Προσοχής:** 12 κεφαλές προσοχής (attention heads) για το base μοντέλο και 16 για το large.
- **Κρυφή Διάσταση:** 768 μονάδες για το base και 1024 για το large μοντέλο.
- **Παράμετροι:** Περίπου 110 εκατομμύρια παράμετροι για το BERT-base.

Μαθηματικά, ο μηχανισμός self-attention υπολογίζεται ως:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{3}$$

όπου Q, K, V αντιπροσωπεύουν τους πίνακες Query, Key και Value αντίστοιχα, και d_k είναι η διάσταση των κλειδιών.

3.1.3 Προ-εκπαίδευση

Η προ-εκπαίδευση του BERT πραγματοποιείται με δύο στόχους:

1. **Masked Language Modeling (MLM):** Τυχαίο 15% των tokens καλύπτονται και το μοντέλο προβλέπει τα αρχικά tokens.
2. **Next Sentence Prediction (NSP):** Το μοντέλο μαθαίνει να προβλέπει εάν δύο προτάσεις είναι διαδοχικές στο αρχικό κείμενο.

3.1.4 Χρησιμοποιούμενο Μοντέλο: BERT GoEmotions

Στην παρούσα εργασία χρησιμοποιήθηκε το μοντέλο `monologg/bert-base-cased-goemotions-original` από την πλατφόρμα Hugging Face[1]. Το συγκεκριμένο μοντέλο έχει λεπτο-ρυθμιστεί (fine-tuned) στο σύνολο δεδομένων GoEmotions της Google, το οποίο περιλαμβάνει 58.000 σχόλια από το Reddit με ετικέτες για 27 διακριτά συναισθήματα συν μία κατηγορία "neutral".
Τα 28 συναισθήματα του GoEmotions περιλαμβάνουν: admiration, amusement, anger, annoyance, approval, caring, confusion, curiosity, desire, disappointment, disapproval, disgust, embarrassment, excitement, fear, gratitude, grief, joy, love, nervousness, optimism, pride, realization, relief, remorse, sadness, surprise και neutral.
Η υλοποίηση της ανάλυσης συναισθήματος με το BERT πραγματοποιήθηκε μέσω της βιβλιοθήκης Transformers της Hugging Face. Η αναλυτική περιγραφή του κώδικα και της διαδικασίας εφαρμογής παρουσιάζεται στην Ενότητα 4.4.

3.2 RoBERTa: Robustly Optimized BERT Pretraining Approach

3.2.1 Θεωρητικό Υπόβαθρο

Το RoBERTa αναπτύχθηκε από την Facebook AI (Meta AI) και παρουσιάστηκε το 2019. Αποτελεί μια βελτιστοποιημένη έκδοση του BERT, η οποία διατηρεί την ίδια αρχιτεκτονική αλλά τροποποιεί σημαντικά τη διαδικασία προ-εκπαίδευσης.

[1] https://huggingface.co/monologg/bert-base-cased-goemotions-original

Οι ερευνητές της Meta AI διαπίστωσαν ότι το αρχικό BERT ήταν σημαντικά υπο-εκπαιδευμένο (undertrained) και ότι με προσεκτική ρύθμιση των υπερπαραμέτρων και της διαδικασίας εκπαίδευσης, η απόδοση μπορούσε να βελτιωθεί σημαντικά.

3.2.2 Βασικές Διαφορές από το BERT

Το RoBERTa διαφοροποιείται από το BERT στα εξής σημεία:

1. **Αφαίρεση του NSP:** Η εργασία Next Sentence Prediction αφαιρέθηκε, καθώς αποδείχθηκε ότι δεν συνεισφέρει στην απόδοση ή ακόμη και την μειώνει.

2. **Δυναμικό Masking:** Αντί για στατικό masking που εφαρμόζεται μία φορά κατά την προ-επεξεργασία, το RoBERTa χρησιμοποιεί δυναμικό masking όπου το μοτίβο masking αλλάζει σε κάθε epoch.

3. **Μεγαλύτερα Batches:** Χρήση batch size 8.000 αντί για 256 του BERT.

4. **Περισσότερα Δεδομένα Εκπαίδευσης:** Εκπαίδευση σε 160GB κειμένου αντί για 16GB του BERT.

5. **Μεγαλύτερες Ακολουθίες:** Εκπαίδευση σε μεγαλύτερες ακολουθίες κειμένου.

6. **Byte-Level BPE:** Χρήση Byte-Pair Encoding σε επίπεδο byte αντί για character-level.

Table 2: Σύγκριση παραμέτρων προ-εκπαίδευσης BERT και RoBERTa

Παράμετρος	**BERT**	**RoBERTa**
Δεδομένα εκπαίδευσης	16GB	160GB
Batch size	256	8,000
Βήματα εκπαίδευσης	1M	500K
Next Sentence Prediction	Ναι	Όχι
Masking	Στατικό	Δυναμικό
Tokenization	WordPiece	Byte-level BPE

3.2.3 Προ-εκπαίδευση

Η προ-εκπαίδευση του RoBERTa διαφοροποιείται σημαντικά από αυτή του BERT:

1. **Masked Language Modeling (MLM) μόνο:** Σε αντίθεση με το BERT, το RoBERTa χρησιμοποιεί αποκλειστικά την εργασία MLM, καθώς αποδείχθηκε ότι η Next Sentence Prediction (NSP) δεν συνεισφέρει στην απόδοση.

2. **Δυναμικό Masking:** Το μοτίβο masking δημιουργείται δυναμικά σε κάθε epoch εκπαίδευσης, αντί να εφαρμόζεται στατικά μία φορά κατά την προ-επεξεργασία. Αυτό επιτρέπει στο μοντέλο να βλέπει διαφορετικές παραλλαγές του ίδιου κειμένου.

3. **Μεγαλύτερη Κλίμακα Εκπαίδευσης:** Εκπαίδευση με batch size 8.000 (αντί για 256) σε 160GB δεδομένων κειμένου (αντί για 16GB), επιτρέποντας καλύτερη γενίκευση.

3.2.4 Χρησιμοποιούμενο Μοντέλο: RoBERTa GoEmotions

Στην παρούσα εργασία χρησιμοποιήθηκε το μοντέλο `SamLowe/roberta-base-go_emotions` από την πλατφόρμα Hugging Face[2]. Όπως και το αντίστοιχο BERT μοντέλο, έχει λεπτορυθμιστεί στο σύνολο δεδομένων GoEmotions για την ταξινόμηση 28 συναισθημάτων.
Το συγκεκριμένο μοντέλο επιλέχθηκε λόγω της υψηλής απόδοσής του σε benchmarks ανάλυσης συναισθήματος και της ευρείας αποδοχής του από την ερευνητική κοινότητα.
Η υλοποίηση για το RoBERTa ακολουθεί παρόμοια δομή με αυτή του BERT. Η αναλυτική περιγραφή του κώδικα παρουσιάζεται στην Ενότητα 4.4.

3.3 Αντιστοίχιση Συναισθημάτων σε Κατηγορίες Sentiment

Για τη διευκόλυνση της συγκριτικής ανάλυσης, τα 28 συναισθήματα του GoEmotions αντιστοιχίστηκαν σε τρεις ευρύτερες κατηγορίες sentiment: θετικό (positive), αρνητικό (negative) και ουδέτερο (neutral). Η αντιστοίχιση αυτή βασίστηκε στη συναισθηματική βαλεντικότητα (valence) κάθε συναισθήματος. Ο αναλυτικός κώδικας αντιστοίχισης παρουσιάζεται στην Ενότητα 4.4.

3.4 Σύγκριση Αρχιτεκτονικών

Παρά τις ομοιότητες στη βασική αρχιτεκτονική, τα δύο μοντέλα παρουσιάζουν σημαντικές διαφορές που επηρεάζουν την απόδοσή τους:

[2] https://huggingface.co/SamLowe/roberta-base-go_emotions

Table 3: Κατηγοριοποίηση συναισθημάτων GoEmotions

Κατηγορία	**Συναισθήματα**
Θετικά (12)	admiration, amusement, approval, caring, desire, excitement, gratitude, joy, love, optimism, pride, relief
Αρνητικά (11)	anger, annoyance, disappointment, disapproval, disgust, embarrassment, fear, grief, nervousness, remorse, sadness
Ουδέτερα (5)	confusion, curiosity, neutral, realization, surprise

Table 4: Αναλυτική σύγκριση BERT και RoBERTa

Χαρακτηριστικό	**BERT-base**	**RoBERTa-base**
Επίπεδα Transformer	12	12
Κεφαλές Προσοχής	12	12
Κρυφή Διάσταση	768	768
Παράμετροι	110M	125M
Λεξιλόγιο	30,522	50,265
Tokenizer	WordPiece	Byte-level BPE
Μέγιστο Μήκος	512 tokens	512 tokens

3.5 Πλεονεκτήματα και Μειονεκτήματα

3.5.1 BERT

Πλεονεκτήματα:

- Πρωτοποριακό μοντέλο με εκτεταμένη τεκμηρίωση και υποστήριξη
- Ελαφρύτερο μοντέλο με λιγότερες παραμέτρους
- Ευρεία γκάμα προ-εκπαιδευμένων εκδόσεων για διάφορες γλώσσες

Μειονεκτήματα:

- Υπο-εκπαίδευση σε σχέση με νεότερα μοντέλα
- Το NSP task μπορεί να εισάγει θόρυβο
- Στατικό masking περιορίζει τη γενίκευση

3.5.2 RoBERTa

Πλεονεκτήματα:

- Βελτιωμένη απόδοση λόγω βελτιστοποιημένης εκπαίδευσης
- Δυναμικό masking για καλύτερη γενίκευση
- Εκπαίδευση σε περισσότερα δεδομένα
- Καλύτερη βαθμονόμηση εμπιστοσύνης (confidence calibration)

Μειονεκτήματα:

- Υψηλότερες υπολογιστικές απαιτήσεις κατά την εκπαίδευση
- Μεγαλύτερο μέγεθος λεξιλογίου

3.6 Hugging Face: Η Πλατφόρμα Φόρτωσης Μοντέλων

Τα μοντέλα που χρησιμοποιήθηκαν στην παρούσα εργασία αντλήθηκαν από την πλατφόρμα Hugging Face Hub[3], η οποία αποτελεί το κορυφαίο αποθετήριο για προ-εκπαιδευμένα μοντέλα μηχανικής μάθησης.
Η Hugging Face παρέχει:

[3] https://huggingface.co/

- Πρόσβαση σε χιλιάδες προ-εκπαιδευμένα μοντέλα
- Τυποποιημένο API μέσω της βιβλιοθήκης `transformers`
- Αυτόματη λήψη και caching μοντέλων
- Τεκμηρίωση και model cards για κάθε μοντέλο
- Δυνατότητα εύκολης σύγκρισης μοντέλων

Τα συγκεκριμένα μοντέλα που επιλέχθηκαν:

- **BERT:** `monologg/bert-base-cased-goemotions-original`
- **RoBERTa:** `SamLowe/roberta-base-go_emotions`

4 Μεθοδολογική Διαδικασία

Η παρούσα ενότητα περιγράφει τη μεθοδολογική διαδικασία που ακολουθήθηκε για την εκπόνηση της έρευνας. Η μεθοδολογία διαρθρώνεται σε πέντε φάσεις: (1) Συλλογή Δεδομένων από το Stack Overflow, (2) Προ-επεξεργασία και Καθαρισμός Κειμένου, (3) Διερευνητική Ανάλυση Δεδομένων, (4) Εφαρμογή Μοντέλων BERT και RoBERTa, και (5) Στατιστική Αξιολόγηση των αποτελεσμάτων.

4.1 Πηγή Δεδομένων

Για την εκπόνηση της παρούσας πτυχιακής εργασίας χρησιμοποιήθηκε το **Stack Overflow Data**, ένα δημόσια διαθέσιμο σύνολο δεδομένων που φιλοξενείται στην πλατφόρμα Google BigQuery και είναι προσβάσιμο μέσω του Kaggle[4]. Το συγκεκριμένο dataset αποτελεί ένα από τα πλέον εκτενή και αξιόπιστα σύνολα δεδομένων για την ανάλυση διαδικτυακών τεχνικών κοινοτήτων, καθώς περιέχει το σύνολο των δημοσιεύσεων, σχολίων και πληροφοριών χρηστών της πλατφόρμας Stack Overflow από την ίδρυσή της έως σήμερα.
Το Stack Overflow αποτελεί τη μεγαλύτερη διαδικτυακή κοινότητα προγραμματιστών παγκοσμίως, με εκατομμύρια ενεργούς χρήστες που ανταλλάσσουν γνώσεις, θέτουν ερωτήσεις και παρέχουν απαντήσεις σε τεχνικά ζητήματα. Η επιλογή αυτού του dataset κρίθηκε κατάλληλη για την παρούσα έρευνα, καθώς τα σχόλια των χρηστών αντικατοπτρίζουν ένα ευρύ φάσμα συναισθημάτων, από την ικανοποίηση και την ευγνωμοσύνη έως την απογοήτευση και την κριτική.

[4] https://www.kaggle.com/datasets/stackoverflow/stackoverflow

4.1.1 Δομή και Πίνακες Δεδομένων

Η πρόσβαση στα δεδομένα πραγματοποιήθηκε μέσω του Google BigQuery API, το οποίο επιτρέπει την εκτέλεση SQL ερωτημάτων σε μεγάλα σύνολα δεδομένων. Για τις ανάγκες της έρευνας, χρησιμοποιήθηκαν τρεις πίνακες από το δημόσιο dataset `bigquery-public-data.stackoverflow`:

1. **comments**: Περιέχει τα σχόλια των χρηστών σε δημοσιεύσεις. Αποτελεί τον κύριο πίνακα για την ανάλυση συναισθήματος.

2. **posts_answers**: Περιέχει πληροφορίες για τις δημοσιεύσεις και τις απαντήσεις, συμπεριλαμβανομένων μετρικών δημοτικότητας.

3. **users**: Περιέχει τα δημογραφικά στοιχεία και τις μετρικές δραστηριότητας των χρηστών.

Ο Πίνακας 5 παρουσιάζει αναλυτικά τα πεδία (columns) που εξήχθησαν από κάθε πίνακα.

Table 5: Πεδία δεδομένων ανά πίνακα

Πίνακας	**Πεδίο**	**Περιγραφή**
comments	id	Μοναδικός αναγνωριστικός αριθμός σχολίου
	text	Το κείμενο του σχολίου
	post_id	Αναγνωριστικό της σχετικής δημοσίευσης
	user_id	Αναγνωριστικό του χρήστη που έγραψε το σχόλιο
	score	Βαθμολογία του σχολίου (upvotes)
posts_answers	id	Μοναδικός αναγνωριστικός αριθμός δημοσίευσης
	comment_count	Αριθμός σχολίων στη δημοσίευση
	favorite_count	Αριθμός αγαπημένων
	score	Βαθμολογία της δημοσίευσης
users	id	Μοναδικός αναγνωριστικός αριθμός χρήστη
	display_name	Εμφανιζόμενο όνομα χρήστη
	age	Ηλικία χρήστη
	location	Γεωγραφική τοποθεσία
	reputation	Βαθμός φήμης στην πλατφόρμα
	up_votes	Συνολικές θετικές ψήφοι
	down_votes	Συνολικές αρνητικές ψήφοι

4.1.2 Στρατηγική Δειγματοληψίας

Λόγω του τεράστιου όγκου δεδομένων του Stack Overflow (δεκάδες εκατομμύρια σχόλια), εφαρμόστηκε τυχαία δειγματοληψία (random sampling) για την εξαγωγή ενός αντιπροσωπευτικού υποσυνόλου. Συγκεκριμένα:

- Εφαρμόστηκε τυχαία δειγματοληψία με πιθανότητα 5% (`RAND() < 0.05`) στον πίνακα σχολίων.
- Ορίστηκε ανώτατο όριο 110.000 σχολίων για τη διασφάλιση της υπολογιστικής αποδοτικότητας.

- Οι πίνακες **posts_answers** και **users** φιλτραρίστηκαν ώστε να περιλαμβάνουν μόνο τις εγγραφές που σχετίζονται με τα δειγματοληπτικά σχόλια, μέσω συνένωσης βάσει των πεδίων **post_id** και **user_id**.

Η προσέγγιση αυτή διασφαλίζει τη συνοχή των δεδομένων μεταξύ των τριών πινάκων, επιτρέποντας τη διασύνδεση σχολίων με τις αντίστοιχες δημοσιεύσεις και χρήστες για πολυδιάστατη ανάλυση.

4.1.3 Κώδικας Εξαγωγής Δεδομένων

Η εξαγωγή των δεδομένων πραγματοποιήθηκε μέσω του περιβάλλοντος Kaggle Notebooks με χρήση της βιβλιοθήκης **google-cloud-bigquery** της Python. Ο Κώδικας 1 παρουσιάζει την πλήρη διαδικασία εξαγωγής.

Listing 1: Εξαγωγή δεδομένων από Google BigQuery

```
import numpy as np
import pandas as pd
import os
from google.cloud import bigquery

# Initialize BigQuery client
bq_client = bigquery.Client()

# SAMPLE COMMENTS FIRST
query_comments =
    SELECT id, text, post_id, user_id, score
    FROM `bigquery-public-data.stackoverflow.comments`
    WHERE RAND() < 0.05
    LIMIT 110000

comments_df = bq_client.query(query_comments).to_dataframe()
print(f Sampled comments: {comments_df.shape} )

# GET UNIQUE POST_IDS AND USER_IDS
post_ids = comments_df[ post_id ].dropna().unique().tolist()
user_ids = comments_df[ user_id ].dropna().unique().tolist()
print(f Unique post IDs: {len(post_ids)} )
print(f Unique user IDs: {len(user_ids)} )

# GET ONLY MATCHING POSTS
```

```
query_posts =
    SELECT id, comment_count, favorite_count, score
    FROM `bigquery-public-data.stackoverflow.posts_answers`
    WHERE id IN UNNEST(@post_ids)

job_config = bigquery.QueryJobConfig(
    query_parameters=[
        bigquery.ArrayQueryParameter( post_ids ,  INT64 , post_ids)
    ]
)
posts_df = bq_client.query(query_posts, job_config=job_config).to_dataframe()
print(f Fetched posts: {posts_df.shape} )

# GET ONLY MATCHING USERS
query_users =
    SELECT id, display_name, age, location, reputation, up_votes, down_votes
    FROM `bigquery-public-data.stackoverflow.users`
    WHERE id IN UNNEST(@user_ids)

job_config = bigquery.QueryJobConfig(
    query_parameters=[
        bigquery.ArrayQueryParameter( user_ids ,  INT64 , user_ids)
    ]
)
users_df = bq_client.query(query_users, job_config=job_config).to_dataframe()
print(f Fetched users: {users_df.shape} )

# SAVE TO CSV FORMAT
comments_df.to_csv( /kaggle/working/comments.csv , index=False)
posts_df.to_csv( /kaggle/working/posts_answers.csv , index=False)
users_df.to_csv( /kaggle/working/users.csv , index=False)
```

4.1.4 Στατιστικά Στοιχεία Εξαχθέντων Δεδομένων

Ο Πίνακας 6 συνοψίζει τα στατιστικά στοιχεία του εξαχθέντος συνόλου δεδομένων.

Table 6: Στατιστικά στοιχεία εξαχθέντος συνόλου δεδομένων

Πίνακας	**Αριθμός Εγγραφών**	**Αριθμός Πεδίων**
comments	110.000	5
posts_answers	50853	4
users	54836	7

Τα εξαχθέντα δεδομένα αποθηκεύτηκαν σε τρία αρχεία μορφής CSV (`comments.csv`, `posts_answers.csv`, `users.csv`) για περαιτέρω επεξεργασία και ανάλυση.

4.2 Βιβλιοθήκες και Περιγραφή Δεδομένων

4.2.1 Εγκατάσταση Απαιτούμενων Βιβλιοθηκών

Για την εκτέλεση του κώδικα της παρούσας εργασίας απαιτείται η εγκατάσταση συγκεκριμένων βιβλιοθηκών Python. Οι απαιτούμενες βιβλιοθήκες καταγράφηκαν στο αρχείο `requirements.txt` και η εγκατάστασή τους πραγματοποιήθηκε μέσω του εργαλείου `pip`.

Listing 2: Περιεχόμενα αρχείου requirements.txt

```
pandas
numpy
seaborn
matplotlib
nltk
emoji
transformers
torch
scipy
statsmodels
scikit-learn
tqdm
ipywidgets
```

Η εγκατάσταση των βιβλιοθηκών πραγματοποιείται με την εκτέλεση της ακόλουθης εντολής:

Listing 3: Εντολή εγκατάστασης βιβλιοθηκών

```
pip install -r requirements.txt
```

4.2.2 Εισαγωγή Βιβλιοθηκών και Αρχικοποίηση

Ο Κώδικας 4 παρουσιάζει την εισαγωγή όλων των απαραίτητων βιβλιοθηκών και την αρχικοποίηση του περιβάλλοντος εκτέλεσης.

Listing 4: Εισαγωγή βιβλιοθηκών και αρχικοποίηση περιβάλλοντος

```
# IMPORT LIBRARIES
import pandas as pd
import numpy as np
import ast
import re
import os
import emoji
import warnings
from collections import Counter
from difflib import SequenceMatcher

# Visualization
import seaborn as sns
import matplotlib.pyplot as plt

# NLP & Text Processing
import nltk
from nltk.tokenize import word_tokenize
from nltk.corpus import stopwords

# Transformers (Hugging Face)
from transformers import pipeline
import torch
import time

# Statistics
from scipy.stats import pearsonr, spearmanr, ttest_ind
from statsmodels.stats.contingency_tables import mcnemar
from sklearn.metrics import (confusion_matrix,
                             ConfusionMatrixDisplay,
                             cohen_kappa_score)

# Display utilities
from IPython.display import display, HTML

```

```python
# Progress Bar
from tqdm.notebook import tqdm

# DOWNLOAD NLTK RESOURCES
nltk.download('punkt')
nltk.download('wordnet')
nltk.download('punkt_tab')
nltk.download('omw-1.4')
nltk.download('stopwords')

# Settings
tqdm.pandas()
warnings.filterwarnings('ignore')
```

Ο Πίνακας 7 παρουσιάζει συνοπτικά τον σκοπό κάθε βιβλιοθήκης.

Table 7: Περιγραφή χρησιμοποιούμενων βιβλιοθηκών

Βιβλιοθήκη	**Χρήση**
pandas	Επεξεργασία και ανάλυση δεδομένων
numpy	Αριθμητικοί υπολογισμοί
seaborn, matplotlib	Οπτικοποίηση δεδομένων
nltk	Επεξεργασία φυσικής γλώσσας
emoji	Διαχείριση emojis σε κείμενα
transformers	Προεκπαιδευμένα μοντέλα BERT/RoBERTa
torch	Framework βαθιάς μάθησης (PyTorch)
scipy, statsmodels	Στατιστικοί έλεγχοι
scikit-learn	Μετρικές αξιολόγησης
tqdm	Γραμμές προόδου
ipywidgets	Διαδραστικά στοιχεία Jupyter

Η εισαγωγή των βιβλιοθηκών οργανώνεται σε λογικές ομάδες:

- **Βασικές βιβλιοθήκες:** Για επεξεργασία δεδομένων και γενικές λειτουργίες (`pandas`, `numpy`, `re`, `os`).
- **Οπτικοποίηση:** Για τη δημιουργία γραφημάτων και διαγραμμάτων (`seaborn`, `matplotlib`).

- **Επεξεργασία Φυσικής Γλώσσας:** Για tokenization και αφαίρεση stop words (`nltk`, `emoji`).
- **Μοντέλα Transformer:** Για την εφαρμογή των μοντέλων BERT και RoBERTa (`transformers`, `torch`).
- **Στατιστική Ανάλυση:** Για τους στατιστικούς ελέγχους και τις μετρικές αξιολόγησης (`scipy`, `statsmodels`, `sklearn`).

Επιπλέον, πραγματοποιείται λήψη των απαραίτητων πόρων της βιβλιοθήκης NLTK, συμπεριλαμβανομένων των tokenizers και των λιστών stop words για την αγγλική γλώσσα.

Listing 5: Φόρτωση δεδομένων

```
import pandas as pd

comments = pd.read_csv( comments.csv )
posts_answers = pd.read_csv( posts_answers.csv )
users = pd.read_csv( users.csv )

print( Users shape: , users.shape)
print( Comments shape: , comments.shape)
print( Posts_answers shape: , posts_answers.shape)
```

- **comments.csv:** Σχόλια χρηστών με κείμενο και βαθμολογία
- **posts_answers.csv:** Δημοσιεύσεις και απαντήσεις
- **users.csv:** Πληροφορίες χρηστών (τοποθεσία, φήμη, ψήφοι)

4.2.3 Αρχική Διερεύνηση Δεδομένων

Μετά τη φόρτωση των δεδομένων, πραγματοποιήθηκε αρχική διερευνητική ανάλυση (Exploratory Data Analysis - EDA) για την κατανόηση της δομής και των χαρακτηριστικών των τριών συνόλων δεδομένων.

Ανάλυση Πίνακα Comments: Ο πίνακας `comments` αποτελεί τον κύριο πίνακα της ανάλυσης. Το Σχήμα 1 παρουσιάζει την αρχική διερεύνηση των δεδομένων, συμπεριλαμβανομένων των ελλιπών τιμών, των περιγραφικών στατιστικών και της κατανομής βαθμολογιών.

```
--- Initial Exploration: Comments Data (Selected Columns) ---

Head of Selected Columns:
```

	text	post_id	user_id	score
0	Check out http://uRequire.org project that bri...	16522990	799502.0	7
1	Or even simpler: Arrays.asList(1, 2, 3);	2607335	244360.0	125
2	@Juhana I was thinking maybe there was some wa...	18412129	912703.0	9
3	You just asked the same the question! http://s...	18415682	256196.0	5
4	Thank you. I also found that for just the purp...	18414263	1055817.0	12

```
Missing Values:
text          0
post_id       0
user_id    1078
score         0
dtype: int64
Duplicate Rows: 1
Unique Users: 54836
Unique Posts: 100818

Descriptive Statistics:
```

	score
count	110000.000000
mean	0.283300
std	2.809226
min	0.000000
25%	0.000000
50%	0.000000
75%	0.000000
max	484.000000

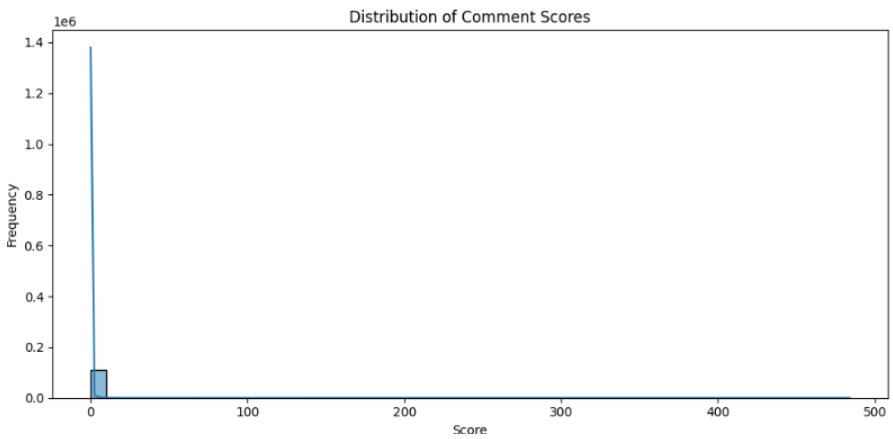

Figure 1: Αρχική διερεύνηση πίνακα Comments: ελλιπείς τιμές, περιγραφικά στατιστικά και κατανομή βαθμολογιών.

Ανάλυση Πίνακα Posts_answers: Ο πίνακας `posts_answers` περιέχει πληροφορίες για τις δημοσιεύσεις. Το Σχήμα 2 παρουσιάζει τα περιγραφικά στατιστικά και τις κατανομές των πεδίων.

```
--- Initial Exploration: Posts_answers (Selected Columns) ---

Head of Selected Columns:
```

	comment_count	favorite_count	score
0	1	NaN	0
1	1	NaN	0
2	1	NaN	0
3	1	NaN	1
4	1	NaN	1

```
Missing Values:
comment_count         0
favorite_count    50853
score                 0
dtype: int64
Duplicate Rows (excluding id): 48717

Descriptive Statistics:
```

	comment_count	favorite_count	score
count	50853.000000	0.0	50853.000000
mean	4.609561	NaN	10.407075
std	3.762111	NaN	89.020001
min	1.000000	NaN	-27.000000
25%	2.000000	NaN	0.000000
50%	4.000000	NaN	1.000000
75%	6.000000	NaN	3.000000
max	88.000000	NaN	5741.000000

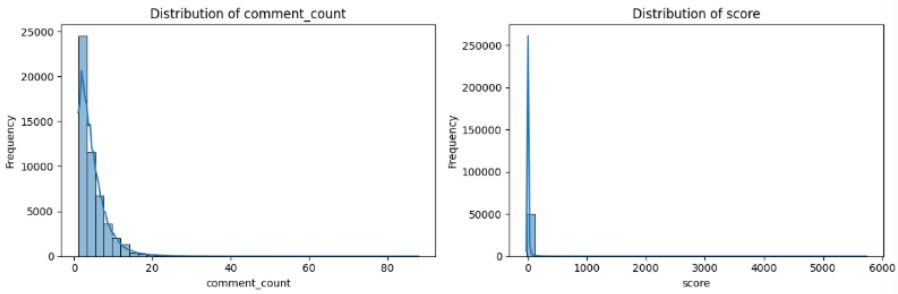

Figure 2: Αρχική διερεύνηση πίνακα Posts_answers: περιγραφικά στατιστικά και κατανομές.

Ανάλυση Πίνακα Users: Ο πίνακας users περιέχει δημογραφικά στοιχεία και μετρικές δραστηριότητας των χρηστών. Το Σχήμα 3 παρουσιάζει τις κατανομές των μετρικών reputation, up_votes και down_votes, οι οποίες ακολουθούν power-law κατανομή.

```
--- User Distributions: Reputation, Up Votes, Down Votes ---

Head of Selected Columns:
```

	age	location	reputation	up_votes	down_votes
0	NaN	Switzerland	313331	8360	216
1	NaN	London, United Kingdom	43384	370	27
2	NaN	Argentina	1828	140	31
3	NaN	Minneapolis, MN, United States	1558	1339	186
4	NaN	United Kingdom	31332	3450	334

```
Missing Values:
age           54836
location      25336
reputation        0
up_votes          0
down_votes        0
dtype: int64
Duplicate Rows: 8215

Descriptive Statistics:
```

	age	reputation	up_votes	down_votes
count	0	54,836	54,836	54,836
mean	NaN	8,499	543	162
std	NaN	34,087	1,493	1,889
min	NaN	1	0	0
25%	NaN	204	11	0
50%	NaN	1,244	90	3
75%	NaN	5,106	450	20
max	NaN	1,357,603	66,690	153,599

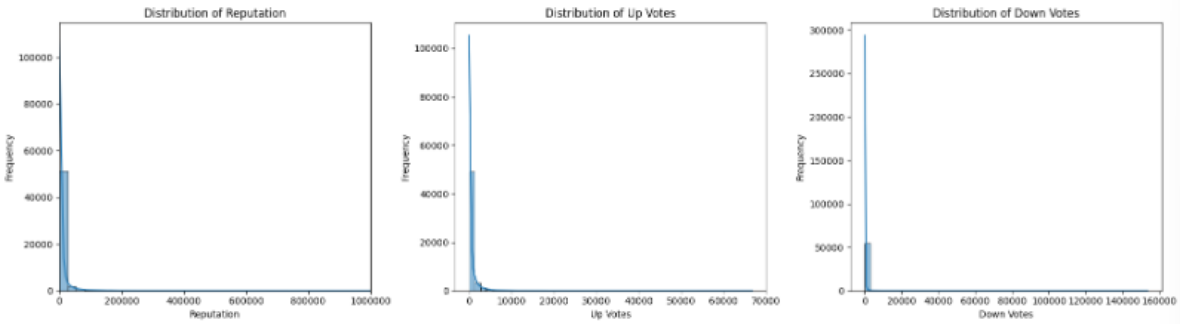

Figure 3: Κατανομές μετρικών χρηστών: reputation, up_votes και down_votes.

Γεωγραφική Κατανομή Χρηστών: Το Σχήμα 4 παρουσιάζει τις 10 συχνότερες τοποθεσίες χρηστών. Η Ινδία, η Γερμανία και οι Ηνωμένες Πολιτείες αποτελούν τις κορυφαίες τοποθεσίες. Ο Πίνακας 26 παρουσιάζει τα αναλυτικά δεδομένα.

```
Top 10 User Locations:
location
India                     774
Germany                   589
United States             525
London, United Kingdom    507
United Kingdom            423
Bangalore, India          321
Netherlands               308
Berlin, Germany           273
France                    252
Paris, France             233
Name: count, dtype: int64
```

Figure 4: Top 10 τοποθεσίες χρηστών βάσει αριθμού σχολίων.

Table 8: Κατανομή σχολίων ανά τοποθεσία χρήστη

Τοποθεσία	**Πλήθος**
India	774
Germany	589
United States	525
London, United Kingdom	507
United Kingdom	423
Bangalore, India	321
Netherlands	308
Berlin, Germany	273
France	252
Paris, France	233
Σύνολο Top 10	**4.205**

4.3 Περιγραφή Προεπεξεργασίας

Η προ-επεξεργασία περιλαμβάνει αφαίρεση HTML tags, URLs, emojis, και φιλτράρισμα βάσει ελάχιστου αριθμού λέξεων.

4.3.1 Καθαρισμός Κειμένου (Text Cleaning)

Listing 6: Text cleaning

```
# TEXT CLEANING UTILITIES


# Regex Patterns
URL_PATTERN = re.compile(r http\S+|www.\S+ )
MEANINGFUL_TEXT_PATTERN = re.compile(r \w{3,} )
EMOJI_PATTERN = re.compile( [\U0001F600-\U0001F64F
```

```
                            \U0001F300-\U0001F5FF
                            \U0001F680-\U0001F6FF
                            \U0001F1E0-\U0001F1FF]+ , flags=re.UNICODE)

def has_meaningful_text(text):
    text = URL_PATTERN.sub(  , text)
    return bool(MEANINGFUL_TEXT_PATTERN.search(text))

def remove_emojis(text):
    return emoji.replace_emoji(text, replace=  )

def clean_text(text, lower=True, strip=True, remove_urls=True, ↩
    remove_emojis_flag=True):
    if pd.isna(text):
        return

    text = re.sub(r'<[^>]+>', '', text)  # Remove HTML tags

    if lower:
        text = text.lower()
    if remove_urls:
        text = URL_PATTERN.sub(  , text)
    if remove_emojis_flag:
        text = remove_emojis(text)
    if strip:
        text = text.strip()
    return text

def clean_comments(df, text_col= text , min_words=3, drop_duplicates=True↩
    , remove_emojis_flag=True, lower=True):
    df = df.copy()
    df = df[df[text_col].notna()]
    df = df[df[text_col].str.strip() !=   ]
    df[text_col] = df[text_col].apply(lambda x: clean_text(x, lower=lower↩
        , remove_emojis_flag=remove_emojis_flag))
    if drop_duplicates:
        df = df.drop_duplicates(subset=[text_col])
    df = df[df[text_col].str.split().str.len() >= min_words]
    df = df[df[text_col].apply(has_meaningful_text)]
    return df.reset_index(drop=True)

```

```
comments_original_count = len(comments)

# Apply cleaning
comments = clean_comments(comments, min_words=3, remove_emojis_flag=True)
```

Table 9: Αποτελέσματα καθαρισμού δεδομένων

Μετρική	**Τιμή**
Αρχικός αριθμός σχολίων	110000
Τελικός αριθμός σχολίων	108687
Ποσοστό αφαίρεσης	1.2% (1313)

4.3.2 Επαλήθευση Ποιότητας Καθαρισμού

Μετά την εφαρμογή των διαδικασιών καθαρισμού, πραγματοποιήθηκε δειγματοληπτική επαλήθευση της ποιότητας των επεξεργασμένων κειμένων. Το Σχήμα 5 παρουσιάζει πέντε τυχαία επιλεγμένα καθαρισμένα σχόλια, επιβεβαιώνοντας την επιτυχή αφαίρεση HTML tags, URLs και emojis, διατηρώντας παράλληλα το ουσιαστικό περιεχόμενο του κειμένου.

```
--- Sample Cleaned Comments ---
Showing 5 random cleaned comments to verify quality:

1. @lundin - edited (with more readable option), however, the intent of the answer was to show a one-liner, and to show oth
er, simpler possibilities.  i ...

2. did you compile this as c or c++?  it should be complaining about the use of `instruction` without an accompanying `stru
ct` keyword.  your typdef name...

3. @edhedges interesting read

4. @danielgonzalez thanks for your answer; i copied the login.html page from server/conf to myapp/common; i do not have a l
oginerror.html. where should i...

5. what's the benefit of copying it to another variable?
```

Figure 5: Δείγμα καθαρισμένων σχολίων για επαλήθευση ποιότητας.

Τα δείγματα επιβεβαιώνουν ότι τα κείμενα διατηρούν τη σημασιολογική τους ακεραιότητα και είναι κατάλληλα για ανάλυση συναισθήματος με τα μοντέλα BERT και RoBERTa.

4.3.3 Ανάλυση Μήκους Κειμένων

Πριν την εφαρμογή των μοντέλων ανάλυσης συναισθήματος, εξετάστηκε η κατανομή του μήκους των σχολίων τόσο σε αριθμό λέξεων όσο και σε αριθμό χαρακτήρων. Η ανάλυση

αυτή είναι σημαντική καθώς τα μοντέλα BERT και RoBERTa έχουν όριο 512 tokens.

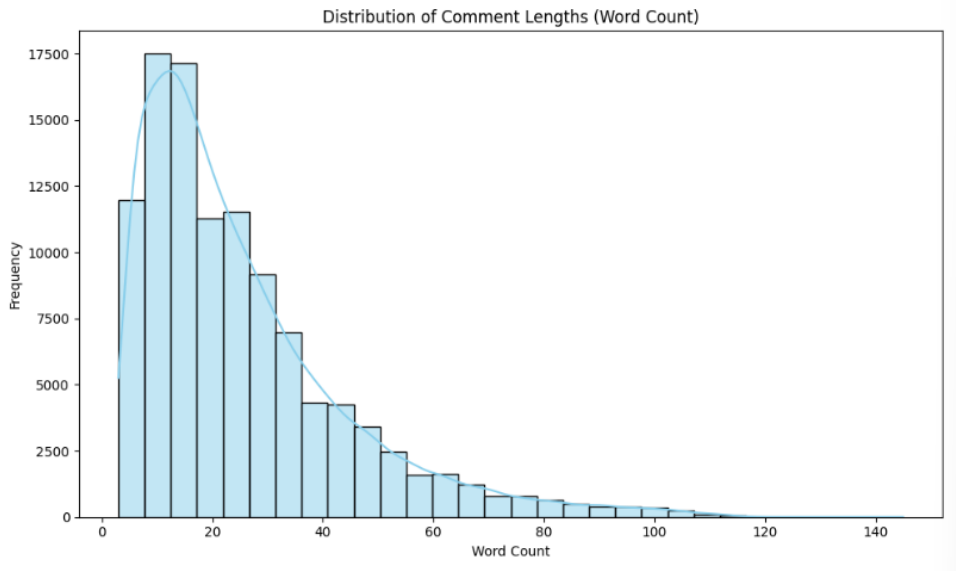

Figure 6: Κατανομή μήκους σχολίων σε αριθμό λέξεων. Η πλειονότητα των σχολίων περιέχει 10-20 λέξεις.

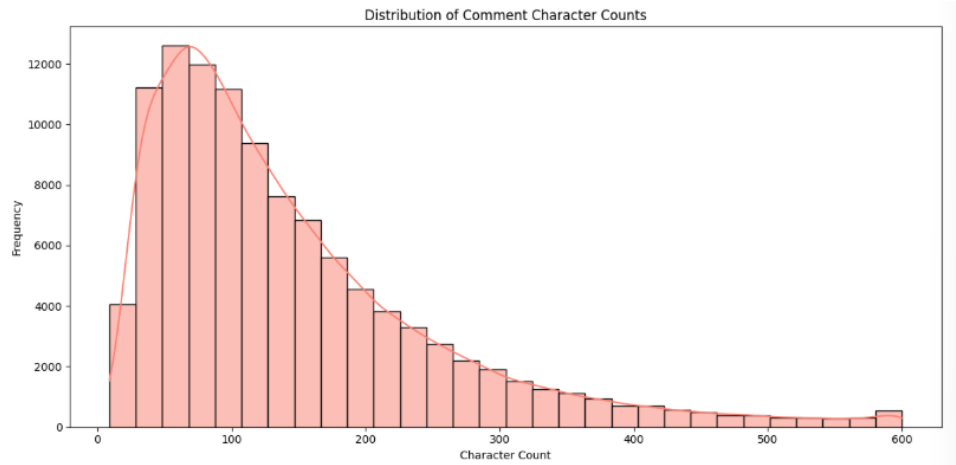

Figure 7: Κατανομή μήκους σχολίων σε αριθμό χαρακτήρων. Η κορυφή εντοπίζεται περίπου στους 50-100 χαρακτήρες.

Και οι δύο κατανομές παρουσιάζουν ασυμμετρία προς τα δεξιά (right-skewed), με την πλειονότητα των σχολίων να είναι σχετικά σύντομα. Το γεγονός αυτό διασφαλίζει ότι τα περισσότερα κείμενα δεν θα υπερβαίνουν το όριο tokens των μοντέλων Transformer.

4.3.4 Προετοιμασία Δεδομένων για Ανάλυση NLP

Για την ανάλυση συχνοτήτων κειμένου πραγματοποιήθηκε tokenization των σχολίων με αφαίρεση stop words και φιλτράρισμα μη αλφαβητικών χαρακτήρων. Στη συνέχεια, υπολογίστηκαν οι συχνότητες μονών λέξεων (unigrams), ζευγών λέξεων (bigrams) και τριάδων λέξεων (trigrams).

Listing 7: Tokenization και ανάλυση n-grams

```
# Unified preprocessing function
def preprocess_text(text):
    tokens = word_tokenize(str(text).lower())
    tokens = [t for t in tokens if t.isalpha() and t not in stop_words ↩
        and len(t) > 2]
    return tokens

# Apply to comments
comments['tokens'] = comments['text'].progress_apply(preprocess_text)

# Generate bigrams
bigrams_list = []
for tokens in comments['tokens']:
    bigrams_list.extend(list(nltk.bigrams(tokens)))

# Count top bigrams
bigram_counts = Counter(bigrams_list)
top_bigrams = bigram_counts.most_common(20)
```

Ανάλυση Συχνότητας Λέξεων (Unigrams): Το Σχήμα 8 παρουσιάζει τις 20 συχνότερες λέξεις στα σχόλια μετά την αφαίρεση stop words. Οι λέξεις "code", "use" και "thanks" κυριαρχούν, αντικατοπτρίζοντας τον τεχνικό χαρακτήρα της πλατφόρμας Stack Overflow καθώς και την εκδήλωση ευγνωμοσύνης μεταξύ των χρηστών.

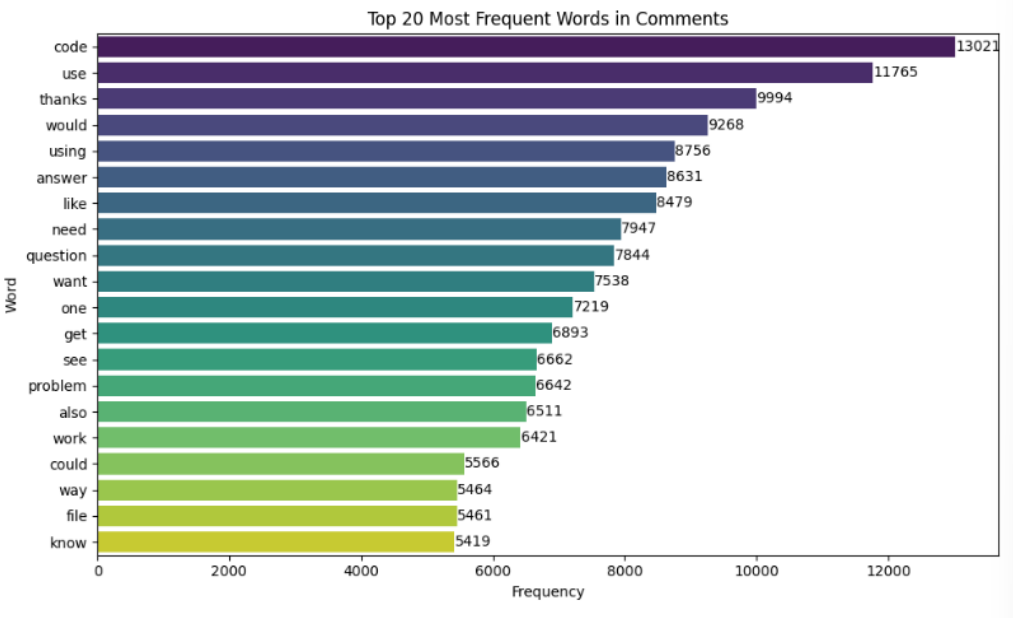

Figure 8: Οι 20 συχνότερες λέξεις στα σχόλια. Κυριαρχούν τεχνικοί όροι και εκφράσεις ευγνωμοσύνης.

Ανάλυση Bigrams: Τα bigrams αποκαλύπτουν συνήθεις φράσεις δύο λέξεων. Το Σχήμα 9 παρουσιάζει τα 20 συχνότερα bigrams, όπου εντοπίζονται εκφράσεις όπως "looks like", "something like", "thank much" και "thanks help", υποδεικνύοντας τόσο τεχνικές συζητήσεις όσο και θετικές αλληλεπιδράσεις.

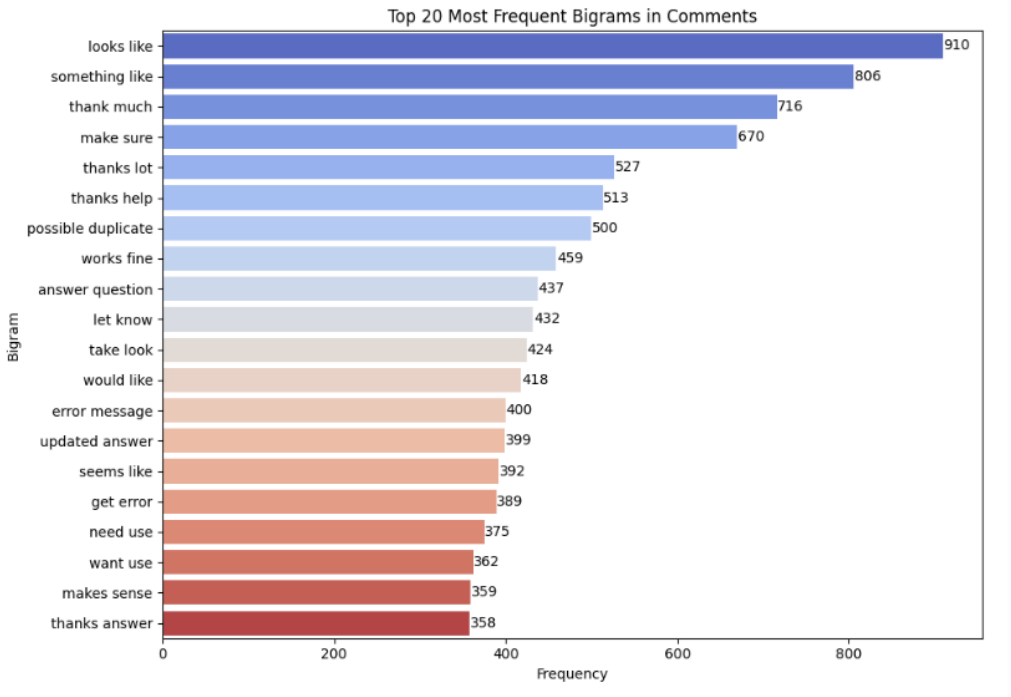

Figure 9: Τα 20 συχνότερα bigrams στα σχόλια.

Ανάλυση Trigrams: Τα trigrams παρέχουν ακόμη πιο λεπτομερή εικόνα των εκφράσεων. Το Σχήμα 10 παρουσιάζει τα 20 συχνότερα trigrams, όπου εντοπίζονται χαρακτηριστικές φράσεις της κοινότητας όπως "please let know", "works like charm", "glad could help" και "thank much help".

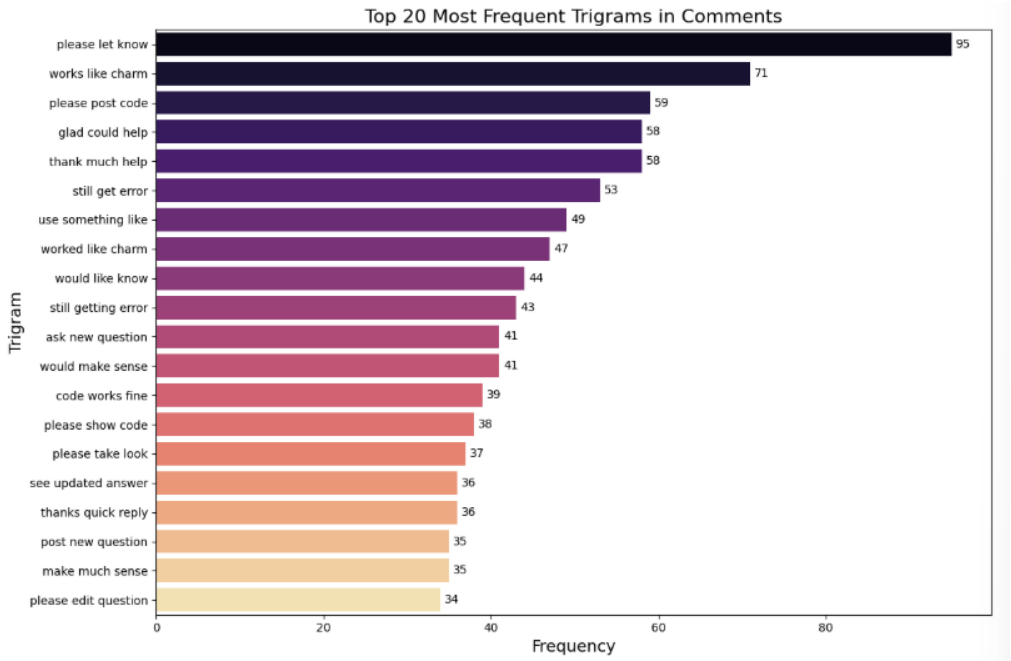

Figure 10: Τα 20 συχνότερα trigrams στα σχόλια.

Η ανάλυση n-grams αποκαλύπτει ότι τα σχόλια του Stack Overflow περιέχουν σημαντικό ποσοστό θετικών εκφράσεων (ευγνωμοσύνη, επιβεβαίωση λύσης), τεχνικής ορολογίας, καθώς και αιτημάτων για περαιτέρω βοήθεια.

4.4 Πειράματα Μάθησης

Η παρούσα υποενότητα περιγράφει την εφαρμογή των μοντέλων ανάλυσης συναισθήματος στα προεπεξεργασμένα δεδομένα.

4.4.1 Ανάλυση Συναισθημάτων με GoEmotions Model

Για την ανάλυση συναισθήματος χρησιμοποιήθηκαν δύο προ-εκπαιδευμένα μοντέλα από την πλατφόρμα Hugging Face, τα οποία έχουν λεπτο-ρυθμιστεί (fine-tuned) στο dataset GoEmotions για την ταξινόμηση 28 διακριτών συναισθημάτων:

- **RoBERTa:** `SamLowe/roberta-base-go_emotions`
- **BERT:** `monologg/bert-base-cased-goemotions-original`

Η εφαρμογή των μοντέλων πραγματοποιήθηκε μέσω της βιβλιοθήκης `transformers` της Hugging Face, χρησιμοποιώντας το pipeline API για ταξινόμηση κειμένου. Ο Κώδικας 8 παρουσιάζει την υλοποίηση.

Listing 8: Εφαρμογή μοντέλων ανάλυσης συναισθήματος

```
# Check GPU availability
device = 0 if torch.cuda.is_available() else -1
print(f Using device: {'GPU (CUDA)' if device == 0 else 'CPU'} )

# RoBERTa GoEmotions
def run_roberta_goemotions(df, text_col= text , batch_size=16):
    classifier = pipeline(
         text-classification ,
        model= SamLowe/roberta-base-go_emotions ,
        top_k=None,
        device=device,
        truncation=True
    )
    texts = [str(t)[:512] for t in df[text_col].tolist()]

    top_labels, top_scores, all_outputs = [], [], []

    for i in tqdm(range(0, len(texts), batch_size),
                  desc= Running RoBERTa GoEmotions ):
        batch = texts[i:i+batch_size]
        batch_results = classifier(batch)

        for result in batch_results:
            sorted_result = sorted(result, key=lambda x: x[ score ],
                                   reverse=True)
            top_labels.append(sorted_result[0][ label ])
            top_scores.append(sorted_result[0][ score ])
            all_outputs.append({r[ label ]: r[ score ] for r in ↩
                sorted_result})

    df[ roberta_top_emotion ] = top_labels
    df[ roberta_emotion_score ] = top_scores
```

```
    df[ roberta_all_emotions ] = all_outputs
    return df

# BERT GoEmotions
def run_bert_goemotions(df, text_col= text , batch_size=16):
    classifier = pipeline(
         text-classification ,
        model= monologg/bert-base-cased-goemotions-original ,
        top_k=None,
        device=device,
        truncation=True
    )
    texts = [str(t)[:512] for t in df[text_col].tolist()]

    top_labels, top_scores, all_outputs = [], [], []

    for i in tqdm(range(0, len(texts), batch_size),
                  desc= Running BERT GoEmotions ):
        batch = texts[i:i+batch_size]
        batch_results = classifier(batch)

        for result in batch_results:
            sorted_result = sorted(result, key=lambda x: x[ score ],
                                   reverse=True)
            top_labels.append(sorted_result[0][ label ])
            top_scores.append(sorted_result[0][ score ])
            all_outputs.append({r[ label ]: r[ score ] for r in ↩
                sorted_result})

    df[ bert_top_emotion ] = top_labels
    df[ bert_emotion_score ] = top_scores
    df[ bert_all_emotions ] = all_outputs
    return df

# Execute RoBERTa
print( Running RoBERTa GoEmotions... )
start_time = time.time()
comments = run_roberta_goemotions(comments)
print(f RoBERTa completed in {time.time() - start_time:.2f} seconds. )

# Execute BERT
```

```
print( Running BERT GoEmotions... )
start_time = time.time()
comments = run_bert_goemotions(comments)
print(f BERT completed in {time.time() - start_time:.2f} seconds. )

# Save results
comments.to_csv( comments_with_emotions.csv , index=False)
```

Για κάθε σχόλιο, τα μοντέλα επιστρέφουν:

- Το κυρίαρχο συναίσθημα (`top_emotion`)
- Το confidence score του κυρίαρχου συναισθήματος (`emotion_score`)
- Τις πιθανότητες για όλα τα 28 συναισθήματα (`all_emotions`)

Η επεξεργασία πραγματοποιήθηκε σε batches των 16 κειμένων για βελτιστοποίηση της υπολογιστικής απόδοσης. Κάθε κείμενο περικόπηκε στους 512 χαρακτήρες, το οποίο αντιστοιχεί στο μέγιστο όριο tokens των μοντέλων Transformer.

4.5 Μέθοδοι Στατιστικής Αξιολόγησης

Για τη συγκριτική αξιολόγηση των μοντέλων BERT και RoBERTa εφαρμόστηκαν οι ακόλουθες στατιστικές μέθοδοι:

- **Cohen's Kappa (κ):** Μέτρηση της συμφωνίας μεταξύ των δύο μοντέλων, λαμβάνοντας υπόψη την τυχαία συμφωνία.
- **McNemar's Test:** Έλεγχος για στατιστικά σημαντικές διαφορές στις προβλέψεις των μοντέλων.
- **Pearson Correlation:** Ανάλυση συσχέτισης μεταξύ confidence scores και μετρικών αλληλεπίδρασης.
- **Independent Samples t-test:** Σύγκριση των μέσων confidence scores μεταξύ BERT και RoBERTa.

Τα αναλυτικά αποτελέσματα των στατιστικών ελέγχων παρουσιάζονται στην Ενότητα 5.

4.6 Σύνοψη Μεθοδολογικής Διαδικασίας

Ο Πίνακας 10 συνοψίζει τα βασικά στάδια της μεθοδολογικής διαδικασίας που ακολουθήθηκε στην παρούσα εργασία.

Table 10: Συνοπτική παρουσίαση μεθοδολογικής διαδικασίας

Φάση	**Περιγραφή**	**Εργαλεία/Τεχνικές**	**Αποτέλεσμα**
1. Συλλογή Δεδομένων	Εξαγωγή σχολίων, δημοσιεύσεων και χρηστών από Stack Overflow	Google BigQuery API, Kaggle, SQL queries	110.000 σχόλια, 50.853 posts, 54.836 χρήστες
2. Προ-επεξεργασία	Καθαρισμός κειμένου: αφαίρεση HTML, URLs, emojis, φιλτράρισμα	Python (re, emoji), NLTK	108.687 καθαρισμένα σχόλια (98.8%)
3. Διερευνητική Ανάλυση	Ανάλυση κατανομών, μήκους κειμένων, n-grams	NLTK tokenization, Counter	Unigrams, bigrams, trigrams
4. Εφαρμογή Μοντέλων	Ανάλυση συναισθήματος με BERT και RoBERTa fine-tuned σε GoEmotions	Hugging Face Transformers, PyTorch	28 συναισθήματα + confidence scores
5. Στατιστική Αξιολόγηση	Σύγκριση μοντέλων και στατιστικοί έλεγχοι	Cohen's Kappa, McNemar, Pearson, t-test	Μετρικές συμφωνίας και σημαντικότητας

Table 11: Τεχνικές προδιαγραφές της έρευνας

Παράμετρος	**Τιμή**
Πηγή δεδομένων	Stack Overflow (BigQuery Public Dataset)
Μέγεθος δείγματος	110.000 σχόλια (5% τυχαία δειγματοληψία)
Τελικό μέγεθος μετά καθαρισμό	108.687 σχόλια
Μοντέλο BERT	monologg/bert-base-cased-goemotions-original
Μοντέλο RoBERTa	SamLowe/roberta-base-go_emotions
Dataset fine-tuning	GoEmotions (58.000 Reddit comments)
Αριθμός συναισθημάτων	28 (12 θετικά, 11 αρνητικά, 5 ουδέτερα)
Μέγιστο μήκος κειμένου	512 tokens
Batch size	16

5 Ανάλυση και Αξιολόγηση

Η παρούσα ενότητα παρουσιάζει τα αποτελέσματα της ανάλυσης συναισθήματος και τη συγκριτική αξιολόγηση των δύο μοντέλων BERT και RoBERTa.

5.1 Αρχική Σύγκριση Μοντέλων

Μετά την εφαρμογή των μοντέλων στα 108.687 σχόλια, πραγματοποιήθηκε αρχική σύγκριση των αποτελεσμάτων. Το Σχήμα 11 και ο Πίνακας 12 παρουσιάζουν τα 5 συχνότερα συναισθήματα για κάθε μοντέλο.

```
Quick Model Comparison

RoBERTa top 5 emotions:
roberta_top_emotion
neutral      60841
gratitude    13119
curiosity    11305
confusion     7140
approval      5215
Name: count, dtype: int64

BERT top 5 emotions:
bert_top_emotion
neutral      61655
gratitude    12814
curiosity    10014
confusion     7272
approval      4486
Name: count, dtype: int64
```

Figure 11: Σύγκριση των 5 συχνότερων συναισθημάτων μεταξύ RoBERTa και BERT.

Table 12: Συχνότητα των 5 κυρίαρχων συναισθημάτων ανά μοντέλο

Συναίσθημα	**RoBERTa**	**BERT**
neutral	60.841	61.655
gratitude	13.119	12.814
curiosity	11.305	10.014
confusion	7.140	7.272
approval	5.215	4.486
Σύνολο Top 5	**97.620**	**96.241**

Παρατηρείται ότι και τα δύο μοντέλα αναγνωρίζουν τα ίδια 5 κυρίαρχα συναισθήματα (neutral, gratitude, curiosity, confusion, approval), αν και με διαφορετικές συχνότητες. Το συναίσθημα "neutral" κυριαρχεί και στα δύο μοντέλα με περίπου 60.000 εμφανίσεις.

5.2 Συγχώνευση Δεδομένων

Για την ολοκληρωμένη ανάλυση, τα δεδομένα συναισθημάτων συγχωνεύτηκαν με τις πληροφορίες χρηστών και δημοσιεύσεων. Ο Κώδικας 9 παρουσιάζει τη διαδικασία συγχώνευσης.

Listing 9: Συγχώνευση δεδομένων

```
# LOAD & MERGE ALL DATA
comments = pd.read_csv( comments_with_emotions.csv )
users = pd.read_csv( users.csv )
posts = pd.read_csv( posts_answers.csv )

# Parse dictionary columns
def safe_parse(x):
    if pd.isna(x):
        return {}
    if isinstance(x, dict):
        return x
    try:
        return ast.literal_eval(x)
    except:
        return {}

comments[ roberta_all_emotions ] = comments[ roberta_all_emotions ].apply(safe_parse)
comments[ bert_all_emotions ] = comments[ bert_all_emotions ].apply(safe_parse)

# Merge with users (INCLUDING LOCATION)
df = comments.merge(
    users[[ id ,  location ,  reputation ,  up_votes ,  down_votes ]],
    left_on= user_id ,
    right_on= id ,
    how= left ,
    suffixes=('', '_user')
)

# Merge with posts
df = df.merge(
    posts[[ id ,  score ,  comment_count ,  favorite_count ]],
    left_on= post_id ,
    right_on= id ,
    how= left ,
    suffixes=('', '_post')
)

print(f Loaded {len(comments)} comments )
```

```
print(f Merged dataset shape: {df.shape} )
```

Το τελικό συγχωνευμένο dataset περιλαμβάνει 108.687 εγγραφές με 23 πεδία, συνδυάζοντας τα συναισθήματα με τα χαρακτηριστικά χρηστών και δημοσιεύσεων.

5.3 Αντιστοίχιση Συναισθημάτων σε Κατηγορίες (Sentiment Mapping)

Τα 28 συναισθήματα του GoEmotions ομαδοποιήθηκαν σε τρεις κατηγορίες sentiment για υψηλότερου επιπέδου ανάλυση:

- **Positive (12):** admiration, amusement, approval, caring, desire, excitement, gratitude, joy, love, optimism, pride, relief
- **Negative (11):** anger, annoyance, disappointment, disapproval, disgust, embarrassment, fear, grief, nervousness, remorse, sadness
- **Neutral (5):** confusion, curiosity, neutral, realization, surprise

Το Σχήμα 12 και ο Πίνακας 13 παρουσιάζουν την κατανομή sentiment για κάθε μοντέλο.

```
Sentiment mapping applied.

RoBERTa sentiment distribution:
roberta_sentiment
neutral     80144
positive    22106
negative     6437
Name: count, dtype: int64

BERT sentiment distribution:
bert_sentiment
neutral     80427
positive    22010
negative     6250
Name: count, dtype: int64
```

Figure 12: Κατανομή sentiment για RoBERTa και BERT μετά την ομαδοποίηση συναισθημάτων.

Table 13: Κατανομή sentiment ανά μοντέλο

Sentiment	**RoBERTa**	**%**	**BERT**	**%**
neutral	80.144	73,7%	80.427	74,0%
positive	22.106	20,3%	22.010	20,3%
negative	6.437	5,9%	6.250	5,8%
Σύνολο	**108.687**	**100%**	**108.687**	**100%**

5.4 Ανάλυση Συμφωνίας Μοντέλων

Για την αξιολόγηση της συνέπειας μεταξύ των δύο μοντέλων, υπολογίστηκε το ποσοστό συμφωνίας τόσο σε επίπεδο ακριβούς συναισθήματος όσο και σε επίπεδο sentiment.

Listing 10: Ανάλυση συμφωνίας μοντέλων

```
# MODEL AGREEMENT ANALYSIS

# Exact emotion agreement
emotion_agreement = (comments[ roberta_top_emotion ] == comments[ bert_top_emotion ]).mean()
print(f Exact Emotion Agreement: {emotion_agreement:.2%} )

# Sentiment agreement (positive/negative/neutral)
sentiment_agreement = (comments[ roberta_sentiment ] == comments[ bert_sentiment ]).mean()
print(f Sentiment Agreement: {sentiment_agreement:.2%} )

# Create agreement columns
comments[ models_agree_emotion ] = comments[ roberta_top_emotion ] == comments[ bert_top_emotion ]
comments[ models_agree_sentiment ] = comments[ roberta_sentiment ] == comments[ bert_sentiment ]

# Where do they disagree?
disagreements = comments[~comments[ models_agree_emotion ]]
print(f Number of disagreements: {len(disagreements)} ({len(disagreements)/len(comments)*100:.1f}%) )
```

Ο Πίνακας 14 παρουσιάζει τα αποτελέσματα της ανάλυσης συμφωνίας.

Table 14: Αποτελέσματα ανάλυσης συμφωνίας μεταξύ BERT και RoBERTa

Μετρική	**Τιμή**
Ακριβής Συμφωνία Συναισθήματος (Exact Emotion Agreement)	78,45%
Συμφωνία Sentiment (Sentiment Agreement)	90,40%
Αριθμός διαφωνιών (σε επίπεδο συναισθήματος)	23.425 (21,6%)

Τα αποτελέσματα δείχνουν ότι:

- Τα δύο μοντέλα συμφωνούν στο **78,45%** των περιπτώσεων όταν εξετάζεται το ακριβές συναίσθημα (28 κατηγορίες).
- Η συμφωνία αυξάνεται στο **90,40%** όταν εξετάζεται το sentiment (3 κατηγορίες).
- Οι διαφωνίες (21,6%) εντοπίζονται κυρίως σε λεπτές διακρίσεις μεταξύ παρόμοιων συναισθημάτων εντός της ίδιας κατηγορίας sentiment.

Το Σχήμα 13 παρουσιάζει δείγμα περιπτώσεων όπου τα δύο μοντέλα διαφωνούν. Παρατηρείται ότι οι περισσότερες διαφωνίες αφορούν λεπτές αποχρώσεις συναισθημάτων (π.χ. neutral vs confusion, admiration vs approval), ενώ το sentiment παραμένει συχνά το ίδιο.

```
Exact Emotion Agreement: 78.45%
Sentiment Agreement: 90.40%

Number of disagreements: 23425 (21.6%)

Sample disagreements:
```

	text	roberta_top_emotion	bert_top_emotion	roberta_sentiment	bert_sentiment
2	@juhana i was thinking maybe there was some wa...	neutral	confusion	neutral	neutral
6	nice, so `a = list(set(a))` gets the unique it...	admiration	approval	positive	positive
7	i can't read your image, but i found this:	neutral	realization	neutral	neutral
9	if you don't trust your friends, best to not g...	neutral	approval	neutral	positive
15	it is not working today. i can't find platform...	disapproval	neutral	negative	neutral
21	main problem : when you close it, all applicat...	neutral	disappointment	neutral	negative
28	how would you pass `object` from command line?...	curiosity	neutral	neutral	neutral
33	you've come to the right site if you're gettin...	neutral	approval	neutral	positive
34	still 4 months to christmas	neutral	surprise	neutral	neutral
37	sorry, i saw the mac os, and i thought you wer...	remorse	neutral	negative	neutral

Figure 13: Δείγμα διαφωνιών μεταξύ BERT και RoBERTa. Οι περισσότερες διαφωνίες αφορούν παρόμοια συναισθήματα εντός της ίδιας κατηγορίας sentiment.

Από το δείγμα διαφωνιών προκύπτουν τα εξής συμπεράσματα:

- Το RoBERTa τείνει να ταξινομεί περισσότερα σχόλια ως "neutral", ενώ το BERT διακρίνει πιο συγκεκριμένα συναισθήματα (confusion, realization, approval).
- Σε ορισμένες περιπτώσεις (γραμμές 9, 33), τα μοντέλα διαφωνούν και στο sentiment (neutral vs positive).
- Κείμενα με αμφίσημο ή τεχνικό περιεχόμενο παρουσιάζουν μεγαλύτερη πιθανότητα διαφωνίας.

5.5 Κατανομή Συναισθημάτων

Η παρούσα υποενότητα παρουσιάζει την αναλυτική κατανομή των 28 συναισθημάτων όπως ταξινομήθηκαν από τα δύο μοντέλα.

5.5.1 Σύγκριση Κατανομής Συναισθημάτων

Ο Πίνακας 15 παρουσιάζει την πλήρη κατανομή των 28 συναισθημάτων για τα δύο μοντέλα, καθώς και τη διαφορά μεταξύ τους.

Table 15: Κατανομή συναισθημάτων: Σύγκριση RoBERTa και BERT

Συναίσθημα	**RoBERTa**	**BERT**	**Διαφορά**
neutral	60.841	61.655	-814
gratitude	13.119	12.814	+305
curiosity	11.305	10.014	+1.291
confusion	7.140	7.272	-132
approval	5.215	4.486	+729
disapproval	2.681	2.259	+422
remorse	1.929	1.535	+394
admiration	1.258	1.797	-539
disappointment	1.138	1.159	-21
optimism	772	1.314	-542
caring	572	618	-46
realization	565	989	-424
joy	403	297	+106
annoyance	324	783	-459
amusement	312	273	+39
desire	307	196	+111
surprise	293	497	-204
sadness	138	144	-6
fear	133	182	-49
love	105	101	+4
excitement	43	82	-39
disgust	39	65	-26
embarrassment	26	78	-52
anger	17	33	-16
nervousness	12	12	0
pride	0	2	-2
relief	0	30	-30
Σύνολο	**108.687**	**108.687**	

Από τον πίνακα προκύπτουν τα εξής συμπεράσματα:

- Το **neutral** κυριαρχεί και στα δύο μοντέλα (56% των σχολίων).
- Το RoBERTa ανιχνεύει περισσότερα **curiosity** (+1.291) και **approval** (+729).

- Το BERT ανιχνεύει περισσότερα **admiration** (+539), **optimism** (+542) και **annoyance** (+459).
- Ορισμένα συναισθήματα (pride, relief) σχεδόν δεν ανιχνεύονται από το RoBERTa.

5.5.2 Οπτική Σύγκριση Κορυφαίων Συναισθημάτων

Το Σχήμα 14 παρουσιάζει οπτικά τη σύγκριση των 15 συχνότερων συναισθημάτων μεταξύ των δύο μοντέλων.

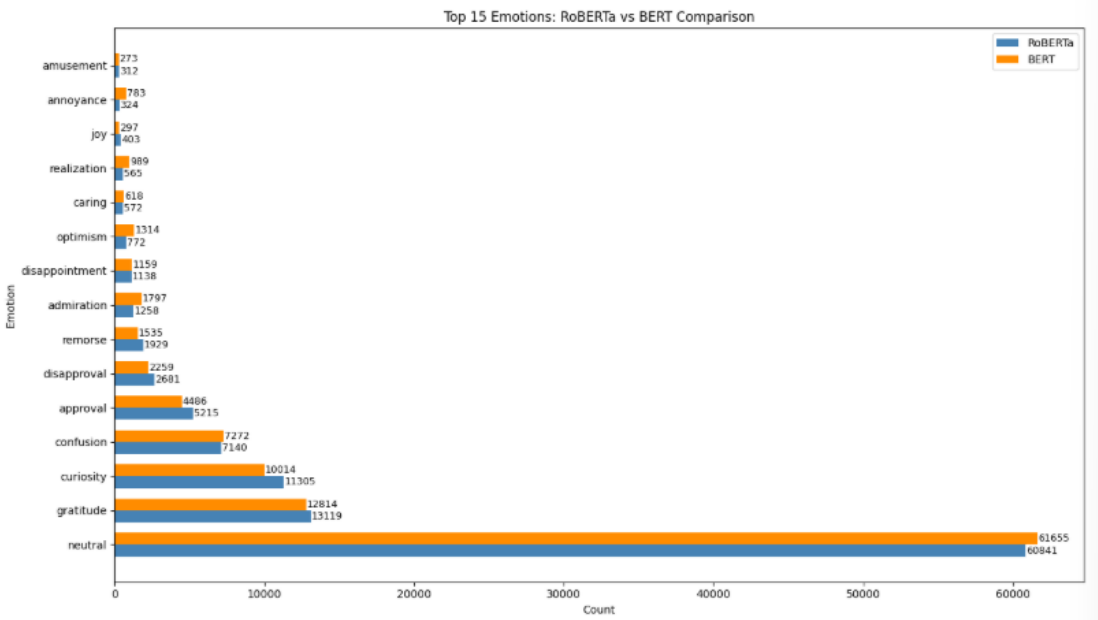

Figure 14: Σύγκριση των 15 συχνότερων συναισθημάτων μεταξύ RoBERTa (μπλε) και BERT (πορτοκαλί). Το neutral κυριαρχεί με περίπου 60.000 εμφανίσεις.

Η οπτική σύγκριση αναδεικνύει ότι:

- Τα δύο μοντέλα παρουσιάζουν παρόμοια ιεράρχηση συναισθημάτων.
- Οι μεγαλύτερες αποκλίσεις εντοπίζονται στα συναισθήματα curiosity, admiration και annoyance.
- Τα σπάνια συναισθήματα (anger, nervousness, pride) έχουν πολύ χαμηλή συχνότητα και στα δύο μοντέλα.

5.6 Κατανομή Sentiment

Μετά την ομαδοποίηση των 28 συναισθημάτων σε τρεις κατηγορίες sentiment (positive, negative, neutral), εξετάστηκε η συνολική κατανομή για κάθε μοντέλο.
Το Σχήμα 15 παρουσιάζει τη σύγκριση της κατανομής sentiment μεταξύ RoBERTa και BERT, τόσο σε μορφή pie chart όσο και σε μορφή bar chart.

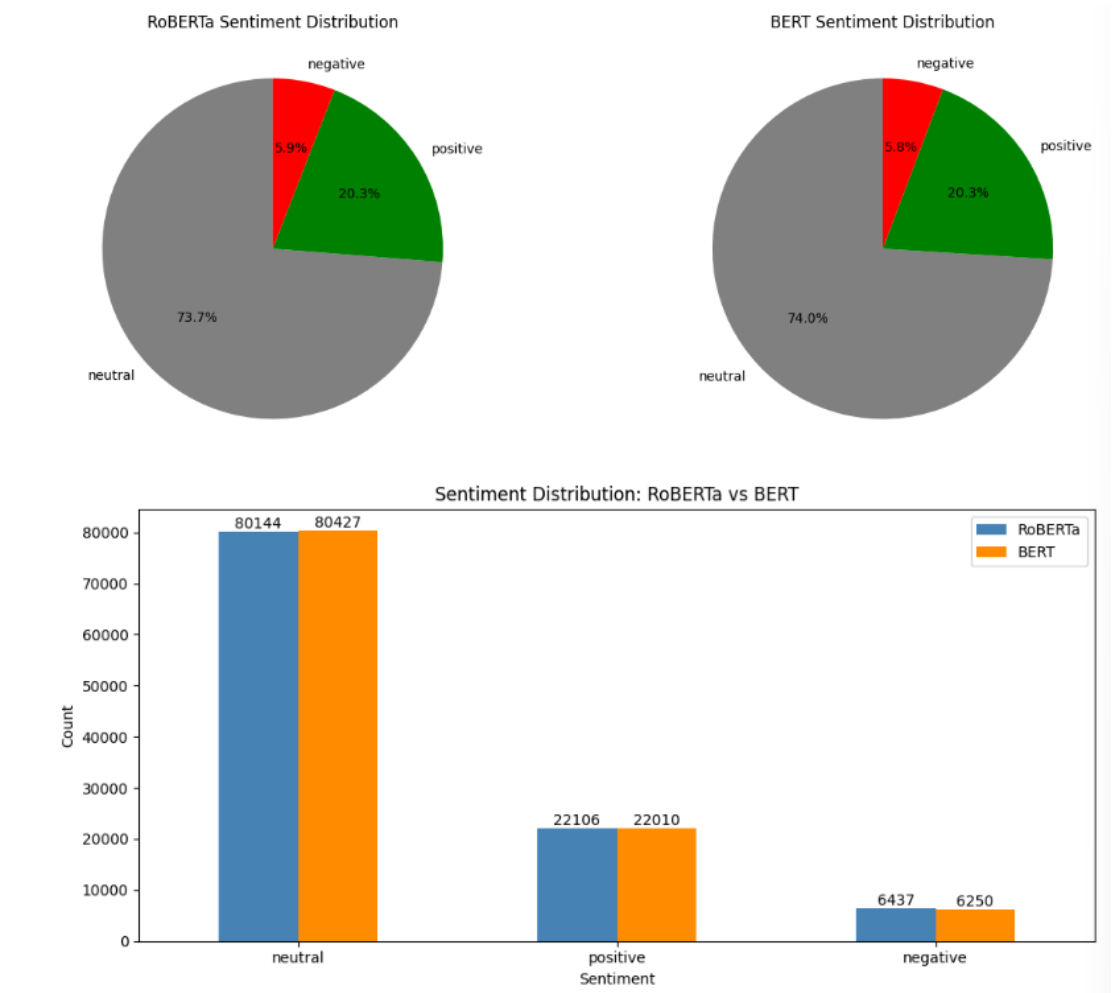

Figure 15: Κατανομή Sentiment για RoBERTa και BERT. Άνω: Pie charts με ποσοστά. Κάτω: Bar chart με απόλυτες τιμές.

Ο Πίνακας 16 συνοψίζει την κατανομή sentiment.

Table 16: Συγκριτική κατανομή Sentiment

Sentiment	**RoBERTa**	**RoBERTa (%)**	**BERT**	**BERT (%)**
Neutral	80.144	73,7%	80.427	74,0%
Positive	22.106	20,3%	22.010	20,3%
Negative	6.437	5,9%	6.250	5,8%
Σύνολο	108.687	100%	108.687	100%

Τα κύρια ευρήματα της ανάλυσης sentiment είναι:

- **Εντυπωσιακή ομοιότητα:** Τα δύο μοντέλα παρουσιάζουν σχεδόν ταυτόσημες κατανομές sentiment, με διαφορές μικρότερες του 0,3%.
- **Κυριαρχία neutral:** Περίπου 74% των σχολίων ταξινομούνται ως neutral, αντικατοπτρίζοντας τον τεχνικό και ενημερωτικό χαρακτήρα της πλατφόρμας Stack Overflow.
- **Θετικότητα:** Το 20% των σχολίων εκφράζει θετικό συναίσθημα, κυρίως μέσω ευγνωμοσύνης (gratitude) και έγκρισης (approval).
- **Χαμηλή αρνητικότητα:** Μόνο 6% των σχολίων είναι αρνητικά, υποδεικνύοντας μια σχετικά θετική κοινότητα.

5.7 Confusion Matrix Μεταξύ Μοντέλων

Για την αναλυτική κατανόηση των διαφωνιών μεταξύ των δύο μοντέλων, δημιουργήθηκε confusion matrix σε επίπεδο sentiment. Το Σχήμα 16 παρουσιάζει τον πίνακα σύγχυσης μεταξύ RoBERTa και BERT.

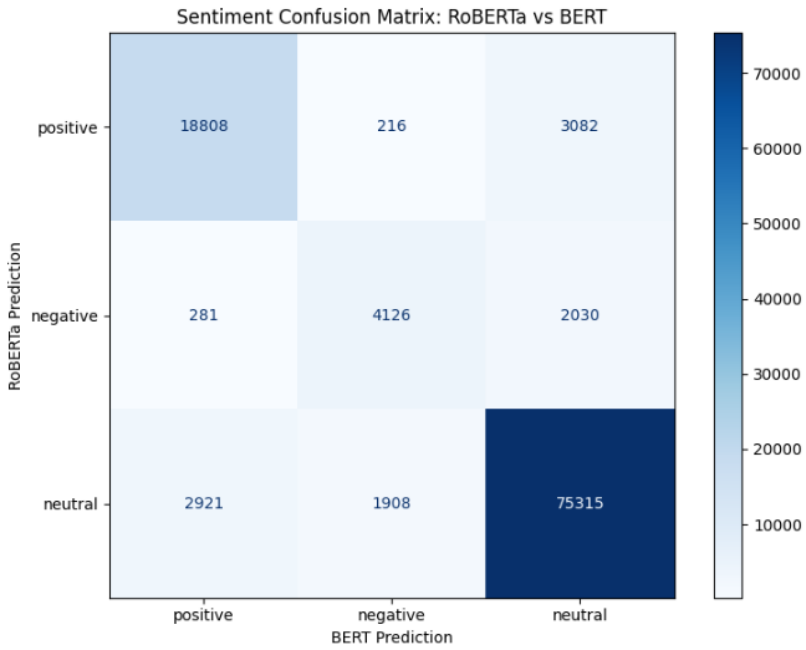

Figure 16: Confusion Matrix μεταξύ RoBERTa και BERT σε επίπεδο Sentiment. Οι διαγώνιοι αριθμοί αντιπροσωπεύουν τη συμφωνία μεταξύ των μοντέλων.

Ο Πίνακας 17 αναλύει τα αποτελέσματα του confusion matrix.

Table 17: Ανάλυση Confusion Matrix: Συμφωνίες και Διαφωνίες

RoBERTa	**BERT**	**Πλήθος**
Συμφωνίες (Διαγώνιος):		
Positive	Positive	18.808
Negative	Negative	4.126
Neutral	Neutral	75.315
Σύνολο Συμφωνιών		**98.249 (90,4%)**
Κύριες Διαφωνίες:		
Positive	Neutral	3.082
Neutral	Positive	2.921
Negative	Neutral	2.030
Neutral	Negative	1.908
Σύνολο Διαφωνιών		**10.438 (9,6%)**

Από τον confusion matrix προκύπτουν τα εξής:

- Η μεγαλύτερη συμφωνία εντοπίζεται στην κατηγορία **neutral** (75.315 σχόλια), όπου και τα δύο μοντέλα συμφωνούν στην πλειονότητα των περιπτώσεων.
- Οι κύριες διαφωνίες αφορούν τη διάκριση μεταξύ **neutral** και **positive** sentiment (6.000 περιπτώσεις συνολικά).
- Η διαφωνία μεταξύ **positive** και **negative** είναι ελάχιστη (216 + 281 = 497 περιπτώσεις), υποδεικνύοντας ότι τα μοντέλα διακρίνουν σαφώς τα αντίθετα συναισθήματα.

5.8 Συσχέτιση Συναισθήματος με Βαθμολογία Σχολίου

Εξετάστηκε η σχέση μεταξύ του αναγνωρισμένου συναισθήματος και της βαθμολογίας (upvotes) που λαμβάνει το σχόλιο από την κοινότητα. Το Σχήμα 17 παρουσιάζει τη μέση βαθμολογία σχολίων ανά συναίσθημα για κάθε μοντέλο.

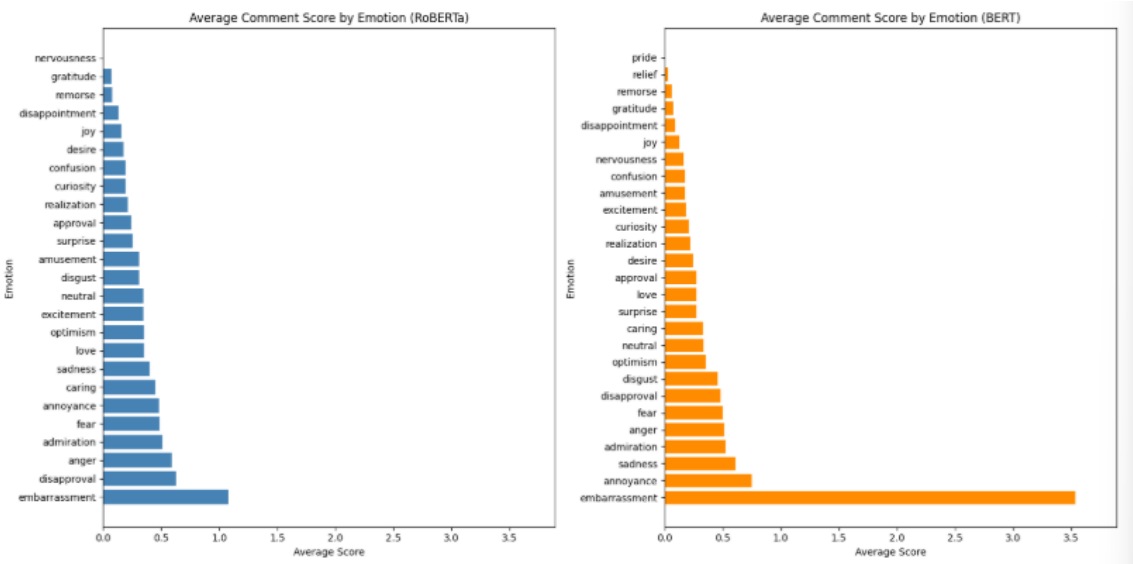

Figure 17: Μέση βαθμολογία σχολίων ανά συναίσθημα για RoBERTa (αριστερά) και BERT (δεξιά).

Από την ανάλυση προκύπτουν τα εξής ευρήματα:

- Το συναίσθημα **embarrassment** σχετίζεται με τις υψηλότερες βαθμολογίες και στα δύο μοντέλα, πιθανώς λόγω του χιουμοριστικού χαρακτήρα τέτοιων σχολίων.
- Τα αρνητικά συναισθήματα (**disapproval**, **anger**, **annoyance**) τείνουν να έχουν υψηλότερες βαθμολογίες σε σχέση με τα neutral.
- Τα θετικά συναισθήματα όπως **gratitude** και **admiration** παρουσιάζουν χαμηλότερες μέσες βαθμολογίες, καθώς συνήθως αποτελούν απλές ευχαριστίες.
- Το BERT παρουσιάζει μεγαλύτερη διακύμανση στις μέσες βαθμολογίες, ιδιαίτερα για τα συναισθήματα annoyance και sadness.

5.9 Συνοπτικά Στατιστικά Ανάλυσης

Μετά την ολοκλήρωση της ανάλυσης, τα επεξεργασμένα δεδομένα αποθηκεύτηκαν για περαιτέρω χρήση. Ο Πίνακας 18 συνοψίζει τα κύρια στατιστικά της ανάλυσης.

Table 18: Συνοπτικά στατιστικά ανάλυσης συναισθήματος

Μετρική	**Τιμή**
Συνολικά σχόλια που αναλύθηκαν	108.687
Ποσοστό συμφωνίας συναισθήματος (Emotion Agreement)	78,45%
Ποσοστό συμφωνίας sentiment (Sentiment Agreement)	90,40%
Μέσο confidence score RoBERTa	0,7528
Μέσο confidence score BERT	0,9378

Τα συνοπτικά στατιστικά αναδεικνύουν:

- **Υψηλή συμφωνία:** Τα δύο μοντέλα συμφωνούν στο 90,4% των περιπτώσεων σε επίπεδο sentiment, υποδεικνύοντας αξιοπιστία στην ανάλυση.
- **Διαφορά confidence:** Το BERT παρουσιάζει σημαντικά υψηλότερο μέσο confidence score (0,94 vs 0,75), υποδεικνύοντας πιθανή υπερβολική εμπιστοσύνη (overconfidence).
- **Επαρκές δείγμα:** Τα 108.687 σχόλια παρέχουν στατιστικά σημαντικό δείγμα για αξιόπιστα συμπεράσματα.

5.10 Cross tabulation Ταξινόμηση Συναισθημάτων

Για την αναλυτική κατανόηση των διαφωνιών σε επίπεδο συναισθήματος (και όχι μόνο sentiment), δημιουργήθηκε πίνακας διασταυρωμένης ταξινόμησης (cross-tabulation) μεταξύ των προβλέψεων των δύο μοντέλων.
Το Σχήμα 18 παρουσιάζει τον πλήρη πίνακα διασταυρωμένης ταξινόμησης για όλα τα 28 συναισθήματα.

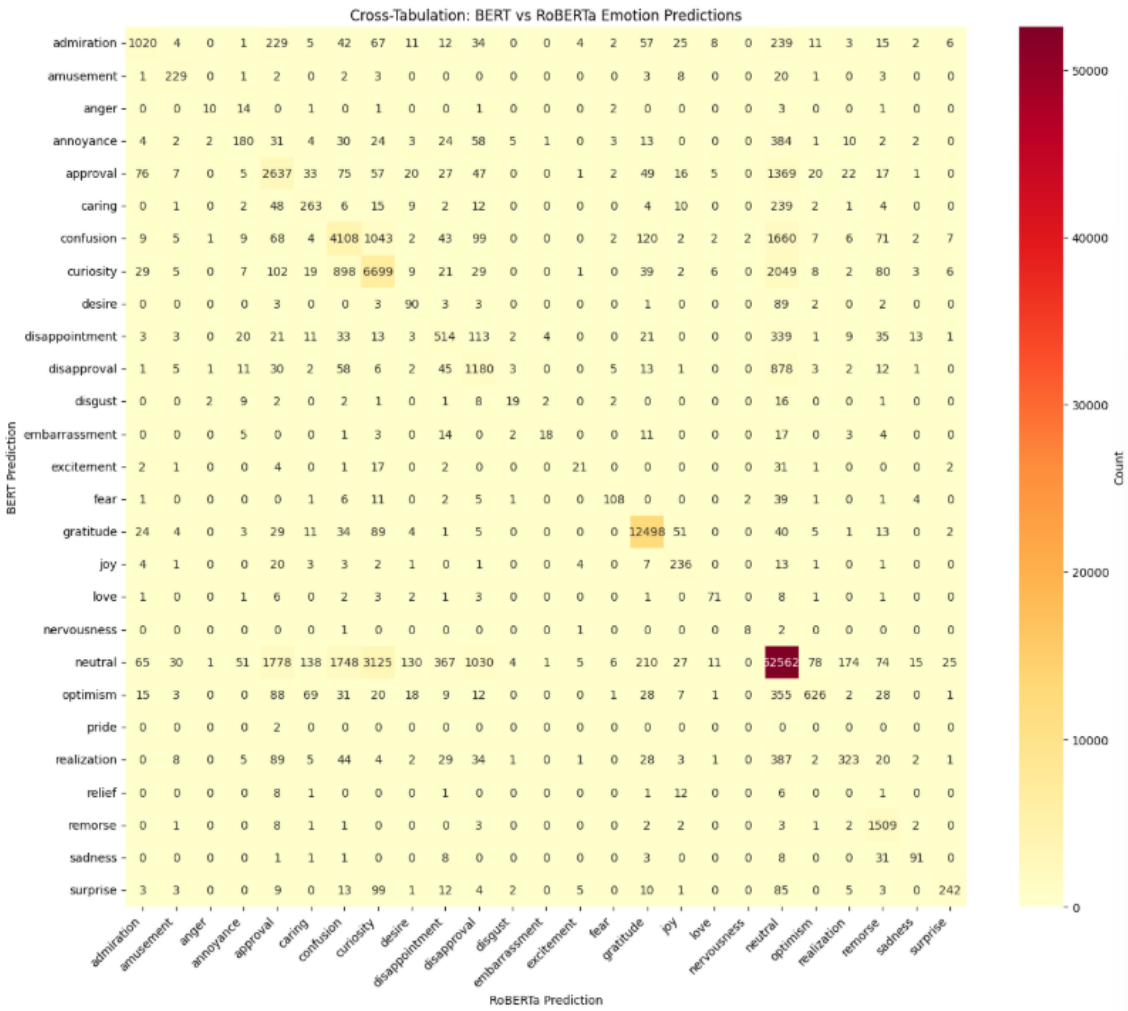

Figure 18: Διασταυρωμένη ταξινόμηση (Cross-Tabulation) μεταξύ BERT και RoBERTa. Οι διαγώνιες τιμές (υψηλότερες) αντιπροσωπεύουν τη συμφωνία μεταξύ των μοντέλων.

Από τον πίνακα διασταυρωμένης ταξινόμησης προκύπτουν τα εξής συμπεράσματα:

- **Υψηλή συμφωνία στο neutral:** Η μεγαλύτερη συμφωνία εντοπίζεται στο συναίσθημα neutral (52.562 σχόλια), το οποίο κυριαρχεί στο dataset.
- **Σύγχυση μεταξύ παρόμοιων συναισθημάτων:** Παρατηρείται σημαντική σύγχυση μεταξύ:
  - curiosity ↔ confusion (6.699 και 4.108 αντίστοιχα)
  - gratitude ↔ approval (μερική επικάλυψη)

  - admiration ↔ approval

- **Σπάνια συναισθήματα:** Τα συναισθήματα pride, relief και nervousness έχουν πολύ χαμηλή συχνότητα, καθιστώντας δύσκολη την αξιόπιστη σύγκριση.

- **Διαγώνια κυριαρχία:** Οι υψηλότερες τιμές εντοπίζονται στη διαγώνιο του πίνακα, επιβεβαιώνοντας τη συνολική συμφωνία (78,4%) μεταξύ των μοντέλων.

5.11 Οπτικοποίηση Συμφωνίας Μοντέλων

Το Σχήμα 19 παρουσιάζει οπτικά τα ποσοστά συμφωνίας και διαφωνίας μεταξύ των δύο μοντέλων, τόσο σε επίπεδο ακριβούς συναισθήματος όσο και σε επίπεδο sentiment.

```
============================================================
       BERT vs RoBERTa: EMOTION ANALYSIS SUMMARY
============================================================

DATASET OVERVIEW
----------------
- Total comments analyzed: 108687
- Unique emotions detected: 25

MODEL AGREEMENT
---------------
- Exact emotion agreement: 78.4%
  → Both models predicted the SAME emotion 78.4% of the time

- Sentiment agreement: 90.4%
  → Both models agreed on positive/negative/neutral 90.4% of the time

CONFIDENCE SCORES
-----------------
- BERT average confidence: 93.8%
- RoBERTa average confidence: 75.3%

INTERPRETATION:
→ BERT is more "confident" but this may indicate overconfidence
→ RoBERTa's lower confidence suggests better calibration
```

Figure 19: Οπτικοποίηση συμφωνίας μεταξύ BERT και RoBERTa. Αριστερά: Συμφωνία σε επίπεδο ακριβούς συναισθήματος (78,4%). Δεξιά: Συμφωνία σε επίπεδο sentiment (90,4%).

Η διαφορά μεταξύ των δύο τύπων συμφωνίας εξηγείται ως εξής:

- **Emotion Agreement (78,4%):** Αυστηρή σύγκριση — και τα δύο μοντέλα πρέπει να προβλέψουν ακριβώς το ίδιο συναίσθημα (π.χ. και τα δύο "joy").

- **Sentiment Agreement (90,4%):** Χαλαρή σύγκριση — τα μοντέλα πρέπει να προβλέψουν την ίδια κατηγορία (positive, negative ή neutral).

- Η υψηλότερη συμφωνία sentiment είναι αναμενόμενη, καθώς πολλά συναισθήματα ανήκουν στην ίδια κατηγορία (π.χ. joy, love, excitement → όλα "positive").

5.12 Συνοπτικός Πίνακας Αποτελεσμάτων

Ο Πίνακας 19 συνοψίζει τα κύρια ευρήματα της συγκριτικής ανάλυσης μεταξύ BERT και RoBERTa.

Table 19: Συνοπτικός πίνακας αποτελεσμάτων ανάλυσης συναισθήματος

Κατηγορία	**Ευρήματα**
Dataset Overview	
Σύνολο σχολίων	108.687
Μοναδικά συναισθήματα	25 (από 28 διαθέσιμα)
Model Agreement	
Emotion Agreement	78,4% — Τα μοντέλα προβλέπουν το ίδιο ακριβές συναίσθημα
Sentiment Agreement	90,4% — Τα μοντέλα συμφωνούν στην κατηγορία (positive/negative/neutral)
Confidence Scores	
BERT μέσο confidence	93,8%
RoBERTa μέσο confidence	75,3%
Interpretation	
BERT	Υψηλότερο confidence, πιθανή υπερβολική εμπιστοσύνη (overconfidence)
RoBERTa	Χαμηλότερο confidence, καλύτερη βαθμονόμηση (calibration)

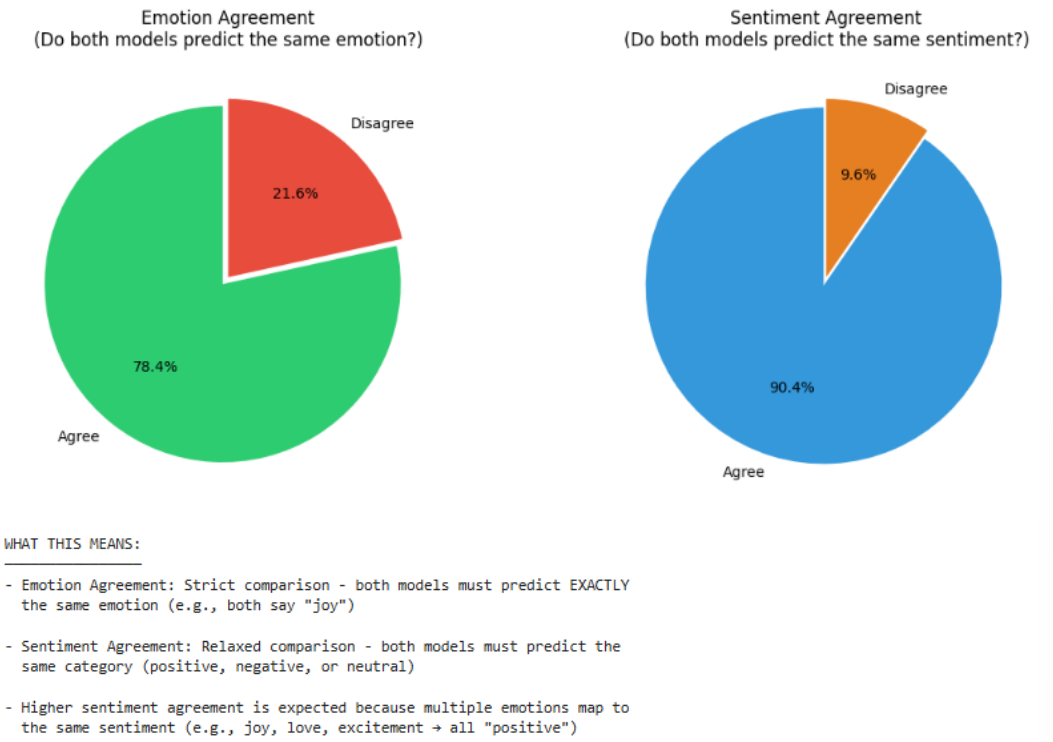

Figure 20: Συνοπτική επισκόπηση αποτελεσμάτων ανάλυσης συναισθήματος BERT vs RoBERTa.

Τα κύρια συμπεράσματα της συγκριτικής ανάλυσης είναι:

1. **Υψηλή συμφωνία:** Τα δύο μοντέλα συμφωνούν στην πλειονότητα των περιπτώσεων (78,4% σε επίπεδο συναισθήματος, 90,4% σε επίπεδο sentiment), υποδεικνύοντας αξιοπιστία στην ανάλυση.

2. **Διαφορετική βαθμονόμηση:** Το BERT παρουσιάζει σημαντικά υψηλότερα confidence scores (93,8% vs 75,3%), γεγονός που υποδεικνύει πιθανή υπερβολική εμπιστοσύνη. Το RoBERTa φαίνεται να έχει καλύτερη βαθμονόμηση μεταξύ confidence και πραγματικής απόδοσης.

3. **Συμπληρωματικότητα:** Οι διαφωνίες μεταξύ των μοντέλων εντοπίζονται κυρίως σε λεπτές διακρίσεις συναισθημάτων, υποδεικνύοντας ότι η χρήση και των δύο μοντέλων μπορεί να παρέχει πληρέστερη εικόνα.

5.13 Στατιστικοί Έλεγχοι

Για την αξιολόγηση της στατιστικής σημαντικότητας των διαφορών μεταξύ των δύο μοντέλων, εφαρμόστηκαν διάφοροι στατιστικοί έλεγχοι.

5.13.1 Έλεγχος McNemar

Ο έλεγχος McNemar χρησιμοποιείται για τη σύγκριση δύο ταξινομητών στα ίδια δεδομένα, εξετάζοντας αν παρουσιάζουν συστηματικά διαφορετική συμπεριφορά. Ο έλεγχος εστιάζει στις περιπτώσεις διαφωνίας μεταξύ των μοντέλων.
Ο στατιστικός τύπος του McNemar's test είναι:

$$\chi^2 = \frac{(b-c)^2}{b+c} \tag{4}$$

όπου b είναι ο αριθμός περιπτώσεων όπου το BERT είναι πιο σίγουρο και c όπου το RoBERTa είναι πιο σίγουρο.
Το Σχήμα 21 παρουσιάζει τα αποτελέσματα του ελέγχου McNemar.

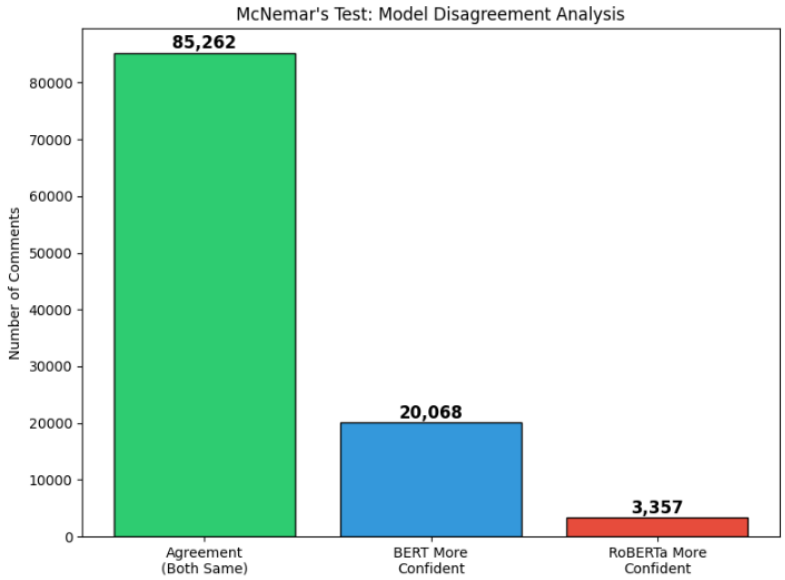


```
McNEMAR'S TEST RESULTS
──────────────────────
- Statistic: 11919.9189
- p-value: 0.0000

WHAT IS McNEMAR'S TEST?
───────────────────────
McNemar's test checks if two models make DIFFERENT types of errors.
It answers: "Do BERT and RoBERTa disagree in a systematic way?"

HOW TO INTERPRET:
─────────────────
- If p-value < 0.05: Models have SIGNIFICANTLY different behavior
- If p-value ≥ 0.05: No significant difference in model behavior

RESULT:
───────


→ p-value = 0.0000 < 0.05
→ The models behave SIGNIFICANTLY differently
→ One model may be better suited for certain types of text
```

Figure 21: Αποτελέσματα ελέγχου McNemar: Ανάλυση διαφωνιών μεταξύ BERT και RoBERTa.

Ο Πίνακας 20 συνοψίζει τα αποτελέσματα του ελέγχου.

Table 20: Αποτελέσματα ελέγχου McNemar

Μετρική	**Τιμή**
Συμφωνία (Both Same)	85.262
BERT More Confident	20.068
RoBERTa More Confident	3.357
McNemar Statistic (χ^2)	11.919,92
p-value	0,0001

Ερμηνεία αποτελεσμάτων:

- Το **p-value** $<$ **0,05** υποδεικνύει ότι τα μοντέλα παρουσιάζουν **στατιστικά σημαντική διαφορά** στη συμπεριφορά τους.
- Όταν τα μοντέλα διαφωνούν, το BERT είναι πιο σίγουρο σε **20.068** περιπτώσεις έναντι **3.357** του RoBERTa (αναλογία 6:1).
- Αυτό επιβεβαιώνει την τάση του BERT για υπερβολική εμπιστοσύνη (overconfidence) στις προβλέψεις του.

5.13.2 Ανάλυση Συσχετίσεων (Pearson Correlation)

Εξετάστηκε η συσχέτιση μεταξύ των confidence scores των μοντέλων και της βαθμολογίας των σχολίων, καθώς και η συσχέτιση μεταξύ των confidence scores των δύο μοντέλων.
Το Σχήμα 22 παρουσιάζει τα αποτελέσματα της ανάλυσης συσχετίσεων.

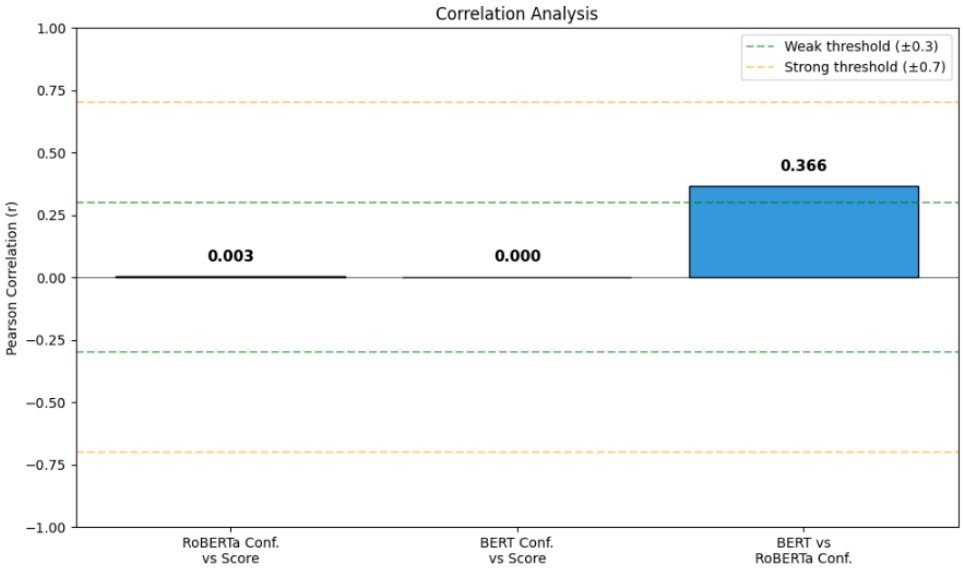


```
CORRELATION RESULTS
------------------------------------------------------------

- RoBERTa Confidence vs Comment Score: r = 0.0030 (p = 0.3245)
- BERT Confidence vs Comment Score:    r = 0.0004 (p = 0.8940)
- BERT vs RoBERTa Confidence:          r = 0.3659 (p = 0.0000)

WHAT IS CORRELATION?
------------------------------------------------------------

Correlation measures how two variables move together:
- r = +1.0: Perfect positive relationship
- r = 0.0:  No relationship
- r = -1.0: Perfect negative relationship

INTERPRETATION GUIDE:
------------------------------------------------------------

- |r| < 0.1:  Negligible correlation
- |r| < 0.3:  Weak correlation
- |r| < 0.5:  Moderate correlation
- |r| < 0.7:  Strong correlation
- |r| ≥ 0.7:  Very strong correlation

WHAT THE RESULTS MEAN:
------------------------------------------------------------

• RoBERTa Confidence vs Score: Negligible positive correlation
• BERT Confidence vs Score: Negligible positive correlation
• BERT vs RoBERTa Confidence: Moderate positive correlation
```

Figure 22: Ανάλυση συσχετίσεων Pearson μεταξύ confidence scores και βαθμολογίας σχολίων.

Ο Πίνακας 21 συνοψίζει τα αποτελέσματα της ανάλυσης συσχετίσεων.

Table 21: Αποτελέσματα ανάλυσης συσχετίσεων Pearson

Συσχέτιση	**r**	**p-value**	**Ερμηνεία**
RoBERTa Conf. vs Score	0,003	0,3245	Αμελητέα (μη σημαντική)
BERT Conf. vs Score	0,000	0,8940	Αμελητέα (μη σημαντική)
BERT vs RoBERTa Conf.	0,366	0,0001	Μέτρια θετική (σημαντική)

Κλίμακα ερμηνείας συσχέτισης:

- $|r| < 0,1$: Αμελητέα συσχέτιση
- $0,1 \leq |r| < 0,3$: Ασθενής συσχέτιση
- $0,3 \leq |r| < 0,5$: Μέτρια συσχέτιση
- $0,5 \leq |r| < 0,7$: Ισχυρή συσχέτιση
- $|r| \geq 0,7$: Πολύ ισχυρή συσχέτιση

Ερμηνεία αποτελεσμάτων:

- **Confidence vs Score 0:** Η εμπιστοσύνη των μοντέλων δεν σχετίζεται με τη δημοτικότητα του σχολίου. Αυτό είναι αναμενόμενο, καθώς η βαθμολογία εξαρτάται από το περιεχόμενο και όχι από τη σαφήνεια του συναισθήματος.
- **BERT vs RoBERTa Conf. = 0,366:** Υπάρχει μέτρια θετική συσχέτιση μεταξύ των confidence scores, υποδεικνύοντας ότι όταν ένα μοντέλο είναι σίγουρο, τείνει να είναι και το άλλο. Ωστόσο, η συσχέτιση δεν είναι ισχυρή, επιβεβαιώνοντας τις διαφορές στη βαθμονόμηση.

5.13.3 Σύγκριση Confidence Scores

Πραγματοποιήθηκε αναλυτική σύγκριση των κατανομών confidence scores μεταξύ των δύο μοντέλων, χρησιμοποιώντας περιγραφικά στατιστικά και t-test για ανεξάρτητα δείγματα.
Το Σχήμα 23 παρουσιάζει τις κατανομές confidence scores.

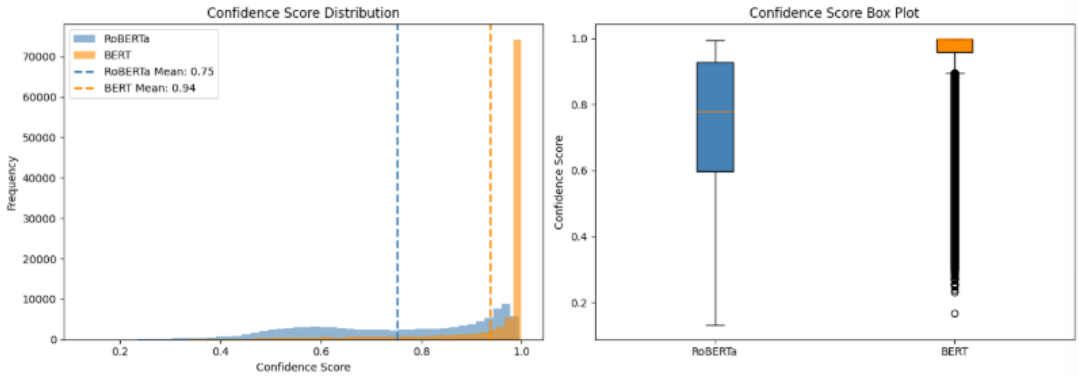


```
CONFIDENCE SCORE COMPARISON
──────────────────────────

                    RoBERTa         BERT
Mean:               0.7528          0.9378
Std Dev:            0.1818          0.1284
Median:             0.7787          0.9988
Min:                0.1312          0.1671
Max:                0.9953          1.0000

T-TEST RESULTS
──────────────

- t-statistic: 274.1203
- p-value: 0.00e+00

WHAT THIS MEANS:
────────────────

- BERT has HIGHER average confidence (93.8% vs 75.3%)
- This does NOT mean BERT is more accurate!
- Higher confidence can indicate "overconfidence" - the model is very
  sure even when it might be wrong
- RoBERTa's lower, more varied confidence suggests it "knows what it
  doesn't know" - this is called better calibration

KEY INSIGHTS:
─────────────

→ A well-calibrated model's confidence should match its accuracy
→ If a model says "90% confident" it should be correct ~90% of the time
→ BERT's consistently high confidence suggests potential overconfidence
```

Figure 23: Σύγκριση κατανομών confidence scores μεταξύ RoBERTa και BERT. Αριστερά: Histogram με μέσους όρους. Δεξιά: Box plot.

Ο Πίνακας 22 παρουσιάζει τα περιγραφικά στατιστικά των confidence scores.

Table 22: Περιγραφικά στατιστικά confidence scores

Στατιστικό	**RoBERTa**	**BERT**
Mean	0,7528	0,9378
Std Dev	0,1818	0,1284
Median	0,7787	0,9988
Min	0,1312	0,1671
Max	0,9953	1,0000

Αποτελέσματα t-test:

- t-statistic: 274,12
- p-value: 0,0001

Το εξαιρετικά χαμηλό p-value επιβεβαιώνει ότι η διαφορά στα confidence scores μεταξύ των δύο μοντέλων είναι **στατιστικά σημαντική**.

Κύρια ευρήματα:

- **BERT:** Μέσο confidence 93,8%, με διάμεσο 99,88%. Το 50% των προβλέψεων έχει confidence ανω του 99,9%, υποδεικνύοντας έντονη υπερβολική εμπιστοσύνη (overconfidence).
- **RoBERTa:** Μέσο confidence 75,3%, με μεγαλύτερη διακύμανση (std = 0,18). Η κατανομή είναι πιο "απλωμένη", υποδεικνύοντας καλύτερη βαθμονόμηση.
- **Ερμηνεία:** Ένα καλά βαθμονομημένο μοντέλο θα πρέπει να έχει confidence που αντιστοιχεί στην πραγματική ακρίβεια. Το BERT φαίνεται να είναι "υπερβολικά σίγουρο" ακόμα και σε αμφίβολες περιπτώσεις, ενώ το RoBERTa παρουσιάζει πιο ρεαλιστικές εκτιμήσεις εμπιστοσύνης.

5.13.4 Cohen's Kappa: Συμφωνία Μεταξύ Μοντέλων

Ο συντελεστής Cohen's Kappa αποτελεί μια ευρέως χρησιμοποιούμενη μετρική για την αξιολόγηση της συμφωνίας μεταξύ δύο ταξινομητών, λαμβάνοντας υπόψη τη συμφωνία που θα προέκυπτε τυχαία. Ο τύπος υπολογισμού είναι:

$$\kappa = \frac{p_o - p_e}{1 - p_e} \tag{5}$$

όπου p_o είναι η παρατηρούμενη συμφωνία και p_e είναι η αναμενόμενη τυχαία συμφωνία. Ο Πίνακας 23 παρουσιάζει την κλίμακα ερμηνείας του Cohen's Kappa.

Table 23: Κλίμακα ερμηνείας Cohen's Kappa

Τιμή κ	**Ερμηνεία**
$\kappa < 0,20$	Ασθενής συμφωνία (Poor agreement)
$0,21 \leq \kappa \leq 0,40$	Μέτρια συμφωνία (Fair agreement)
$0,41 \leq \kappa \leq 0,60$	Μέτρια προς καλή συμφωνία (Moderate agreement)
$0,61 \leq \kappa \leq 0,80$	Ουσιαστική συμφωνία (Substantial agreement)
$\kappa > 0,80$	Σχεδόν τέλεια συμφωνία (Almost perfect agreement)

Αποτέλεσμα:

Table 24: Αποτέλεσμα Cohen's Kappa μεταξύ BERT και RoBERTa

Μετρική	**Τιμή**
Cohen's Kappa (κ)	0,669
Κατηγορία	Ουσιαστική συμφωνία (Substantial agreement)

Ερμηνεία αποτελέσματος:

- Η τιμή $\kappa = 0,669$ εμπίπτει στην κατηγορία **"Substantial agreement"** (ουσιαστική συμφωνία), υποδεικνύοντας ότι τα δύο μοντέλα παρουσιάζουν υψηλό βαθμό συνέπειας στις προβλέψεις τους.
- Η τιμή αυτή είναι σημαντικά υψηλότερη από την τυχαία συμφωνία, επιβεβαιώνοντας ότι και τα δύο μοντέλα αναγνωρίζουν παρόμοια patterns στα δεδομένα.
- Η συμφωνία δεν είναι "σχεδόν τέλεια" ($\kappa > 0,80$), γεγονός που αντικατοπτρίζει τις διαφορές στη βαθμονόμηση και τις λεπτές διακρίσεις συναισθημάτων μεταξύ των μοντέλων.

5.14 Πρόσθετες Οπτικοποιήσεις

Η παρούσα υποενότητα παρουσιάζει πρόσθετες οπτικοποιήσεις για την εμβάθυνση στη σχέση μεταξύ των δύο μοντέλων και την ανάλυση των διαφωνιών τους.

5.14.1 Scatter Plot: Σύγκριση Confidence Scores

Το Σχήμα 24 παρουσιάζει τη σχέση μεταξύ των confidence scores των δύο μοντέλων για κάθε σχόλιο, με χρωματική διάκριση ανάλογα με το αν τα μοντέλα συμφωνούν ή διαφωνούν.

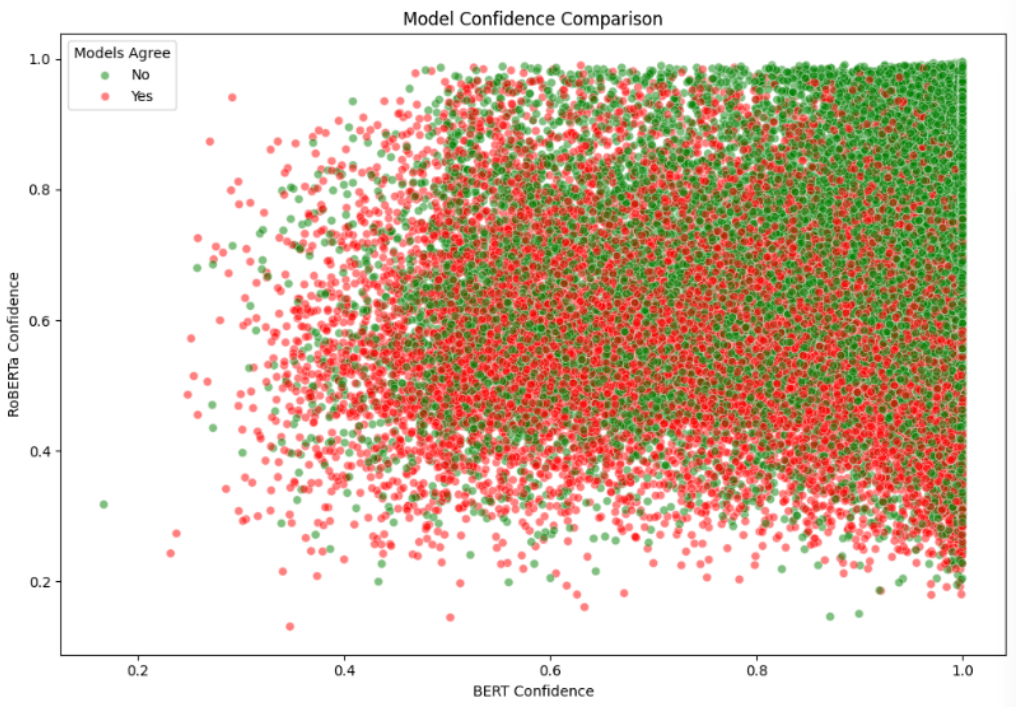

Figure 24: Scatter plot σύγκρισης confidence scores μεταξύ BERT (άξονας x) και RoBERTa (άξονας y). Πράσινα σημεία: διαφωνία, Κόκκινα σημεία: συμφωνία.

Από το scatter plot προκύπτουν τα εξής συμπεράσματα:

- **Συγκέντρωση BERT στο 1.0:** Τα σημεία συγκεντρώνονται στη δεξιά πλευρά του γραφήματος (BERT confidence κοντά στο 1.0), επιβεβαιώνοντας την υπερβολική εμπιστοσύνη του BERT.
- **Διασπορά RoBERTa:** Το RoBERTa παρουσιάζει μεγαλύτερη διασπορά στα confidence scores (από 0.2 έως 1.0), υποδεικνύοντας καλύτερη βαθμονόμηση.
- **Διαφωνίες σε χαμηλά confidence:** Οι διαφωνίες (πράσινα σημεία) τείνουν να εμφανίζονται συχνότερα όταν το RoBERTa έχει χαμηλότερο confidence, υποδεικνύοντας αμφιβολία του μοντέλου.

- **Συμφωνία σε υψηλά confidence:** Όταν και τα δύο μοντέλα έχουν υψηλό confidence (πάνω δεξιά γωνία), τείνουν να συμφωνούν.

5.14.2 Ανάλυση Διαφωνιών: Ποια Συναισθήματα Προκαλούν Σύγχυση

Εξετάστηκε σε ποια συναισθήματα εντοπίζονται οι περισσότερες διαφωνίες μεταξύ των μοντέλων. Το Σχήμα 25 παρουσιάζει τα 10 συναισθήματα με τις περισσότερες διαφωνίες.

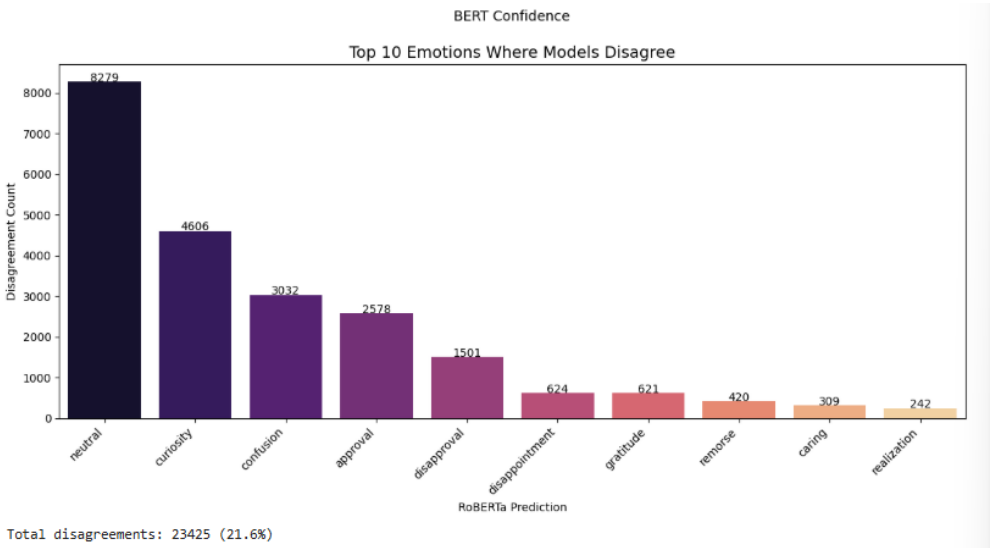

Figure 25: Τα 10 συναισθήματα (κατά RoBERTa) με τις περισσότερες διαφωνίες μεταξύ των μοντέλων. Συνολικές διαφωνίες: 23.425 (21,6%).

Ο Πίνακας 25 συνοψίζει τα συναισθήματα με τις περισσότερες διαφωνίες.

Table 25: Top 10 συναισθήματα με τις περισσότερες διαφωνίες

Συναίσθημα (RoBERTa)	Διαφωνίες	Ποσοστό Διαφωνιών
neutral	8.279	35,4%
curiosity	4.606	19,7%
confusion	3.032	12,9%
approval	2.578	11,0%
disapproval	1.501	6,4%
disappointment	624	2,7%
gratitude	621	2,7%
remorse	420	1,8%
caring	309	1,3%
realization	242	1,0%

Κύρια ευρήματα:

- Το **neutral** παρουσιάζει τις περισσότερες διαφωνίες (8.279), καθώς αποτελεί το συχνότερο συναίσθημα και συχνά συγχέεται με ουδέτερα-αμφίσημα συναισθήματα.
- Τα **curiosity** και **confusion** (4.606 και 3.032 διαφωνίες αντίστοιχα) είναι σημασιολογικά κοντά, εξηγώντας τη συχνή σύγχυση.
- Το **approval** (2.578 διαφωνίες) συχνά συγχέεται με admiration ή gratitude.

5.15 Γεωγραφική Ανάλυση Συναισθημάτων

Εξετάστηκε η κατανομή των συναισθημάτων σε σχέση με τη γεωγραφική τοποθεσία των χρηστών.

5.15.1 Κατανομή Τοποθεσιών Χρηστών

Το Σχήμα 26 παρουσιάζει τις 10 συχνότερες τοποθεσίες χρηστών βάσει αριθμού σχολίων.

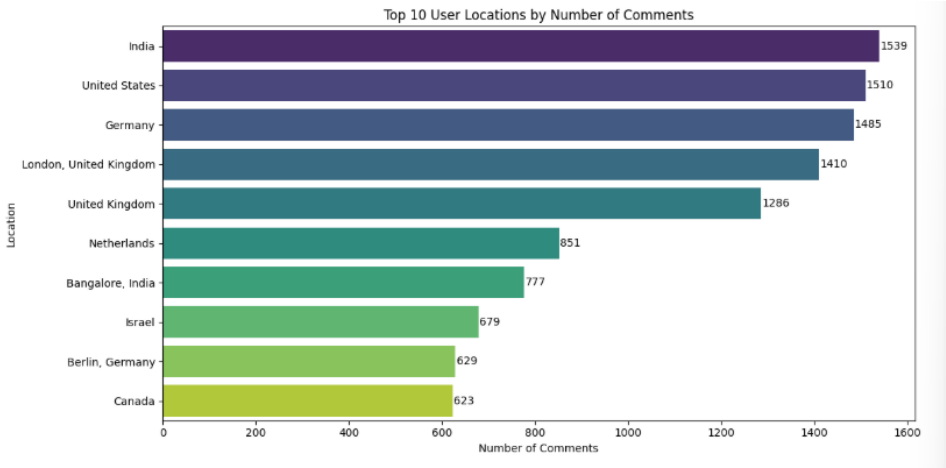

Figure 26: Top 10 τοποθεσίες χρηστών βάσει αριθμού σχολίων.

Ο Πίνακας 26 συνοψίζει τις κορυφαίες τοποθεσίες.

Table 26: Top 10 τοποθεσίες χρηστών

Τοποθεσία	**Αριθμός Σχολίων**
India	1.539
United States	1.510
Germany	1.485
London, United Kingdom	1.410
United Kingdom	1.286
Netherlands	851
Bangalore, India	777
Israel	679
Berlin, Germany	629
Canada	623

Παρατηρείται ότι η Ινδία, οι ΗΠΑ, η Γερμανία και το Ηνωμένο Βασίλειο αποτελούν τις κυρίαρχες τοποθεσίες, αντικατοπτρίζοντας τη διεθνή σύνθεση της κοινότητας Stack Overflow.

5.15.2 Heatmap: Συναισθήματα ανά Τοποθεσία

Το Σχήμα 27 παρουσιάζει heatmaps με την κατανομή των 10 συχνότερων συναισθημάτων ανά τοποθεσία για κάθε μοντέλο.

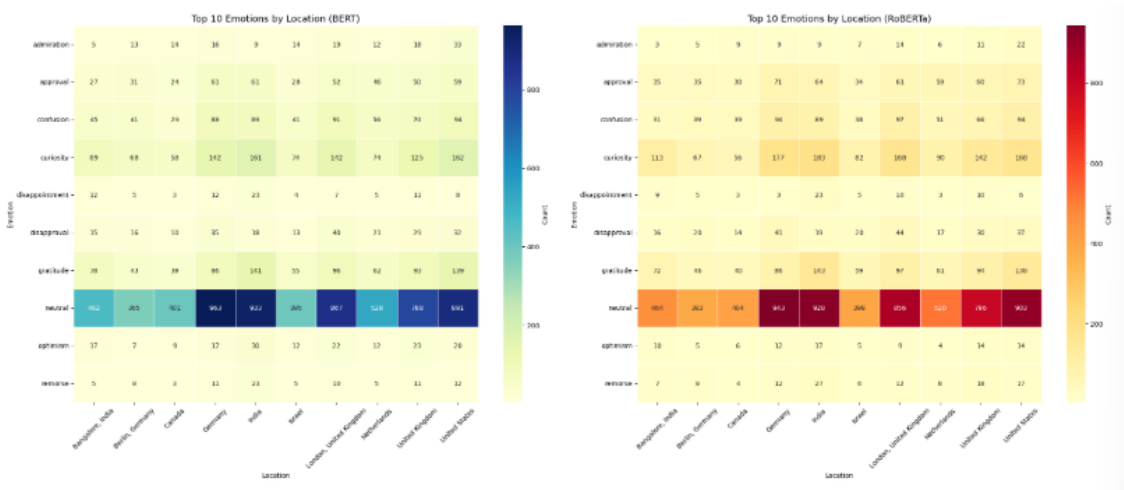

Figure 27: Heatmaps: Κατανομή των 10 συχνότερων συναισθημάτων ανά τοποθεσία για BERT (αριστερά) και RoBERTa (δεξιά).

Κύρια ευρήματα από τη γεωγραφική ανάλυση:

- **Κυριαρχία neutral:** Σε όλες τις τοποθεσίες, το neutral είναι το συχνότερο συναίσθημα (σκούρα κελιά), υποδεικνύοντας τον τεχνικό χαρακτήρα της πλατφόρμας.
- **Ομοιομορφία μεταξύ τοποθεσιών:** Δεν παρατηρούνται σημαντικές διαφορές στην κατανομή συναισθημάτων μεταξύ διαφορετικών χωρών, υποδεικνύοντας ότι η γεωγραφική τοποθεσία δεν επηρεάζει σημαντικά το συναισθηματικό τόνο των σχολίων.
- **Curiosity και Gratitude:** Τα συναισθήματα curiosity και gratitude είναι σταθερά υψηλά σε όλες τις τοποθεσίες, αντικατοπτρίζοντας τη φύση της πλατφόρμας (ερωτήσεις και ευχαριστίες για απαντήσεις).
- **Συνέπεια μεταξύ μοντέλων:** Τα δύο μοντέλα παρουσιάζουν παρόμοια patterns στη γεωγραφική κατανομή συναισθημάτων, επιβεβαιώνοντας την αξιοπιστία της ανάλυσης.

5.16 Ανάλυση Ψήφων ανά Συναίσθημα

Εξετάστηκε η σχέση μεταξύ του αναγνωρισμένου συναισθήματος και των ψήφων (upvotes/-downvotes) που λαμβάνουν οι χρήστες που δημοσίευσαν τα σχόλια.

5.16.1 Upvotes ανά Συναίσθημα

Το Σχήμα 28 παρουσιάζει την κατανομή των upvotes για τα 10 συχνότερα συναισθήματα, για κάθε μοντέλο.

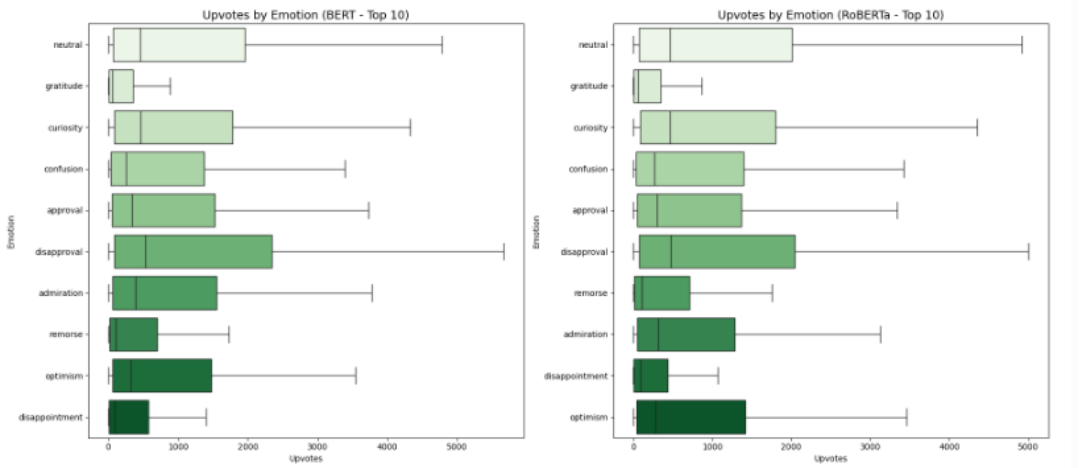

Figure 28: Κατανομή Upvotes ανά συναίσθημα για BERT (αριστερά) και RoBERTa (δεξιά). Τα box plots δείχνουν τη διάμεσο, τα τεταρτημόρια και τις ακραίες τιμές.

Κύρια ευρήματα (Upvotes):

- Το **neutral** παρουσιάζει τη μεγαλύτερη διακύμανση στα upvotes, με ακραίες τιμές που φτάνουν τα 5.000+.
- Τα συναισθήματα **disapproval** και **curiosity** σχετίζονται με υψηλότερα upvotes, πιθανώς επειδή αντικατοπτρίζουν κριτική σκέψη ή ενδιαφέρουσες ερωτήσεις.
- Το **gratitude** έχει χαμηλά upvotes, καθώς τα ευχαριστήρια σχόλια σπάνια λαμβάνουν ψήφους.

5.16.2 Downvotes ανά Συναίσθημα

Το Σχήμα 29 παρουσιάζει την κατανομή των downvotes για τα 10 συχνότερα συναισθήματα.

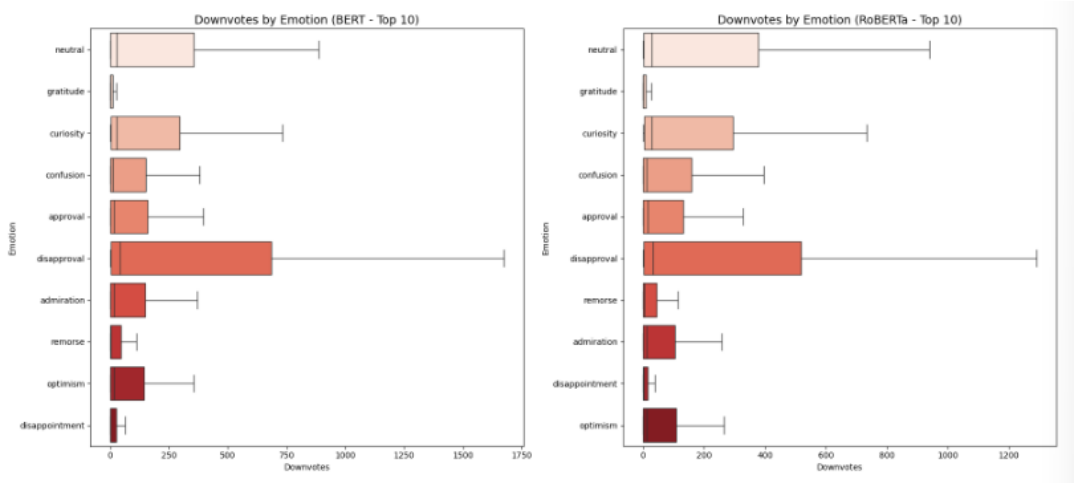

Figure 29: Κατανομή Downvotes ανά συναίσθημα για BERT (αριστερά) και RoBERTa (δεξιά).

Κύρια ευρήματα (Downvotes):

- Το **disapproval** σχετίζεται με τα υψηλότερα downvotes και στα δύο μοντέλα, υποδεικνύοντας ότι οι χρήστες που εκφράζουν αποδοκιμασία τείνουν να λαμβάνουν και οι ίδιοι αρνητικές ψήφους.
- Το **neutral** παρουσιάζει επίσης υψηλή διακύμανση στα downvotes.
- Τα θετικά συναισθήματα (**gratitude**, **admiration**) έχουν χαμηλά downvotes.

5.17 Ανάλυση Συναισθημάτων ανά Ομάδα Βαθμολογίας

Για την καλύτερη κατανόηση της σχέσης μεταξύ συναισθημάτων και δημοτικότητας, δημιουργήθηκαν ομάδες βαθμολογίας (score groups) τόσο για τα σχόλια όσο και για τις δημοσιεύσεις.

5.17.1 Δημιουργία Ομάδων Βαθμολογίας

Ο Πίνακας 27 παρουσιάζει την κατανομή των σχολίων και δημοσιεύσεων στις διάφορες ομάδες βαθμολογίας.

Table 27: Κατανομή βαθμολογιών σχολίων και δημοσιεύσεων

Ομάδα Βαθμολογίας	**Comment Score**	**Post Score**
Very Low / Negative	97.320	16.237
Low	8.889	30.342
Medium	1.541	5.213
High	608	2.020
Very High	329	876
Σύνολο	108.687	54.688

Παρατηρείται ότι η πλειονότητα των σχολίων (89,5%) έχει πολύ χαμηλή βαθμολογία (Very Low), γεγονός που αντικατοπτρίζει τη φύση της πλατφόρμας όπου τα περισσότερα σχόλια δεν λαμβάνουν ψήφους.

Table 28: Περιγραφικά στατιστικά βαθμολογίας σχολίων

Στατιστικό	**Τιμή**
Count	108.687
Mean	0
Std	3
Min	0
25%	0
50% (Median)	0
75%	0
Max	484

5.17.2 Συναισθήματα ανά Βαθμολογία Σχολίου

Το Σχήμα 30 παρουσιάζει την κατανομή των 5 συχνότερων συναισθημάτων ανά ομάδα βαθμολογίας σχολίου.

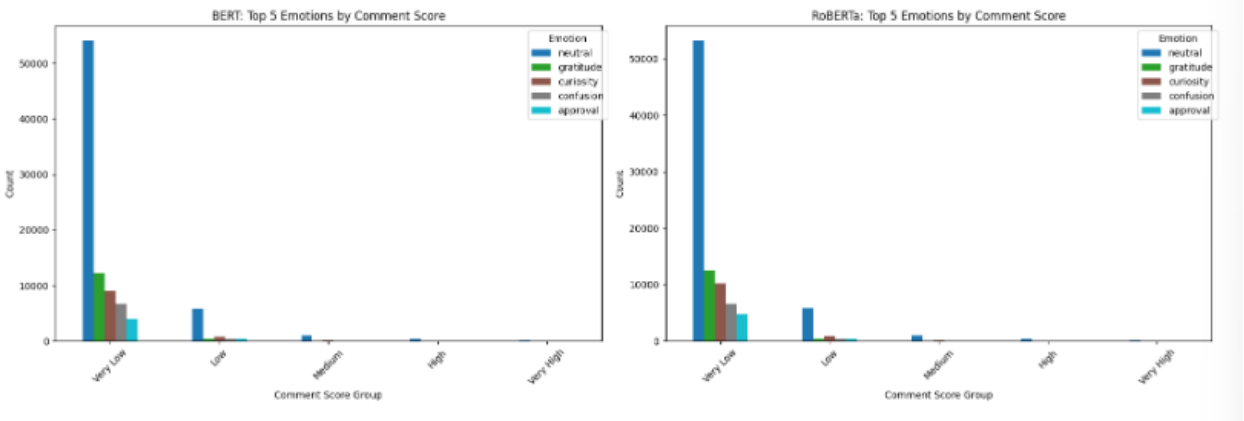

Figure 30: Top 5 συναισθήματα ανά ομάδα βαθμολογίας σχολίου για BERT (αριστερά) και RoBERTa (δεξιά).

Κύρια ευρήματα:

- Το **neutral** κυριαρχεί σε όλες τις ομάδες βαθμολογίας, ιδιαίτερα στην κατηγορία "Very Low".
- Το **gratitude** είναι πιο συχνό στα σχόλια με χαμηλή βαθμολογία, καθώς τα ευχαριστήρια σχόλια σπάνια λαμβάνουν upvotes.
- Στις υψηλότερες βαθμολογίες (High, Very High), παρατηρείται σχετική αύξηση των συναισθημάτων **curiosity** και **approval**.

5.17.3 Συναισθήματα ανά Βαθμολογία Δημοσίευσης

Το Σχήμα 31 παρουσιάζει την κατανομή των 5 συχνότερων συναισθημάτων ανά ομάδα βαθμολογίας της δημοσίευσης στην οποία ανήκει το σχόλιο.

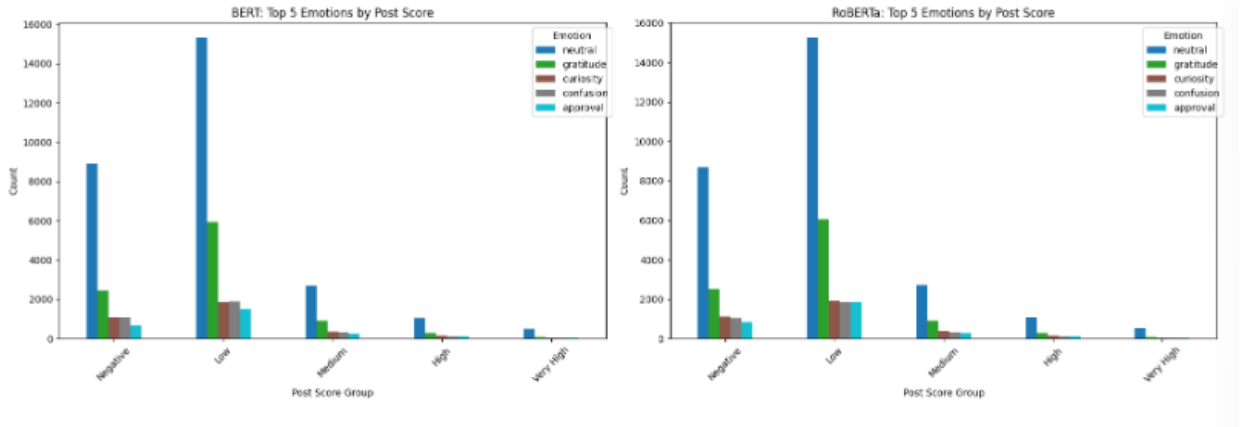

Figure 31: Top 5 συναισθήματα ανά ομάδα βαθμολογίας δημοσίευσης για BERT (αριστερά) και RoBERTa (δεξιά).

Κύρια ευρήματα:

- Η κατηγορία "Low" (χαμηλή βαθμολογία δημοσίευσης) περιέχει τα περισσότερα σχόλια, με κυριαρχία του **neutral**.
- Σε δημοσιεύσεις με **αρνητική βαθμολογία** (Negative), παρατηρείται υψηλότερο ποσοστό **curiosity** και **confusion**, πιθανώς επειδή οι χρήστες ζητούν διευκρινίσεις.
- Το **gratitude** είναι πιο συχνό σε δημοσιεύσεις με θετική βαθμολογία, υποδεικνύοντας ότι οι χρήστες ευχαριστούν για χρήσιμες απαντήσεις.
- Τα patterns είναι παρόμοια μεταξύ BERT και RoBERTa, επιβεβαιώνοντας τη συνέπεια της ανάλυσης.

5.18 Συγκεντρωτικά Αποτελέσματα Σύγκρισης Μοντέλων

Η παρούσα υποενότητα συνοψίζει τα τελικά αποτελέσματα της συγκριτικής ανάλυσης μεταξύ των μοντέλων BERT και RoBERTa.

5.18.1 Τελικός Πίνακας Σύγκρισης Μοντέλων

Ο Πίνακας 29 παρουσιάζει τη συνολική σύγκριση των δύο μοντέλων σε όλες τις βασικές μετρικές.

Table 29: Τελική σύγκριση μοντέλων BERT και RoBERTa

Μετρική	**RoBERTa**	**BERT**
Total Comments Analyzed	108.687	108.687
Emotion Agreement Rate	78,4%	78,4%
Sentiment Agreement Rate	90,4%	90,4%
Average Confidence	75,3%	93,8%
Confidence Std Dev	0,1818	0,1284
Most Common Emotion	neutral	neutral
Most Common Sentiment	neutral	neutral

Συμπεράσματα από τη σύγκριση:

1. **Υψηλή συμφωνία sentiment:** Και τα δύο μοντέλα παρουσιάζουν υψηλή συμφωνία σε επίπεδο sentiment (90,4%), υποδεικνύοντας ότι είναι αξιόπιστα για γενική ταξινόμηση συναισθήματος.

2. **Διαφορά στο confidence:** Το BERT παρουσιάζει υψηλότερα confidence scores (93,8% vs 75,3%), αλλά αυτό μπορεί να υποδεικνύει υπερβολική εμπιστοσύνη (overconfidence) παρά καλύτερη απόδοση.

3. **Καλύτερη βαθμονόμηση RoBERTa:** Η μεγαλύτερη διασπορά των confidence scores του RoBERTa (std = 0,1818) υποδεικνύει καλύτερη βαθμονόμηση, δηλαδή το confidence αντικατοπτρίζει καλύτερα την πραγματική βεβαιότητα.

4. **Επιλογή μοντέλου:** Η επιλογή μεταξύ των μοντέλων εξαρτάται από τις ανάγκες της εφαρμογής — υψηλότερο confidence (BERT) ή καλύτερη βαθμονόμηση (RoBERTa).

5.18.2 Insights Ανάλυσης Συναισθημάτων

Η ανάλυση αποκάλυψε ενδιαφέροντα patterns σχετικά με τη σχέση συναισθημάτων και δραστηριότητας χρηστών.

Συναισθήματα με Υψηλότερα Upvotes Ο Πίνακας 30 παρουσιάζει τα συναισθήματα που σχετίζονται με τα υψηλότερα μέσα upvotes χρηστών.

Table 30: Συναισθήματα με υψηλότερα μέσα upvotes ανά μοντέλο

BERT		RoBERTa	
Emotion	**Avg Upvotes**	**Emotion**	**Avg Upvotes**
relief	3.100,3	love	2.370,5
excitement	2.886,7	fear	2.238,5
fear	2.199,6	embarrassment	2.210,8
love	2.135,7	neutral	2.018,6
caring	2.133,1	caring	2.013,4

Συναισθήματα με Υψηλότερα Downvotes Ο Πίνακας 31 παρουσιάζει τα συναισθήματα που σχετίζονται με τα υψηλότερα μέσα downvotes χρηστών.

Table 31: Συναισθήματα με υψηλότερα μέσα downvotes ανά μοντέλο

BERT		RoBERTa	
Emotion	**Avg Downvotes**	**Emotion**	**Avg Downvotes**
relief	3.982,1	embarrassment	2.758,2
anger	2.934,1	disapproval	2.651,3
disapproval	2.913,6	fear	2.298,9
caring	2.636,3	joy	2.196,6
annoyance	2.566,9	amusement	2.159,1

Κυρίαρχο Συναίσθημα ανά Τοποθεσία Ο Πίνακας 32 παρουσιάζει το συχνότερο συναίσθημα ανά γεωγραφική τοποθεσία.

Table 32: Κυρίαρχο συναίσθημα ανά τοποθεσία

Τοποθεσία	**BERT**	**RoBERTa**
India	neutral	neutral
United States	neutral	neutral
Germany	neutral	neutral
London, United Kingdom	neutral	neutral
United Kingdom	neutral	neutral

Κύρια ευρήματα από τα insights:

- **Υψηλά upvotes σε έντονα συναισθήματα:** Τα συναισθήματα relief, excitement, love και fear σχετίζονται με χρήστες που έχουν υψηλά upvotes, υποδεικνύοντας ότι η συναισθηματική έκφραση μπορεί να συνδέεται με την αναγνώριση από την κοινότητα.
- **Αρνητικά συναισθήματα και downvotes:** Τα συναισθήματα anger, disapproval και annoyance σχετίζονται με υψηλότερα downvotes, υποδεικνύοντας ότι η αρνητική έκφραση μπορεί να οδηγεί σε αρνητική ανταπόκριση από την κοινότητα.
- **Ομοιομορφία μεταξύ τοποθεσιών:** Το neutral είναι το κυρίαρχο συναίσθημα σε όλες τις τοποθεσίες και για τα δύο μοντέλα, επιβεβαιώνοντας τον τεχνικό και ουδέτερο χαρακτήρα της πλατφόρμας Stack Overflow ανεξαρτήτως γεωγραφικής περιοχής.
- **Διαφορές μεταξύ μοντέλων:** Παρατηρούνται κάποιες διαφορές στα patterns upvotes/downvotes μεταξύ των μοντέλων, αλλά τα γενικά συμπεράσματα παραμένουν σταθερά.

6 Συμπεράσματα

Η παρούσα ενότητα συνοψίζει τα κύρια συμπεράσματα της έρευνας, απαντά στα ερευνητικά ερωτήματα που τέθηκαν και παρουσιάζει τη συνεισφορά της εργασίας στο επιστημονικό πεδίο.

6.1 Κύρια Συμπεράσματα

Η συγκριτική ανάλυση των μοντέλων BERT και RoBERTa σε 108.687 σχόλια του Stack Overflow οδήγησε στα ακόλουθα κύρια συμπεράσματα:

1. **Αποτελεσματικότητα μοντέλων Transformer:** Τα προεκπαιδευμένα μοντέλα BERT και RoBERTa, λεπτο-ρυθμισμένα στο GoEmotions dataset, αποδείχθηκαν αποτελεσματικά στην ανάλυση συναισθήματος τεχνικών κειμένων, παρά το γεγονός ότι εκπαιδεύτηκαν σε δεδομένα κοινωνικών δικτύων (Reddit).

2. **Υψηλή συμφωνία μεταξύ μοντέλων:** Τα δύο μοντέλα παρουσιάζουν ουσιαστική συμφωνία (Cohen's Kappa = 0,669) με ποσοστό συμφωνίας 78,4% σε επίπεδο συναισθήματος και 90,4% σε επίπεδο sentiment, υποδεικνύοντας αξιοπιστία στην ταξινόμηση.

3. **Διαφορετικά χαρακτηριστικά βαθμονόμησης:** Το BERT παρουσιάζει υπερβολική εμπιστοσύνη (overconfidence) με μέσο confidence score 93,8%, ενώ το RoBERTa εμφανίζει καλύτερη βαθμονόμηση με 75,3%, καθιστώντας τις εκτιμήσεις του πιο ρεαλιστικές.

4. **Χαρακτηριστικά τεχνικών κοινοτήτων:** Η ανάλυση αποκάλυψε ότι το 74% των σχολίων του Stack Overflow είναι συναισθηματικά ουδέτερα, με το 20% να εκφράζει θετικά συναισθήματα (κυρίως ευγνωμοσύνη) και μόλις 6% αρνητικά.

5. **Στατιστικά σημαντικές διαφορές:** Ο έλεγχος McNemar επιβεβαίωσε ότι τα μοντέλα παρουσιάζουν στατιστικά σημαντική διαφορά στη συμπεριφορά τους (p ¡ 0,0001), με το BERT να είναι πιο "σίγουρο" σε αναλογία 6:1 σε σχέση με το RoBERTa.

6. **Ανεξαρτησία από γεωγραφική τοποθεσία:** Η κατανομή συναισθημάτων παραμένει σταθερή ανεξαρτήτως της γεωγραφικής τοποθεσίας των χρηστών, υποδεικνύοντας ομοιογένεια στην τεχνική κοινότητα.

6.2 Απάντηση στα Ερευνητικά Ερωτήματα

Ο Πίνακας 33 παρουσιάζει τις απαντήσεις στα ερευνητικά ερωτήματα που τέθηκαν στην αρχή της εργασίας.

Table 33: Απαντήσεις στα ερευνητικά ερωτήματα

Ερευνητικό Ερώτημα	**Απάντηση**
ΕΕ1: Σε ποιο βαθμό συμφωνούν τα μοντέλα BERT και RoBERTa στην ανάλυση συναισθήματος;	Τα μοντέλα συμφωνούν στο 78,4% σε επίπεδο ακριβούς συναισθήματος και στο 90,4% σε επίπεδο sentiment, με Cohen's Kappa = 0,669 (ουσιαστική συμφωνία).
ΕΕ2: Ποιες είναι οι διαφορές στη βαθμονόμηση (calibration) μεταξύ των δύο μοντέλων;	Το BERT παρουσιάζει υπερβολική εμπιστοσύνη (μέσο confidence 93,8%, διάμεσος 99,9%), ενώ το RoBERTa έχει καλύτερη βαθμονόμηση (μέσο confidence 75,3%) με πιο ρεαλιστική διασπορά τιμών.
ΕΕ3: Ποια είναι τα κυρίαρχα συναισθήματα στην τεχνική κοινότητα του Stack Overflow;	Neutral (74%), Gratitude (12%), Curiosity (10%), Confusion (7%), Approval (5%). Η κοινότητα χαρακτηρίζεται από ουδέτερο τόνο με σημαντική παρουσία θετικών συναισθημάτων.
ΕΕ4: Υπάρχει συσχέτιση μεταξύ συναισθήματος και δημοτικότητας σχολίων;	Η συσχέτιση μεταξύ confidence scores και βαθμολογίας σχολίων είναι αμελητέα ($r \approx 0$), υποδεικνύοντας ότι η δημοτικότητα εξαρτάται από το περιεχόμενο και όχι από τη σαφήνεια του συναισθήματος.
ΕΕ5: Σε ποια συναισθήματα παρατηρούνται οι περισσότερες διαφωνίες μεταξύ των μοντέλων;	Οι κύριες διαφωνίες εντοπίζονται στα: neutral (35,4%), curiosity (19,7%), confusion (12,9%) και approval (11%), δηλαδή σε σημασιολογικά κοντινά συναισθήματα.

6.3 Συνεισφορά της Εργασίας

Η παρούσα πτυχιακή εργασία συνεισφέρει στο επιστημονικό πεδίο της ανάλυσης συναισθήματος στους ακόλουθους τομείς:

6.3.1 Θεωρητική Συνεισφορά

- **Συγκριτική ανάλυση μοντέλων:** Παρέχεται εκτενής συγκριτική αξιολόγηση των μοντέλων BERT και RoBERTa, εξετάζοντας την ακρίβεια ταξινόμησης, τη βαθμονόμηση και τη συμφωνία.

- **Στατιστική επικύρωση:** Εφαρμόστηκαν αυστηροί στατιστικοί έλεγχοι (Cohen's Kappa, McNemar, Pearson, t-test) για την τεκμηρίωση των ευρημάτων.
- **Χαρακτηρισμός τεχνικών κοινοτήτων:** Συνεισφέρει στην κατανόηση του συναισθηματικού τόνου σε τεχνικές διαδικτυακές κοινότητες.

6.3.2 Πρακτική Συνεισφορά

- **Ανάλυση πραγματικών δεδομένων:** Βασίζεται σε 108.687 σχόλια από το Stack Overflow, προσφέροντας insights για τη συναισθηματική δυναμική τεχνικών κοινοτήτων.
- **Πολυδιάστατη ανάλυση:** Διερευνήθηκε η σχέση μεταξύ συναισθημάτων και μετρικών αλληλεπίδρασης (upvotes, downvotes, reputation) καθώς και γεωγραφικών παραγόντων.
- **Αναπαραγώγιμη μεθοδολογία:** Παρέχεται πλήρης τεκμηρίωση της μεθοδολογίας και του κώδικα Python.

6.3.3 Στατιστική Συνεισφορά

- **Πολυδιάστατη στατιστική ανάλυση:** Εφαρμόζει πολλαπλούς στατιστικούς ελέγχους (Cohen's Kappa, McNemar, Pearson, t-test) για την ολοκληρωμένη αξιολόγηση.
- **Μεγάλο δείγμα:** Η ανάλυση βασίζεται σε 108.687 σχόλια, παρέχοντας στατιστικά ισχυρά συμπεράσματα.

6.4 Προτάσεις για Πρακτική Εφαρμογή

Βάσει των ευρημάτων της έρευνας, προτείνονται οι ακόλουθες οδηγίες για πρακτική εφαρμογή:

Table 34: Προτάσεις επιλογής μοντέλου ανά περίπτωση χρήσης

Περίπτωση Χρήσης	**Προτεινόμενο Μοντέλο**	**Αιτιολόγηση**
Γενική ταξινόμηση sentiment	BERT ή RoBERTa	Υψηλή συμφωνία (90,4%) καθιστά και τα δύο κατάλληλα
Εφαρμογές με ανάγκη για αξιόπιστες εκτιμήσεις βεβαιότητας	RoBERTa	Καλύτερη βαθμονόμηση confidence scores
Εφαρμογές με ανάγκη για υψηλή βεβαιότητα	BERT	Υψηλότερα confidence scores (με επιφύλαξη για overconfidence)
Λεπτομερής ανάλυση συναισθημάτων	Συνδυασμός και των δύο	Οι διαφωνίες μπορούν να αποκαλύψουν αμφίσημα κείμενα

6.5 Περιορισμοί της Έρευνας

Η παρούσα έρευνα υπόκειται στους ακόλουθους περιορισμούς:

1. **Απουσία ground truth:** Δεν υπάρχουν χειροκίνητα επισημασμένα δεδομένα για τα σχόλια του Stack Overflow, καθιστώντας αδύνατη την αξιολόγηση της απόλυτης ακρίβειας των μοντέλων.

2. **Domain mismatch:** Τα μοντέλα εκπαιδεύτηκαν στο GoEmotions (Reddit), το οποίο διαφέρει από το τεχνικό ύφος του Stack Overflow.

3. **Γλωσσικός περιορισμός:** Η ανάλυση περιορίστηκε στην αγγλική γλώσσα.

4. **Τυχαία δειγματοληψία:** Η δειγματοληψία 5% μπορεί να μην είναι πλήρως αντιπροσωπευτική.

5. **Χρονική στιγμή:** Τα δεδομένα αντιπροσωπεύουν μια χρονική στιγμή και δεν καλύπτουν χρονικές τάσεις.

6.6 Τελική Σύνοψη

Η παρούσα πτυχιακή εργασία πραγματοποίησε μια ολοκληρωμένη συγκριτική ανάλυση των μοντέλων BERT και RoBERTa για την ανάλυση συναισθήματος σε τεχνικές διαδικτυακές κοινότητες. Τα αποτελέσματα επιβεβαιώνουν την αποτελεσματικότητα των μοντέλων Transformer, αναδεικνύουν τη σημασία της βαθμονόμησης στην αξιολόγηση μοντέλων, και παρέχουν πρακτικές κατευθύνσεις για την επιλογή μοντέλου ανάλογα με τις απαιτήσεις της εφαρμογής. Η υψηλή συμφωνία μεταξύ των μοντέλων (90,4% σε επίπεδο sentiment) υποδεικνύει ότι και τα δύο αποτελούν αξιόπιστες επιλογές για ανάλυση συναισθήματος, με το RoBERTa να προσφέρει καλύτερη βαθμονόμηση και το BERT υψηλότερα confidence scores. Η έρευνα συνεισφέρει τόσο θεωρητικά όσο και πρακτικά στο πεδίο της ανάλυσης συναισθήματος, παρέχοντας ένα ολοκληρωμένο μεθοδολογικό πλαίσιο για μελλοντικές εργασίες.

7 Προτάσεις για Μελλοντικές Βελτιώσεις

Η παρούσα ενότητα παρουσιάζει προτάσεις για μελλοντική έρευνα και βελτιώσεις, βασισμένες στα ευρήματα και τους περιορισμούς της παρούσας εργασίας.

7.1 Εμπλουτισμός Δεδομένων

7.1.1 Δημιουργία Ground Truth Dataset

Η σημαντικότερη μελλοντική βελτίωση αφορά τη δημιουργία ενός χειροκίνητα επισημασμένου dataset:

- **Manual annotation:** Επισήμανση τουλάχιστον 5.000-10.000 σχολίων από ανθρώπους αξιολογητές για τη δημιουργία gold standard.
- **Inter-annotator agreement:** Χρήση πολλαπλών αξιολογητών (3) για τον υπολογισμό της συμφωνίας μεταξύ τους και τη διασφάλιση της ποιότητας.
- **Domain-specific guidelines:** Ανάπτυξη οδηγιών επισήμανσης ειδικά για τεχνικά κείμενα, λαμβάνοντας υπόψη τις ιδιαιτερότητες του Stack Overflow.

7.1.2 Επέκταση σε Πολλαπλές Πλατφόρμες

- **Άλλες τεχνικές κοινότητες:** Επέκταση της ανάλυσης σε GitHub Issues, GitLab, Reddit (r/programming, r/learnprogramming).

- **Συγκριτική ανάλυση πλατφορμών:** Σύγκριση του συναισθηματικού τόνου μεταξύ διαφορετικών τεχνικών κοινοτήτων.
- **Διαχρονική ανάλυση:** Εξέταση της εξέλιξης των συναισθημάτων στο Stack Overflow από την ίδρυσή του έως σήμερα.

7.1.3 Πολυγλωσσική Ανάλυση

- **Multilingual models:** Χρήση πολυγλωσσικών μοντέλων (mBERT, XLM-RoBERTa) για ανάλυση σε μη αγγλόφωνες κοινότητες.
- **Τοπικές εκδόσεις Stack Overflow:** Ανάλυση των ισπανικών, πορτογαλικών, ρωσικών και ιαπωνικών εκδόσεων της πλατφόρμας.
- **Cross-lingual transfer:** Διερεύνηση της μεταφοράς γνώσης μεταξύ γλωσσών για ανάλυση συναισθήματος.

7.2 Ποιοτική Ανάλυση και Επαλήθευση

7.2.1 Σύγκριση με Baseline Μοντέλα

- **Λεξικά-based μέθοδοι:** Σύγκριση με παραδοσιακές μεθόδους όπως VADER, TextBlob, AFINN.
- **Machine Learning baselines:** Αξιολόγηση με SVM, Random Forest, Logistic Regression χρησιμοποιώντας TF-IDF features.
- **Προηγούμενα deep learning μοντέλα:** Σύγκριση με LSTM, BiLSTM, CNN για κείμενο.

7.2.2 Ποιοτική Έρευνα

- **Ανάλυση λαθών (Error analysis):** Συστηματική εξέταση των περιπτώσεων διαφωνίας για την κατανόηση των αδυναμιών των μοντέλων.
- **Συνεντεύξεις με χρήστες:** Διεξαγωγή συνεντεύξεων με χρήστες του Stack Overflow για επαλήθευση των ευρημάτων.
- **Case studies:** Λεπτομερής ανάλυση συγκεκριμένων threads για την κατανόηση της δυναμικής των συναισθημάτων σε τεχνικές συζητήσεις.

7.2.3 Cross-Validation και Robustness

- **K-fold cross-validation:** Εφαρμογή cross-validation για την αξιολόγηση της σταθερότητας των αποτελεσμάτων.
- **Bootstrap confidence intervals:** Υπολογισμός διαστημάτων εμπιστοσύνης για τις μετρικές αξιολόγησης.
- **Sensitivity analysis:** Εξέταση της ευαισθησίας των αποτελεσμάτων σε διαφορετικές παραμέτρους.

7.3 Προηγμένες Τεχνικές Ανάλυσης

7.3.1 Νεότερα Μοντέλα Transformer

- **DeBERTa:** Χρήση του DeBERTa (Decoding-enhanced BERT) που έχει δείξει βελτιωμένη απόδοση σε NLU tasks.
- **ELECTRA:** Εξέταση του ELECTRA για πιο αποδοτική προεκπαίδευση.
- **Large Language Models (LLMs):** Αξιολόγηση μοντέλων όπως GPT-4, Claude, LLaMA για zero-shot και few-shot sentiment analysis.

7.3.2 Fine-tuning σε Domain-Specific Δεδομένα

- **Domain adaptation:** Fine-tuning των μοντέλων σε τεχνικά κείμενα (documentation, code comments, technical forums).
- **Continued pre-training:** Συνέχιση της προεκπαίδευσης σε μεγάλο corpus τεχνικών κειμένων πριν το fine-tuning.
- **Custom emotion taxonomy:** Ανάπτυξη ειδικής ταξινομίας συναισθημάτων για τεχνικές κοινότητες.

7.3.3 Ensemble και Hybrid Μέθοδοι

- **Model ensembling:** Συνδυασμός πολλαπλών μοντέλων (BERT, RoBERTa, DeBERTa) με voting ή stacking.
- **Hybrid approaches:** Συνδυασμός Transformer με λεξικά-based μεθόδους για βελτιωμένη ερμηνευσιμότητα.

- **Multi-task learning:** Ταυτόχρονη εκπαίδευση για πολλαπλές εργασίες (sentiment, emotion, sarcasm detection).

7.3.4 Aspect-Based Sentiment Analysis

- **Αναγνώριση aspects:** Εντοπισμός συγκεκριμένων πτυχών (code quality, documentation, response time) στα σχόλια.
- **Sentiment per aspect:** Ανάλυση συναισθήματος για κάθε aspect ξεχωριστά.
- **Opinion mining:** Εξαγωγή δομημένων απόψεων από τα σχόλια.

7.4 Τεχνολογικές Επεκτάσεις

7.4.1 Χρονική Ανάλυση (Temporal Analysis)

- **Trend analysis:** Παρακολούθηση της εξέλιξης των συναισθημάτων στο χρόνο.
- **Event detection:** Αναγνώριση γεγονότων που επηρεάζουν το συναισθηματικό κλίμα (releases, security breaches).
- **Seasonal patterns:** Εξέταση εποχιακών μοτίβων στην έκφραση συναισθημάτων.

7.4.2 Ερμηνευσιμότητα (Explainability)

- **SHAP values:** Χρήση SHAP για την εξήγηση των προβλέψεων σε επίπεδο token.
- **LIME:** Εφαρμογή LIME για τοπικές ερμηνείες των προβλέψεων.
- **Attention visualization:** Οπτικοποίηση των attention weights για την κατανόηση της εστίασης του μοντέλου.

7.4.3 Ανίχνευση Ειρωνείας και Σαρκασμού

- **Sarcasm detection:** Ανάπτυξη ειδικού module για την ανίχνευση σαρκασμού, που είναι συχνός στις τεχνικές κοινότητες.
- **Context-aware analysis:** Χρήση του context της συζήτησης για καλύτερη κατανόηση της πρόθεσης.
- **Multi-modal signals:** Ενσωμάτωση σημάτων όπως formatting, code blocks, και links.

7.4.4 Real-Time Ανάλυση

- **Streaming pipeline:** Ανάπτυξη pipeline για ανάλυση σε πραγματικό χρόνο.
- **Dashboard:** Δημιουργία διαδραστικού dashboard για την παρακολούθηση του συναισθηματικού κλίματος.
- **Alert system:** Σύστημα ειδοποιήσεων για ανίχνευση αρνητικών τάσεων ή toxic behavior.

7.5 Εφαρμογές και Αξιοποίηση

- **Community health monitoring:** Εργαλείο για τους moderators του Stack Overflow για την παρακολούθηση της υγείας της κοινότητας.
- **Automated content moderation:** Αυτόματη ανίχνευση toxic ή unwelcoming σχολίων.
- **User feedback analysis:** Ανάλυση feedback για βελτίωση της πλατφόρμας.
- **Developer well-being:** Εργαλεία για την παρακολούθηση της ψυχικής υγείας των developers μέσω της ανάλυσης της επικοινωνίας τους.

7.6 Σύνοψη Μελλοντικών Κατευθύνσεων

Ο Πίνακας 35 συνοψίζει τις προτεινόμενες μελλοντικές κατευθύνσεις ανά προτεραιότητα.

Table 35: Σύνοψη προτάσεων για μελλοντική έρευνα ανά προτεραιότητα

Προτεραιότητα	Πρόταση	Αναμενόμενο Όφελος	Απαιτούμενοι Πόροι
Υψηλή	Δημιουργία ground truth dataset	Αξιολόγηση απόλυτης ακρίβειας	Ανθρώπινοι αξιολογητές
Υψηλή	Fine-tuning σε τεχνικά κείμενα	Βελτιωμένη domain accuracy	GPU resources
Μέτρια	Νεότερα μοντέλα (DeBERTa, LLMs)	Βελτιωμένη απόδοση	Υπολογιστικοί πόροι
Μέτρια	Aspect-based analysis	Λεπτομερέστερα insights	Ερευνητικός χρόνος
Χαμηλή	Πολυγλωσσική ανάλυση	Ευρύτερη εφαρμογή	Πολυγλωσσικά δεδομένα
Χαμηλή	Real-time dashboard	Πρακτική αξιοποίηση	Ανάπτυξη εφαρμογής

7.7 Επίλογος

Η παρούσα πτυχιακή εργασία αποτελεί μια ολοκληρωμένη συγκριτική μελέτη των μοντέλων BERT και RoBERTa για την ανάλυση συναισθήματος σε τεχνικές διαδικτυακές κοινότητες. Μέσω της ανάλυσης 108.687 σχολίων του Stack Overflow, η εργασία κατέδειξε την αποτελεσματικότητα των μοντέλων Transformer στην αναγνώριση συναισθημάτων, αναδεικνύοντας παράλληλα τη σημασία της βαθμονόμησης (calibration) ως κριτήριο αξιολόγησης.

Τα ευρήματα της έρευνας έχουν τόσο θεωρητική όσο και πρακτική σημασία. Από θεωρητική άποψη, η εργασία συνεισφέρει στην κατανόηση της συμπεριφοράς των μοντέλων Transformer σε τεχνικά κείμενα και αναδεικνύει τις διαφορές στη βαθμονόμηση μεταξύ BERT και RoBERTa. Από πρακτική άποψη, παρέχει κατευθυντήριες γραμμές για την επιλογή μοντέλου ανάλογα με τις απαιτήσεις της εκάστοτε εφαρμογής.

Η ανάλυση συναισθήματος σε τεχνικές κοινότητες αποτελεί ένα αναδυόμενο ερευνητικό πεδίο με σημαντικές προοπτικές. Καθώς οι διαδικτυακές κοινότητες developers συνεχίζουν να αναπτύσσονται, η κατανόηση του συναισθηματικού τόνου της επικοινωνίας μπορεί να συμβάλει στη βελτίωση της ποιότητας της αλληλεπίδρασης, στην ανίχνευση προβληματικών συμπεριφορών, και στη δημιουργία πιο φιλόξενων περιβαλλόντων για νέους και έμπειρους προγραμματιστές.

Η παρούσα εργασία θέτει τα θεμέλια για μελλοντική έρευνα στον τομέα, προτείνοντας συγ-

κεκριμένες κατευθύνσεις για την επέκταση και βελτίωση της ανάλυσης. Η δημιουργία ground truth datasets, η εφαρμογή νεότερων μοντέλων, και η ανάπτυξη πρακτικών εφαρμογών αποτελούν τα επόμενα βήματα για την πλήρη αξιοποίηση του δυναμικού της ανάλυσης συναισθήματος στις τεχνικές κοινότητες.

"The emotional tone of technical communities reflects not just the challenges developers face, but also the supportive nature of collaborative problem-solving."

8 Βιβλιογραφία

[1] Stefano Baccianella, Andrea Esuli, and Fabrizio Sebastiani. "SentiWordNet 3.0: an enhanced lexical resource for sentiment analysis and opinion mining". In: *Proceedings of the Seventh International Conference on Language Resources and Evaluation (LREC'10)*. 2010.

[2] Francesco Barbieri et al. "TweetEval: Unified benchmark and comparative evaluation for tweet classification". In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, pp. 1644–1650.

[3] Tom Brown et al. "Language models are few-shot learners". In: *Advances in neural information processing systems* 33 (2020), pp. 1877–1901.

[4] Fabio Calefato et al. "Sentiment polarity detection for software development". In: *Empirical Software Engineering* 23.3 (2018), pp. 1352–1382.

[5] Jacob Cohen. "A coefficient of agreement for nominal scales". In: *Educational and Psychological Measurement* 20.1 (1960), pp. 37–46.

[6] Dorottya Demszky et al. "GoEmotions: A dataset of fine-grained emotions". In: *arXiv preprint arXiv:2005.00547* (2020).

[7] Shrey Desai and Greg Durrett. "Calibration of pre-trained transformers". In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. 2020, pp. 295–302.

[8] Jacob Devlin et al. "BERT: Pre-training of deep bidirectional transformers for language understanding". In: *arXiv preprint arXiv:1810.04805* (2018).

[9] Zhengjie Gao et al. "Target-dependent sentiment classification with BERT". In: *IEEE Access* 7 (2019), pp. 154290–154299.

[10] Alec Go, Richa Bhayani, and Lei Huang. *Twitter sentiment classification using distant supervision*. Tech. rep. Stanford University, 2009.

[11] Sepp Hochreiter and Jürgen Schmidhuber. "Long short-term memory". In: *Neural computation* 9.8 (1997), pp. 1735–1780.

[12] Minqing Hu and Bing Liu. "Mining and summarizing customer reviews". In: *Proceedings of the tenth ACM SIGKDD international conference on Knowledge discovery and data mining*. 2004, pp. 168–177.

[13] Clayton Hutto and Eric Gilbert. "VADER: A parsimonious rule-based model for sentiment analysis of social media text". In: *Proceedings of the International AAAI Conference on Web and Social Media*. Vol. 8. 1. 2014, pp. 216–225.

[14] Yoon Kim. "Convolutional neural networks for sentence classification". In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2014, pp. 1746–1751.

[15] Zhenzhong Lan et al. "ALBERT: A lite BERT for self-supervised learning of language representations". In: *arXiv preprint arXiv:1909.11942* (2019).

[16] Bin Lin et al. "Opinion mining for software development: A systematic literature review". In: *ACM Transactions on Software Engineering and Methodology* 31.3 (2022), pp. 1–41.

[17] Bing Liu. "Sentiment analysis and opinion mining". In: *Synthesis lectures on human language technologies* 5.1 (2012), pp. 1–167.

[18] Yinhan Liu et al. "RoBERTa: A robustly optimized BERT pretraining approach". In: *arXiv preprint arXiv:1907.11692* (2019).

[19] Quinn McNemar. "Note on the sampling error of the difference between correlated proportions or percentages". In: *Psychometrika* 12.2 (1947), pp. 153–157.

[20] Tomas Mikolov et al. "Distributed representations of words and phrases and their compositionality". In: *Advances in neural information processing systems* 26 (2013).

[21] Dat Quoc Nguyen, Thanh Vu, and Anh Tuan Nguyen. "BERTweet: A pre-trained language model for English Tweets". In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. 2020, pp. 9–14.

[22] Nicole Novielli, Fabio Calefato, and Filippo Lanubile. "A benchmark study on sentiment analysis for software engineering research". In: *Proceedings of the 15th International Conference on Mining Software Repositories*. 2018, pp. 364–375.

[23] Bo Pang and Lillian Lee. "Opinion mining and sentiment analysis". In: *Foundations and Trends in Information Retrieval* 2.1–2 (2008), pp. 1–135.

[24] Bo Pang, Lillian Lee, and Shivakumar Vaithyanathan. "Thumbs up? Sentiment classification using machine learning techniques". In: *Proceedings of the ACL-02 conference on Empirical methods in natural language processing*. 2002, pp. 79–86.

[25] Jeffrey Pennington, Richard Socher, and Christopher D Manning. "GloVe: Global vectors for word representation". In: *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*. 2014, pp. 1532–1543.

[26] Sara Rosenthal, Noura Farra, and Preslav Nakov. "SemEval-2017 Task 4: Sentiment analysis in Twitter". In: *Proceedings of the 11th International Workshop on Semantic Evaluation*. 2017, pp. 502–518.

[27] Victor Sanh et al. "DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter". In: *arXiv preprint arXiv:1910.01108* (2019).

[28] Richard Socher et al. "Recursive deep models for semantic compositionality over a sentiment treebank". In: *Proceedings of the 2013 conference on empirical methods in natural language processing*. 2013, pp. 1631–1642.

[29] Marina Sokolova and Guy Lapalme. "A systematic analysis of performance measures for classification tasks". In: *Information Processing & Management* 45.4 (2009), pp. 427–437.

[30] Chi Sun et al. "How to fine-tune BERT for text classification". In: *China National Conference on Chinese Computational Linguistics*. 2019, pp. 194–206.

[31] Peter D Turney. "Thumbs up or thumbs down? Semantic orientation applied to unsupervised classification of reviews". In: *Proceedings of the 40th annual meeting of the association for computational linguistics*. 2002, pp. 417–424.

[32] Ashish Vaswani et al. "Attention is all you need". In: *Advances in neural information processing systems* 30 (2017).

[33] Lei Zhang, Shuai Wang, and Bing Liu. "Deep learning for sentiment analysis: A survey". In: *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 8.4 (2018), e1253.

[34] Wenxuan Zhang et al. "Sentiment analysis in the era of large language models: A reality check". In: *arXiv preprint arXiv:2305.15005* (2023).